

Capitolul 1

METODE EXPLORATORII MULTIDIMENSIONALE

Metodele exploratorii multidimensionale își propun să furnizeze reprezentări sintetice ale unor mulțimi mari de valori numerice, în general sub forma unor vizualizări grafice. Pentru aceasta, se urmărește reducerea dimensiunilor tabelului de date prin reprezentarea asociațiilor între indivizi și variabile în spații de dimensiuni mici. Distanțele între liniile sau între coloanele unui tabel dreptunghiular de valori numerice pot fi întotdeauna calculate dar nu este posibilă vizualizarea imediată a acestora, reprezentările geometrice asociate implicând, în general, spații de dimensiuni superioare lui trei. Este necesar să procedăm la transformări și aproximări pentru a obține o reprezentare plană.

Metodele exploratorii vor căuta, în consecință, subspații de dimensiuni mici - unu, doi sau trei - care aproximează cel mai bine norul de puncte-individ sau cel de puncte-variabilă astfel încât vecinătățile măsurate în aceste spații să reflecte cât mai exact proximitățile reale. Se obține astfel un spațiu de reprezentare, spațiul factorial. Geometria norilor de puncte și calculul proximităților sau a distanțelor care decurg de aici diferă în funcție de natura liniilor și coloanelor tabelului analizat.

Coloanele tabelelor dreptunghiulare de date pot fi variabile continue sau variabile nominale sau categorii în cazul tabelelor de contingență. Liniile pot fi indivizi sau categorii. Natura informațiilor, codificarea, specificitatea domeniului de aplicație vor introduce variante în cadrul metodei factoriale.

În cele ce urmează vor fi prezentate trei tehnici fundamentale:

- **analiza în componente principale** (secțiunea 1.2) se aplică tabelelor de tip "variabile-indivizi" unde coloanele sunt variabile numerice continue și liniile sunt indivizi, observații, obiecte, etc. Proximitățile între variabile se interpretează în termeni de corelații. Proximitățile între indivizi se interpretează în termeni de similitudini globale ale valorilor observate.

- **analiza corespondențelor simple** (secțiunea 1.3) se aplică tabelelor de contingență, adică tabelelor ce conțin numărul indivizilor care posedă concomitent două modalități a două variabile nominale. Aceste tabele au particularitatea că atât liniile cât și coloanele lor joacă un rol identic în analiza corespondențelor simple. Analiza furnizează reprezentări ale asociațiilor între liniile și coloanele tabelelor bazate pe o distanță între profile (care sunt vectori de frecvențe condiționate) cunoscută sub numele de distanța χ^2 .
- **analiza corespondențelor multiple** (secțiunea 1.4) este o extindere a domeniului aplicațiilor analizei corespondențelor simple, având totuși proceduri de calcul și reguli de interpretare specifice. Ea face obiectul unei mențiuni particulare datorită numărului mare de aplicații la care se pretează. Analiza corespondențelor multiple este în mod deosebit adaptată la descrierea tabelelor mari de variabile nominale, cum sunt fișierele de anchete socio-economice sau cele medicale. Liniile acestor tabele sunt, în general, indivizi sau observații (pot exista câteva mii); coloanele sunt modalități ale variabilelor nominale, cel mai adesea modalitățile răspunsurilor la întrebări.

Oricare ar fi tipul tabelului de date, toate tehnicile factoriale au un nucleu comun prezentat în secțiunea 1.1 sub forma unor **preliminarii matematice**.

1.1 Preliminarii matematice

1.1.1 Concepte metrice într-un spațiu euclidian

Fie X mulțime oarecare, $X \neq \emptyset$.

Definiția 1.1.1 O *metrică* pe mulțimea X este o aplicație, $d : X \times X \rightarrow \mathbb{R}$, care satisface următoarele axiome :

- $d(x, y) = d(y, x)$, $(\forall) x, y \in X$ (simetrică);
- $d(x, y) \geq 0$, $(\forall) x, y \in X$ (pozitivă);
- $d(x, y) = 0 \Leftrightarrow x = y$, $(\forall) x, y \in X$ (idempotentă);
- $d(x, y) \leq d(x, z) + d(z, y)$, $(\forall) x, y, z \in X$ (inegalitatea triunghiului).

Definiția 1.1.2 Dacă $d : X \times X \rightarrow \mathbb{R}$ este o aplicație care satisface axiomele (a)÷(c) și în plus este satisfăcută axioma

$$d') \quad d(x, y) \leq \max(d(x, z), d(z, y)), \quad (\forall) x, y, z \in X$$

atunci d se numește *ultrametrică* pe X .

În particular, maximul (minimul) formeii pătrărice simetrice $F(\mathbf{x}, \mathbf{x})$ pe sfera unitate este egal cu cea mai mare (cea mai mică) valoare proprie a lui $\mathbf{A}$.

Vectorul propriu corespunzând celei mai mari valori proprii este un vector ce pornește din origine și trece prin punctul de pe sfera unitate în care este atins maximul.

1.2 Analiza în componente principale (ACP)

Inventată de Karl Pearson în 1901 și introdusă în statistica matematică de Harold Hotelling în 1933, analiza în componente principale a început să fie utilizată efectiv odată cu apariția și extinderea calculatoarelor electronice.

Analiza în componente principale, ACP, poate fi prezentată din diverse puncte de vedere:

- pentru statisticianul clasic, analiza în componente principale înseamnă a estima, pornind de la un eșantion dat, axele principale ale elipsoidului indicator al unei distribuții normale multidimensionale. Aceasta este prezentarea inițială a lui Hotelling urmată apoi de manualele clasice de analiză multivariată (cazul lucrării fundamentale [2]);
- pentru psihologi, analiza în componente principale este un caz particular de analiză factorială utilizată în psihometrie (cazul dispersiilor nule sau egale, conform [33]);
- în fine, pentru analiștii de date, analiza în componente principale este o tehnică de reprezentare a datelor cu un caracter optimal din punct de vedere al unor criterii algebrice sau geometrice, utilizată, în general, fără vreo referire la ipoteze de natură statistică sau la un model particular. Acest punct de vedere, adoptat în cele ce urmează, este foarte răspândit la ora actuală. Este probabil cel mai vechi punct de vedere, regăsindu-se în lucrările lui Pearson. Desigur, în prezentarea acestuia nu este vorba de analiza în componente principale așa cum este ea expusă astăzi, dar pot fi deja întrevăzute ideile esențiale ale metodei. O discuție mai largă asupra acestui subiect se găsește în articolul de sinteză [51].

Analiza în componente principale este utilizată pentru a pune în evidență:

- sistemul de relații existente între variabile (asocierea sau opoziția lor);
- reprezentarea indivizilor în raport cu variabilele observate (indivizi care prezintă caracteristici comune sau antagoniste).

Eventualul utilizator al analizei în componente principale trebuie să posede un tabel dreptunghiular de măsurători în care coloanele reprezintă variabile

numerice continue, sau care pot fi considerate continue, iar liniile reprezintă indivizii pe care au fost măsurate aceste variabile. În biometrie se procedează frecvent la multiple măsurători asupra unor organe sau animale, în economie se înregistrează diverși indicatori privind agenții economici.

Într-o manieră generală, condiția pe care trebuie să o îndeplinească aceste tabele numerice pentru a face obiectul unei analize în componente principale este următoarea: una dintre dimensiunile tabelului (liniile în general) este formată din unități avînd caracter repetitiv, cealaltă dimensiune poate fi mai degrabă eterogenă. În exemplele de mai jos liniile au acest caracter repetitiv. Acestea vor fi numite indivizi sau observații. Coloanele vor fi desemnate ca variabile. Uneori liniile pot fi considerate ca realizări independente ale unor vectori aleatori ale căror componente corespund la diferite variabile. După proveniența variabilelor, trei mari categorii de tabele pot face obiectul unui demers de analiză în componente principale:

1. **Tabelele de măsurători:** variabilele sunt obținute în urma unui sondaj sau recensământ și sunt cantitative.

TABELUL 1.2.1. CONSUMUL MEDIU ANUAL ÎN 1972, EXPRIMAT ÎN FRANCI FRANCEZI, PENTRU 7 TIPURI DE ALIMENTE, ÎN CAZUL A 8 CATEGORII SOCIO-PROFESIONALE

	PAO	PAA	VIO	VIA	POT	LEC
ȚĂRANI	167	1	163	23	41	8
SALARIAȚI AGRICOLI	162	2	141	12	40	12
LIBER PROFESIONIȘTI	119	6	69	56	39	5
CADRE SUPERIOARE	87	11	63	111	27	3
CADRE MEDII	103	5	68	77	32	4
FUNCȚIONARI	111	4	72	66	34	6
MUNCITORI	130	3	76	52	43	7
INACTIVI	138	7	117	74	53	8

(Sursă: A. Villeneuve, *La consommation alimentaire des Français*, collections de l'INSEE, M34)

2. **Tabelele de note:** variabilele sunt obținute în urma unor notații. Notele sunt variabile calitative ce pot fi, în general, asimilate cu variabilele cantitative.

TABELUL 1.2.2. NOTELE OBȚINUTE DE 4 STUDENȚI LA 3 MATERII

	MATEMATICĂ	FIZICĂ	ENGLEZĂ
STUD1	9	8	8
STUD2	10	9	6
STUD3	9	7	10
STUD4	7	5	10

3. **Tabelele de ranguri:** variabilele sunt obținute în urma unor clasamente și sunt variabile calitative ordinale care pot fi transformate în variabile continue.

TABELUL 1.2.3. CLASAMENTUL TABLOURILOR A TREI PICTORI,
PIC1 ÷ PIC3, REALIZAT DE PATRU EXPERTI A ÷ D.

	A	B	C	D
PIC1	1	3	2	1
PIC2	3	1	1	3
PIC3	2	2	3	2

După cum vom vedea, în funcție de transformările aduse tabelului de date, analiza în componente principale prezintă numeroase variante: norul de puncte-indivizi poate fi centrat sau nu, redus sau nu. Dintre aceste variante, analiza în componente principale normată (central-redusă) este cea mai utilizată.

1.2.1 Date și caracteristicile lor

Se presupune că dispunem de observații asupra a p variabile continue măsurate pe n indivizi. Valorile sunt "listate" într-un tabel de n linii și p coloane. Notăm cu $\mathbf{X} = (x_{ij})_{i=1,n}^{j=1,p}$ matricea asociată tabelului, unde x_{ij} este valoarea luată de variabila j măsurată pe individul i .

O variabilă este identificată prin vectorul-coloană j al tabelului $\mathbf{X}$ (notație $\mathbf{x}_j$) iar un individ prin vectorul-linie i (notație $\mathbf{x}_i$).

Dacă datele nu au fost culese în urma unui sondaj aleator cu probabilități egale atunci fiecărui individ i i se atribuie o pondere¹ p_i , conform importanței pe care o are în studiul întreprins.

Definiția 1.2.1 Se numește *matrice (sau metrică) de ponderi* matricea

$$\mathbf{D} = \text{diag}(p_1, \dots, p_n), \text{ unde } p_i > 0, (\forall) i = \overline{1, n} \text{ și } \sum_i p_i = 1.$$

În cazul indivizilor echiponderați $\mathbf{D} = \frac{1}{n}\mathbf{I}_n$, unde $\mathbf{I}_n$ este matricea identitate de dimensiune n .

Să notăm că $\mathbf{x}_j$ poate fi interpretat ca o selecție de volum n asupra variabilei j și că, în acest context:

- *media de selecție* a variabilei j este

$$m(\mathbf{x}_j) \equiv \bar{x}_j = \sum_i p_i x_{ij},$$

¹Termenii de "pondere" sau "masă" sunt utilizați cu același sens în statistică și desemnează adesea frecvențele relative sau probabilitățile *a priori*.

- *dispersia de selecție* a variabilei j este

$$s^2(\mathbf{x}_j) \equiv s_j^2 = \sum_i p_i (x_{ij} - \bar{x}_j)^2,$$

- *covarianța de selecție* a variabilelor j și j' este

$$\text{cov}(\mathbf{x}_j, \mathbf{x}_{j'}) \equiv v_{jj'} = \sum_i p_i (x_{ij} - \bar{x}_j) (x_{ij'} - \bar{x}_{j'}),$$

- *coeficientul de corelație de selecție* a variabilelor j și j' este

$$\text{cor}(\mathbf{x}_j, \mathbf{x}_{j'}) \equiv r_{jj'} = \frac{v_{jj'}}{s_j s_{j'}}.$$

Definiția 1.2.2 Se numește *punct mediu (centru de greutate)* al norului de puncte-individ $\{\mathbf{e}_i\}_{i=1}^n$ vectorul $\mathbf{g}' = (\bar{x}_1, \dots, \bar{x}_p)$.

Se observă că:

$$\mathbf{g} = \mathbf{X}'\mathbf{D}\mathbf{1}_n \text{ unde } \mathbf{1}'_n = (1, \dots, 1) \in \mathbb{R}^n.$$

Într-adevăr,

$$\begin{aligned} \mathbf{X}'\mathbf{D}\mathbf{1}_n &= \begin{pmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \\ \vdots & & & \vdots \\ x_{1p} & x_{2p} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} p_1 & 0 & \dots & 0 \\ 0 & p_2 & \dots & 0 \\ & & \ddots & \\ 0 & 0 & \dots & p_n \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \\ &= \begin{pmatrix} p_1 x_{11} & p_2 x_{21} & \dots & p_n x_{n1} \\ p_1 x_{12} & p_2 x_{22} & \dots & p_n x_{n2} \\ \vdots & & & \vdots \\ p_1 x_{1p} & p_2 x_{2p} & \dots & p_n x_{np} \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} = \\ &= \left(\sum_i p_i x_{i1} \quad \sum_i p_i x_{i2} \quad \dots \quad \sum_i p_i x_{ip} \right)' = (\bar{x}_1 \quad \bar{x}_2 \quad \dots \quad \bar{x}_p)' = \mathbf{g}. \end{aligned}$$

Definiția 1.2.3 Se numește *tabel centrat asociat lui X* matricea

$$\mathbf{Y} = (y_{ij})_{i=1,n}^{j=\overline{1,p}} \text{ unde } y_{ij} = x_{ij} - \bar{x}_j.$$

Se numește *tabel centrat-redus asociat lui X* matricea

$$\mathbf{Z} = (z_{ij})_{i=1,n}^{j=\overline{1,p}} \text{ unde } z_{ij} = \frac{y_{ij}}{s_j}.$$

Lema 1.2.1

a) $\mathbf{Y} = \mathbf{X} - \mathbf{1}_n \mathbf{g}' = (\mathbf{I}_n - \mathbf{1}_n \mathbf{1}_n' \mathbf{D}) \mathbf{X}.$

b) $\mathbf{Z} = \mathbf{Y} \mathbf{D}_{\frac{1}{s}}$ unde $\mathbf{D}_{\frac{1}{s}} = \text{diag} \left(\frac{1}{s_1}, \dots, \frac{1}{s_p} \right).$

c) Matricea de varianță-covarianță asociată tabelului $\mathbf{X}$ este

$$\mathbf{V} = \mathbf{X}' \mathbf{D} \mathbf{X} - \mathbf{g} \mathbf{g}' = \mathbf{Y}' \mathbf{D} \mathbf{Y}.$$

d) Matricea de corelație asociată tabelului $\mathbf{X}$ este

$$\mathbf{R} = \mathbf{D}_{\frac{1}{s}} \mathbf{V} \mathbf{D}_{\frac{1}{s}} = \mathbf{Z}' \mathbf{D} \mathbf{Z}.$$

Demonstrație. a) Conform definiției,

$$\begin{aligned} \mathbf{Y} &= \begin{pmatrix} x_{11} - \bar{x}_1 & x_{12} - \bar{x}_2 & \dots & x_{1p} - \bar{x}_p \\ x_{21} - \bar{x}_1 & x_{22} - \bar{x}_2 & \dots & x_{2p} - \bar{x}_p \\ \vdots & & & \vdots \\ x_{n1} - \bar{x}_1 & x_{n2} - \bar{x}_2 & \dots & x_{np} - \bar{x}_p \end{pmatrix} = \\ &= \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} - \begin{pmatrix} \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_p \\ \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_p \\ \vdots & & & \vdots \\ \bar{x}_1 & \bar{x}_2 & \dots & \bar{x}_p \end{pmatrix} = \\ &= \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} (\bar{x}_1 \quad \bar{x}_2 \quad \dots \quad \bar{x}_p) = \mathbf{X} - \mathbf{1}_n \mathbf{g}' \end{aligned}$$

dar

$$\mathbf{X} - \mathbf{1}_n \mathbf{g}' = \mathbf{X} - \mathbf{1}_n (\mathbf{X}' \mathbf{D} \mathbf{1}_n)' = \mathbf{X} - \mathbf{1}_n \mathbf{1}_n' \mathbf{D} \mathbf{X} = (\mathbf{I}_n - \mathbf{1}_n \mathbf{1}_n' \mathbf{D}) \mathbf{X}.$$

b) Rezultă imediat din definiția lui $\mathbf{Z}$.

c) Relația $\mathbf{V} = \mathbf{Y}' \mathbf{D} \mathbf{Y}$ rezultă din definiția lui $\mathbf{V}$. Pe de altă parte,

$$\begin{aligned} v_{kk'} &= \sum_i p_i (x_{ik} - \bar{x}_k) (x_{ik'} - \bar{x}_{k'}) = \\ &= \sum_i p_i x_{ik} x_{ik'} - \sum_i p_i x_{ik} \bar{x}_{k'} - \sum_i p_i \bar{x}_k x_{ik'} + \sum_i p_i \bar{x}_k \bar{x}_{k'} = \\ &= \sum_i p_i x_{ik} x_{ik'} - \bar{x}_{k'} \sum_i p_i x_{ik} - \bar{x}_k \sum_i p_i x_{ik'} + \bar{x}_k \bar{x}_{k'} \sum_i p_i = \\ &= \sum_i p_i x_{ik} x_{ik'} - \bar{x}_{k'} \bar{x}_k - \bar{x}_k \bar{x}_{k'} + \bar{x}_k \bar{x}_{k'} = \sum_i p_i x_{ik} x_{ik'} - \bar{x}_k \bar{x}_{k'} \\ \Rightarrow \mathbf{V} &= \mathbf{X}' \mathbf{D} \mathbf{X} - \mathbf{g} \mathbf{g}'; \text{ am folosit faptul că } \bar{x}_k = \sum_i p_i x_{ik} \end{aligned}$$

d)

$$\mathbf{R} = \mathbf{D}_{\frac{1}{s}} \mathbf{V} \mathbf{D}_{\frac{1}{s}} = \mathbf{D}_{\frac{1}{s}} \mathbf{Y}' \mathbf{D} \mathbf{Y} \mathbf{D}_{\frac{1}{s}} = \left(\mathbf{Y} \mathbf{D}_{\frac{1}{s}} \right)' \mathbf{D} \left(\mathbf{Y} \mathbf{D}_{\frac{1}{s}} \right) = \mathbf{Z}' \mathbf{D} \mathbf{Z}$$

unde prima egalitate rezultă din definiția lui $\mathbf{R}$. ■**Observația 1.2.1**

Relația $\mathbf{Z}' \mathbf{D} \mathbf{Z} = \sum_{i=1}^n p_i \mathbf{e}_i \mathbf{e}_i'$ este o formulă utilă implementării pe calculator a metodei deoarece evită introducerea în memoria RAM a întregii matrici $\mathbf{X}$.

1.2.1.1 SPAȚIUL INDIVIZILOR

Să analizăm exemplul din tabelul 1.2.2.:

	MATEMATICA	FIZICA	ENGLEZA
STUD1	9	8	8
STUD2	10	9	6
STUD3	9	7	10
STUD4	7	5	10

Individul **stud1** este “caracterizat” de cele trei note obținute: 9 la matematică, 9 la fizică și 8 la engleză. La fel și indivizii **stud2 ÷ stud4**. Reamintim că notația pentru individul i este $\mathbf{e}_i'$. Așadar, pentru exemplul de mai sus: $\mathbf{e}_1' = (9 \ 8 \ 8)$, $\mathbf{e}_2' = (10 \ 9 \ 6)$ etc.

În general, un individ $\mathbf{e}_i'$ este definit de p coordonate corespunzând valorilor celor p variabile măsurate pe acest individ. Îl putem, deci, considera ca un element dintr-un spațiu vectorial $\mathcal{F} \subset \mathbb{R}^p$, pe care îl numim *spațiul indivizilor* (fig. 1.2.1.). Mulțimea celor n indivizi formează un “nor de puncte-individ” în spațiul $\mathcal{F}$, cu $\mathbf{g}$ centrul de greutate al norului. În continuare vom înzestra acest spațiu cu o metrică ce permite definirea distanței dintre indivizi.




FIG. 1.2.1. PRINCIPIUL REPREZENTĂRII GEOMETRICE

Fie $\mathbf{M} \in \mathcal{M}_{p,p}(\mathbb{R})$, o matrice simetrică, pozitiv definită, de dimensiune p , cu coeficienți reali.

Definiția 1.2.4 Se numește *matricea produsului scalar între indivizi* matricea

$$\mathbf{W} = (w_{ij})_{i,j=1,n}^{j=\overline{1,n}}, \text{ unde } w_{ij} = \langle \mathbf{e}_i, \mathbf{e}_j \rangle$$

și $\langle \mathbf{e}_i, \mathbf{e}_j \rangle = \mathbf{e}_i' \mathbf{M} \mathbf{e}_j$ este produsul scalar pe spațiul $\mathcal{F}$ definit de metrica $\mathbf{M}$.

Se observă că

$$\mathbf{W} = \mathbf{X} \mathbf{M} \mathbf{X}'$$

și că distanța dintre doi indivizi, $\mathbf{e}_i$ și $\mathbf{e}_j$, din spațiul $\mathcal{F}$ este dată de relația

$$d^2(\mathbf{e}_i, \mathbf{e}_j) = \langle \mathbf{e}_i - \mathbf{e}_j, \mathbf{e}_i - \mathbf{e}_j \rangle_{\mathbf{M}} = \|\mathbf{e}_i - \mathbf{e}_j\|_{\mathbf{M}}^2$$

În teorie, alegerea metricii depinde de utilizator, singurul care poate preciza metrica adecvată. În practică, metricile cele mai uzitate în ACP sunt:

- $\mathbf{M} = \mathbf{I}_p$, ce induce produsul scalar uzual și distanța euclidiană;
- $\mathbf{M} = \mathbf{D}_{\frac{1}{s_j^2}}$. Utilizarea acestei metrici revine la adimensionalizarea variabilelor deoarece fiecare valoare este împărțită cu abaterea standard de selecție a variabilei corespunzătoare ($\frac{x_{ij}}{s_j}$).

Metrica $\mathbf{M} = \mathbf{I}_p$ dă fiecărei variabile aceeași importanță, independent de dispersia sa. Utilizarea ei va privilegia variabilele cu dispersie mare, pentru care diferențele între indivizi sunt mari, și va neglija diferențele între celelalte variabile. În schimb metrica $\mathbf{M} = \mathbf{D}_{\frac{1}{s_j^2}}$ echilibrează influența variabilelor transformându-le în variabile cu dispersia de selecție unu.

Observația 1.2.2

Dacă $\mathbf{M} = \text{diag}(m_1, \dots, m_p)$ atunci

$$d^2(\mathbf{e}_i, \mathbf{e}_j) = \sum_{k=1}^p m_k (x_{ik} - x_{jk})^2$$

iar coeficienții $\{\sqrt{m_k}\}_{k=1,p}$ pot fi considerați ca ponderi ale variabilelor $\mathbf{x}_j$ în distanța dintre indivizi.

Lema 1.2.2

Matricea produsului scalar între indivizi poate fi întotdeauna exprimată în funcție de metrica $\mathbf{I}_p$.

Demonstrație. Într-adevăr, dacă $\mathbf{M}$ este simetrică și pozitiv definită atunci ea poate fi scrisă ca $\mathbf{M} = \mathbf{T}'\mathbf{T}$ (conform algoritmului lui Cholesky din [15]). Atunci $\langle \mathbf{e}_i, \mathbf{e}_j \rangle_{\mathbf{M}} = \mathbf{e}_i' \mathbf{M} \mathbf{e}_j = \mathbf{e}_i' \mathbf{T}' \mathbf{T} \mathbf{e}_j = (\mathbf{T} \mathbf{e}_i)' (\mathbf{T} \mathbf{e}_j) = (\mathbf{T} \mathbf{e}_i)' \mathbf{I}_p (\mathbf{T} \mathbf{e}_j)$, ceea ce înseamnă că $\mathbf{W} = (\mathbf{X} \mathbf{T}') \mathbf{I}_p (\mathbf{T} \mathbf{X}')$, adică $\mathbf{W}$ este matricea produsului scalar al tabelului $\mathbf{X} \mathbf{T}'$ față de metrica $\mathbf{M} = \mathbf{I}_p$. ■

Corolarul 1.2.1

Utilizarea metricii $\mathbf{M} = \mathbf{D}_{\frac{1}{s^2}}$ pentru tabelul $\mathbf{Y}$ revine la folosirea metricii $\mathbf{M} = \mathbf{I}_p$ pentru tabelul centrat-redus $\mathbf{Z}$.

Reamintim că *ipoteza fundamentală a unui demers ACP* este aceea că întreaga informație este conținută în distanțele dintre punctele-individ ale norului. Acest lucru justifică introducerea noțiunii de “inerție totală”².

Definiția 1.2.5 Se numește *inerție totală (globală)* a norului de puncte-individ media ponderată a pătratelor distanțelor de la punctele-individ la centrul de greutate al norului, adică:

$$I_{\mathbf{g}} = \sum_{i=1}^n p_i (\mathbf{e}_i - \mathbf{g})' \mathbf{M} (\mathbf{e}_i - \mathbf{g}) = \sum_{i=1}^n p_i \|\mathbf{e}_i - \mathbf{g}\|_{\mathbf{M}}^2.$$

Prin analogie, *inerția într-un punct oarecare*, $\mathbf{a} \in \mathbb{R}^p$, se definește ca fiind
$$I_{\mathbf{a}} = \sum_{i=1}^n p_i \|\mathbf{e}_i - \mathbf{a}\|_{\mathbf{M}}^2.$$

Proprietățile inerției globale, puse în evidență de enunțurile de mai jos, sunt utile în demersul ce urmează.

Propoziția 1.2.1 (formula lui Huygens)

Inerția față de un punct satisface următoarea relație:

$$I_{\mathbf{a}} = I_{\mathbf{g}} + (\mathbf{g} - \mathbf{a})' \mathbf{M} (\mathbf{g} - \mathbf{a}) = I_{\mathbf{g}} + \|\mathbf{g} - \mathbf{a}\|_{\mathbf{M}}^2$$

Demonstrație. Într-adevăr,

$$\begin{aligned} I_{\mathbf{a}} &= \sum_{i=1}^n p_i (\mathbf{e}_i - \mathbf{a})' \mathbf{M} (\mathbf{e}_i - \mathbf{a}) = \\ &= \sum_{i=1}^n p_i [(\mathbf{e}_i - \mathbf{g}) + (\mathbf{g} - \mathbf{a})]' \mathbf{M} [(\mathbf{e}_i - \mathbf{g}) + (\mathbf{g} - \mathbf{a})] = \\ &= \sum_{i=1}^n p_i (\mathbf{e}_i - \mathbf{g})' \mathbf{M} (\mathbf{e}_i - \mathbf{g}) + \sum_{i=1}^n p_i (\mathbf{e}_i - \mathbf{g})' \mathbf{M} (\mathbf{g} - \mathbf{a}) + \\ &\quad + \sum_{i=1}^n p_i (\mathbf{g} - \mathbf{a})' \mathbf{M} (\mathbf{e}_i - \mathbf{g}) + \sum_{i=1}^n p_i (\mathbf{g} - \mathbf{a})' \mathbf{M} (\mathbf{g} - \mathbf{a}). \end{aligned}$$

²Termenul *inerție* este împrumutat din mecanică și este sinonim, în acest context, cu termenul statistic *dispersie*.

Se observă că primul termen al sumei este chiar $I_{\mathbf{g}}$, că produsul $(\mathbf{g} - \mathbf{a})' \mathbf{M} (\mathbf{g} - \mathbf{a})$ nu depinde de i , că $\sum_{i=1}^n p_i = 1$ și că produsele $(\mathbf{e}_i - \mathbf{g})' \mathbf{M} (\mathbf{g} - \mathbf{a})$ și $(\mathbf{g} - \mathbf{a})' \mathbf{M} (\mathbf{e}_i - \mathbf{g})$ sunt scalare. Cu aceasta egalitatea de mai sus devine

$$\begin{aligned} I_{\mathbf{a}} &= I_{\mathbf{g}} + 2 \left[\left(\sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{g} - \mathbf{g}' \mathbf{M} \mathbf{g} \right) + \left(\mathbf{g}' \mathbf{M} \mathbf{a} - \sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{a} \right) \right] + \\ &\quad + \|\mathbf{g} - \mathbf{a}\|_{\mathbf{M}}^2 \end{aligned}$$

Se notează $\mathbf{b}' = (\mathbf{M} \mathbf{g})' = (b_1, \dots, b_p)$ și reamintind că $g_j = \sum_{i=1}^n p_i x_{ij}$ rezultă

$$\begin{aligned} \sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{g} - \mathbf{g}' \mathbf{M} \mathbf{g} &= \sum_i p_i \sum_{j=1}^p x_{ij} b_j - \sum_{j=1}^p g_j b_j = \\ &= \sum_{j=1}^p b_j \left(\sum_i p_i x_{ij} \right) - \sum_{j=1}^p g_j b_j = 0. \end{aligned}$$

Analog $\mathbf{g}' \mathbf{M} \mathbf{a} - \sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{a} = 0$. ■

Corolarul 1.2.2

Pentru un nor de puncte-individ dat, $\mathbf{g}$, centrul de greutate al norului, minimizează inerția totală.

Lema 1.2.3

Inerția totală este media pătratelor distanțelor dintre punctele-individ, adică:

$$2I_{\mathbf{g}} = \sum_{i=1}^n \sum_{j=1}^n p_i p_j \|\mathbf{e}_i - \mathbf{e}_j\|_{\mathbf{M}}^2.$$

Demonstrație. Se aplică formula lui Huygens pentru fiecare punct-individ, apoi se adună cele n relații.

$$\begin{aligned} p_1 I_{\mathbf{e}_1} &= p_1 I_{\mathbf{g}} + \|\mathbf{e}_1 - \mathbf{g}\|_{\mathbf{M}}^2 \\ p_2 I_{\mathbf{e}_2} &= p_2 I_{\mathbf{g}} + \|\mathbf{e}_2 - \mathbf{g}\|_{\mathbf{M}}^2 \\ &\vdots \\ \underline{p_n I_{\mathbf{e}_n}} &= \underline{p_n I_{\mathbf{g}}} + \underline{\|\mathbf{e}_n - \mathbf{g}\|_{\mathbf{M}}^2} \\ \sum_{j=1}^n p_j I_{\mathbf{e}_j} &= \sum_{j=1}^n p_j I_{\mathbf{g}} + \sum_{j=1}^n p_j \|\mathbf{e}_j - \mathbf{g}\|_{\mathbf{M}}^2 \Rightarrow \\ \sum_{j=1}^n p_j \sum_{i=1}^n p_i \|\mathbf{e}_i - \mathbf{e}_j\|_{\mathbf{M}}^2 &= I_{\mathbf{g}} + I_{\mathbf{g}}. \end{aligned}$$

■

Lema 1.2.4

1. $I_{\mathbf{g}} = \text{tr}(\mathbf{MV}) = \text{tr}(\mathbf{VM})$, unde cu $\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}$ s-a notat urma matricii $\mathbf{A} \in \mathcal{M}_{n,n}(\mathbb{R})$.
2. Dacă centrul de greutate al norului este în originea axelor de coordonate, adică $\mathbf{g} = \mathbf{0}$, atunci $I_{\mathbf{g}} = \text{tr}(\mathbf{WD}) = \text{tr}(\mathbf{DW})$.

Demonstrație.

1. Într-adevăr

$$\text{tr}(\mathbf{MV}) = \text{tr}(\mathbf{MY}'\mathbf{DY}) = \sum_{i=1}^n \mathbf{M}\mathbf{y}_i p_i \mathbf{y}_i' = \sum_{i=1}^n p_i (\mathbf{e}_i - \mathbf{g})' \mathbf{M} (\mathbf{e}_i - \mathbf{g}) = I_{\mathbf{g}}.$$

$$\text{Analog } \text{tr}(\mathbf{VM}) = I_{\mathbf{g}}.$$

2. Dacă $\mathbf{g} = \mathbf{0}$ atunci $I_{\mathbf{g}} = \sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{e}_i$. Pe de altă parte,

$$\begin{aligned} \text{tr}(\mathbf{WD}) &= \text{tr}(\mathbf{XMX}'\mathbf{D}) = \sum_{i=1}^n \mathbf{e}_i' \mathbf{M} \mathbf{e}_i p_i = I_{\mathbf{g}} = \sum_{i=1}^n p_i \mathbf{e}_i' \mathbf{M} \mathbf{e}_i = \\ &= \text{tr}(\mathbf{DXMX}') = \text{tr}(\mathbf{DW}). \end{aligned}$$

■

Observația 1.2.3

1. Dacă $\mathbf{M} = \mathbf{I}_p$ inerția este egală cu suma dispersiilor de selecție a celor p variabile.
2. Dacă $\mathbf{M} = \mathbf{D}_{\frac{1}{s^2}}$ atunci $I_{\mathbf{g}} = \text{tr}\left(\mathbf{D}_{\frac{1}{s^2}} \mathbf{V}\right) = \text{tr}\left(\mathbf{D}_{\frac{1}{s}} \mathbf{V} \mathbf{D}_{\frac{1}{s}}\right) = \text{tr}(\mathbf{R}) = \sum_{j=1}^p \mathbf{r}_{jj} = \sum_{j=1}^p 1 = p$, așa cum rezultă din Lema 1.2.4. Inerția este, în acest caz, egală cu numărul variabilelor și nu depinde de valorile acestora.

1.2.1.2 SPAȚIUL VARIABILELOR

Fiecare variabilă $\mathbf{x}_j$ poate fi considerată ca un vector al unui spațiu vectorial $\mathcal{E} \subseteq \mathbb{R}^n$ numit *spațiul variabilelor*. Mulțimea celor p variabile formează un "nor de puncte-variabilă" în $\mathcal{E}$ (fig. 1.2.1.). Metrica utilizată în spațiul variabilelor este dată de $\mathbf{D}$, matricea diagonală a ponderilor indivizilor. Cu acestea se observă:

Lema 1.2.5

Dacă variabilele sunt centrate atunci:

- a) produsul scalar indus de metrica $\mathbf{D}$ este egal cu covarianța de selecție dintre cele două variabile necentrate;

- b) norma ("lungimea") unei variabile este egală cu abaterea standard de selecție a variabilei necentrate;
- c) unghiul dintre două variabile este egal cu coeficientul de corelație liniară de selecție al variabilelor necentrate.

Demonstrație. Într-adevăr:

1. $\langle \mathbf{y}_j, \mathbf{y}_k \rangle_{\mathbf{D}} = \mathbf{y}_j' \mathbf{D} \mathbf{y}_k = \sum_{i=1}^n p_i (x_{ij} - \bar{x}_j) (x_{ik} - \bar{x}_k) = \text{cov}(\mathbf{x}_j, \mathbf{x}_k).$
2. $\|\mathbf{y}_j\|_{\mathbf{D}}^2 = \langle \mathbf{y}_j, \mathbf{y}_j \rangle_{\mathbf{D}} = \mathbf{y}_j' \mathbf{D} \mathbf{y}_j = \sum_{i=1}^n p_i (x_{ij} - \bar{x}_j)^2 = s^2(\mathbf{x}_j).$
3. Fie θ_{jk} unghiul dintre variabilele $\mathbf{y}_j$ și $\mathbf{y}_k$. Atunci

$$\cos(\theta_{jk}) = \frac{\langle \mathbf{y}_j, \mathbf{y}_k \rangle_{\mathbf{D}}}{\|\mathbf{y}_j\|_{\mathbf{D}} \|\mathbf{y}_k\|_{\mathbf{D}}} = \frac{\text{cov}(\mathbf{x}_j, \mathbf{x}_k)}{s(\mathbf{x}_j) s(\mathbf{x}_k)} = \frac{v_{jk}}{s_j s_k} = \text{cor}(\mathbf{x}_j, \mathbf{x}_k).$$

■

Corolarul 1.2.3

- a) Mediile de selecție ale variabilelor $\{\mathbf{y}_j\}_{j=1}^p$ sunt nule, dispersiile de selecție sunt egale cu dispersiile de selecție ale variabilelor $\{\mathbf{x}_j\}_{j=1}^p$ și coeficienții de corelație de selecție sunt egali cu coeficienții de corelație de selecție ai variabilelor $\{\mathbf{x}_j\}_{j=1}^p$.
- b) Mediile de selecție ale variabilelor $\{\mathbf{z}_j\}_{j=1}^p$ sunt nule, dispersiile de selecție sunt unitare și coeficienții de corelație liniară de selecție sunt egali cu coeficienții de corelație liniară de selecție a variabilelor $\{\mathbf{x}_j\}_{j=1}^p$.

Din cele de mai sus rezultă:

Lema 1.2.6

$$d^2(\mathbf{z}_j, \mathbf{z}_k) = 2(1 - \mathbf{r}_{jk})$$

Demonstrație.

$$\begin{aligned} d^2(\mathbf{z}_j, \mathbf{z}_k) &= \langle \mathbf{z}_j - \mathbf{z}_k, \mathbf{z}_j - \mathbf{z}_k \rangle'_{\mathbf{D}} = \sum_{i=1}^n p_i (z_{ij} - z_{ik})^2 = \\ &= \sum_{i=1}^n p_i z_{ij}^2 + \sum_{i=1}^n p_i z_{ik}^2 - 2 \sum_{i=1}^n p_i z_{ij} z_{ik}. \end{aligned}$$

Conform corolarului de mai sus,

$$\sum_{i=1}^n p_i z_{ij}^2 = s^2(\mathbf{z}_j) = 1 = s^2(\mathbf{z}_k) = \sum_{i=1}^n p_i z_{ik}^2 \quad \text{și}$$

$$\sum_{i=1}^n p_i z_{ij} z_{ik} = \text{cor}(\mathbf{z}_j, \mathbf{z}_k) = r_{jk},$$

ceea ce implică relația din enunț. ■

Sistemul de proximități dintre două puncte-variabilă din $\mathcal{E}$, indus de relația din Lema 1.2.6, este familiar statisticianului:

- două variabile puternic corelate sunt foarte apropiate una de cealaltă (deoarece $r_{jk} \approx 1$ implică $d^2(\mathbf{z}_j, \mathbf{z}_k) \approx 0$) sau, din contră, foarte depărtate (deoarece $r_{jk} \approx -1$ implică $d^2(\mathbf{z}_j, \mathbf{z}_k) \approx 4$), după cum relația liniară care le leagă este directă sau inversă;
- două variabile necorelate, deci ortogonale, sunt la distanță medie (deoarece $r_{jk} \approx 0$ implică $d^2(\mathbf{z}_j, \mathbf{z}_k) \approx 2$).




FIG. 1.2.2. CORELAȚIILE ȘI DISTANȚELE ÎNTRE PUNCTELE-VARIABILĂ

Proximitatea între două puncte-variabile se interpretează, deci, în termeni de corelații




FIG. 1.2.3. SISTEMUL DE PROXIMITĂȚI ÎNTRE DOUĂ PUNCTE-VARIABILĂ

Din Corolarul 1.2.3 punctul a) rezultă că toate punctele-variabilă se află pe hipersfera de rază 1, centrată în originea axelor. Această hipersferă se numește *sfera de corelație*.

Planurile în care vor fi proiectate variabilele intersectează sfera după cercurile diametrice, de rază 1, numite *cercuri de corelație*, în interiorul cărora se află proiecțiile punctelor-variabilă.




FIG. 1.2.4. REPREZENTAREA SFEREI ȘI CERCULUI DE CORELAȚIE

Observația 1.2.4

Operația de centrare a tabelului $\mathbf{X}$ are în spațiile $\mathbb{R}^p$ și $\mathbb{R}^n$ interpretări geometrice diferite.

- În $\mathbb{R}^p$ această transformare echivalează cu o translație a originii axelor în centrul de greutate (punctul mediu) al norului.
- În $\mathbb{R}^n$ această transformare este o proiecție pe hiperplanul ce trece prin originea axelor și este ortogonal pe dreapta ce trece prin originea axelor și are ca parametri directori $\{p_i\}_{i=1}^n$. Matricea $\mathbf{P} = \mathbf{I}_n - \mathbf{1}_n \mathbf{1}_n' \mathbf{D}$ asociată acestei transformări este idempotentă ($\mathbf{P}^2 = \mathbf{P}$) și M-simetrică ($\mathbf{P}'\mathbf{M} = \mathbf{M}\mathbf{P}$), cu $\mathbf{M} = \mathbf{I}_n$. Ea este matricea proiecției M-ortogonale pe subspațiul generat de vectorii coloană liniari independenți ai matricii $\mathbf{Y}$. Coordonatele acestor vectori satisfac relația $\sum_i p_i y_{ij} = 0, (\forall) j = \overline{1, p}$, ce reprezintă ecuația unui hiperplan în $\mathbb{R}^n$ care trece prin originea axelor și are ca normală în punctul $\mathbf{0}_n$ dreapta de parametri directori $\{p_i\}_{i=1}^n$. Dacă $\mathbf{D} = \frac{1}{n} \mathbf{I}_n$ atunci hiperplanul este ortogonal pe prima bisectoare.

Definiția 1.2.6 (conform [14]) Se numește *studiu* un triplet $(\mathbf{Y}, \mathbf{M}, \mathbf{D})$ unde:

- $\mathbf{Y}$ este matricea centrată asociată tabelului de date indivizi-variabile;
- $\mathbf{M}$ este o metrică în spațiul vectorial al indivizilor, $\mathcal{F}$;
- $\mathbf{D}$ este metrica ponderilor în spațiul vectorial al variabilelor, $\mathcal{E}$.

Studiul este caracterizat de două „obiecte”:

- matricea $\mathbf{W} = \mathbf{Y}\mathbf{M}\mathbf{Y}'$ a produsului scalar între indivizi;
- matricea $\mathbf{V} = \mathbf{Y}'\mathbf{D}\mathbf{Y}$ de varianță-covarianță a variabilelor centrate.

1.2.2 Analiza generală. Descompunerea în valori singulare

S-a arătat mai sus cum liniile și coloanele unui tabel dreptunghiular permit definirea norilor de puncte.

Poziția punctelor în nor este dată de mulțimea distanțelor între toate punctele și determină *forma norului*.




FIG 1.2.5. NOR DE PUNCTE CE ILUSTREAZĂ O RELAȚIE LINIARĂ ÎNTRE VARIABLE




FIG. 1.2.6. NOR DE PUNCTE CE ILUSTREAZĂ O RELAȚIE NELINIARĂ ÎNTRE VARIABLE




FIG 1.2.7. NOR DE PUNCTE CE ILUSTREAZĂ ABSENȚA UNEI RELAȚII ÎNTRE VARIABLE

Forma norului este cea care caracterizează natura și intensitatea relațiilor între indivizi (liniile) și între variabile (coloanele) și relevă structurile de informații conținute în date.

De exemplu, un nor de puncte alungit uniform de-a lungul unei drepte (fig. 1.2.5.) traduce existența unei relații liniare dominante între puncte, în timp ce o formă parabolică (fig. 1.2.6.) ilustrează existența unei relații neliniare iar o formă sferică (fig 1.2.7.) indică, mai degrabă, absența unei relații.

O modalitate simplă de a reda vizual forma unui nor este aceea de a-l proiecta pe o dreaptă, sau mai bine pe un plan, minimizând deformările pe care această proiecție le implică; aceasta este esența analizei generale. În cele ce urmează se va prezenta detaliat programul enunțat.

Matricea $\mathbf{W} = \mathbf{YMY}'$ este o matrice simetrică, de dimensiune n , al cărui termen general $w_{ij} = \mathbf{e}_i' \mathbf{M} \mathbf{e}_j$ este un produs scalar între indivizii i și j . Indivizii aparțin unui spațiu vectorial euclidian $(\mathcal{F}, \mathbf{M})$ de dimensiune p , deoarece sunt p variabile.

Definiția 1.2.7 Se numește *image euclidiană a indivizilor* asociată produselor scalare w_{ij} , un nor compus din n puncte $A_1, \dots, A_n$ și dintr-un punct O din $\mathcal{F}$ astfel încât aceste puncte să reconstituie produsele scalare w_{ij} , adică $\langle OA_i, OA_j \rangle = w_{ij}$, $(\forall) i, j = \overline{1, n}$, unde produsul scalar $\langle \circ, \circ \rangle$ este definit de metrica euclidiană $\mathbf{I}_p$.

Matricea $\mathbf{V} = \mathbf{Y}' \mathbf{D} \mathbf{Y}$ este o matrice simetrică, de dimensiune p , al cărui termen general $v_{ij} = \mathbf{y}_i' \mathbf{D} \mathbf{y}_j$ este un produs scalar între variabilele i și j . Variabilele aparțin unui spațiu vectorial euclidian $(\mathcal{E}, \mathbf{D})$ de dimensiune n (deoarece sunt n indivizi).

Definiția 1.2.8 Se numește *image euclidiană a variabilelor* asociată produselor scalare v_{ij} , un nor compus din p puncte $B_1, \dots, B_p$ și dintr-un punct O din $\mathcal{E}$ astfel încât aceste puncte să reconstituie produsele scalare v_{ij} , adică $\langle OB_i, OB_j \rangle = v_{ij}$, $(\forall) i, j = \overline{1, p}$, unde produsul scalar $\langle \circ, \circ \rangle$ este definit de metrica euclidiană $\mathbf{I}_n$.

Dacă dimensiunea spațiului vectorial în care se lucrează este egală cu 3 atunci imaginea euclidiană a unui nor de puncte poate fi vizualizată. Dacă dimensiunea spațiului este strict superioară lui 3 atunci acest lucru devine imposibil. În acest caz trebuie căutată o imagine euclidiană aproximativă. Să notăm că există o infinitate de imagini euclidiene ale aceluiași nor de puncte. Două imagini euclidiene sunt *echivalente* dacă ele reconstituie aceleași produse scalare.

1.2.1.3 ANALIZA NORULUI DE PUNCTE-INDIVID

Să ne plasăm, mai întâi, în spațiul $\mathcal{F} \subset \mathbb{R}^p$ al indivizilor, în care tabelul $\mathbf{Y}$ poate fi reprezentat ca un nor de n puncte-individ centrate în punctul mediu al norului și ale căror p coordonate reprezintă liniile lui $\mathbf{Y}$. Principiul metodei ACP constă în reprezentarea aproximativă a norului de puncte-individ într-un subspațiu de dimensiune mult mai mică (de regulă egală cu 2). Se pleacă, deci, de la o imagine euclidiană dintr-un spațiu afin de dimensiune p și se ajunge la o imagine euclidiană într-un spațiu afin de dimensiune $q \ll p^3$.

Demersul de mai sus se realizează prin proiecția punctelor-individ pe un subspațiu $\mathcal{F}_q$ de dimensiune q , obținut astfel încât media pătratelor distanțelor între proiecții să fie maximă sau, ținând cont de **Lema 1.2.3.**, inerția norului proiectat pe $\mathcal{F}_q$ să fie maximă sau, în fine, deformarea distanțelor prin proiecție să fie minimă.

Cu notațiile de mai sus, problema ce trebuie rezolvată se formulează astfel:

$$”Să se găsească $\mathcal{H} \equiv \mathcal{F}_q$ astfel încât $\max \sum_{i=1}^n d^2(\mathbf{y}_i, \mathbf{0})$ ”⁴$$

Soluția problemei este dată de următoarea teoremă:

Teorema 1.2.1 *Subspațiul de dimensiune q pe care se proiectează optim, în sensul celor mai mici pătrate, cele n puncte din $\mathbb{R}^p$ este generat de primii q vectori proprii ai matricii $\mathbf{A} = \mathbf{VM} \in \mathcal{M}_{p,p}(\mathbb{R})$ corespunzătorilor valorilor proprii $\lambda_1 > \lambda_2 > \dots > \lambda_q$, unde $\mathbf{V}$ este matricea de varianță-covarianță asociată tabelului $\mathbf{X}$ și $\mathbf{M}$ este metrica spațiului indivizilor.*

Demonstrație. Să notăm cu $\{P_1, \dots, P_n\}$ proiecțiile pe $\mathcal{H}$ ale punctelor $\{A_1, \dots, A_n\}$ și să observăm că:

$$\overline{OA_i}^2 = \overline{OP_i}^2 + \overline{A_iP_i}^2, \quad i = \overline{1, n},$$

conform teoremei lui Pitagora, sau

$$\sum_{i=1}^n \overline{A_iP_i}^2 = \sum_{i=1}^n \overline{OA_i}^2 - \sum_{i=1}^n \overline{OP_i}^2, \quad i = \overline{1, n}, \quad (1)$$

Cum $\overline{OA_i}^2$ sunt fixe pentru $i = \overline{1, n}$, deoarece norul de puncte-individ este dat, a minimiza deformările produse prin proiecții este echivalent cu a minimiza

³Dacă $\text{rg}(\mathbf{Y}) = q$ atunci problema aproximării este practic rezolvată. Într-adevăr, este suficient să găsim o bază a subspațiului vectorial de dimensiune q din $\mathbb{R}^p$ ce conține norul de puncte-individ și să calculăm coordonatele punctelor în noua bază. Vom putea astfel reconstitui cei np coeficienți ai tabelului $\mathbf{Y}$ pornind de la cei $qp + np = (n+p)q$ coeficienți definiți mai sus.

⁴Dacă se lucrează pe tabelul $\mathbf{X}$ atunci problema se formulează astfel: Să se găsească $H \equiv \mathcal{F}_q$ astfel încât $\max_{(H)} \sum_{i=1}^n d^2(\mathbf{e}_i, \mathbf{g})$

suma ponderată a pătratelor distanțelor de la punctele $\{A_1, \dots, A_n\}$ la subspațiul $\mathcal{H}$, adică a afla $\min \sum_{i=1}^n p_i \overline{A_i P_i}^2$ sau, conform relației (1), $\max \sum_{i=1}^n p_i \overline{O P_i}^2$.

Fie $\mathbf{a}$ un vector $\mathbf{M}$ -normat din $\mathbb{R}^p$, adică $\mathbf{a}'\mathbf{M}\mathbf{a} = 1$. Coordonata proiecției P_i a punctului A_i pe dreapta $\Delta_{\mathbf{a}}$ având ca suport pe $\mathbf{a}$ este $OP_i = \mathbf{y}'_i \mathbf{M}\mathbf{a}$. Coordonatele tuturor punctelor P_i pe $\Delta_{\mathbf{a}}$ sunt $\mathbf{Y}\mathbf{M}\mathbf{a}$, de unde rezultă că:

$$\sum_{i=1}^n p_i \overline{O P_i}^2 = \mathbf{a}' \mathbf{M} \mathbf{Y}' \mathbf{D} \mathbf{Y} \mathbf{M} \mathbf{a} = \mathbf{a}' \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{a} = \mathbf{a}' \mathbf{M} \mathbf{A} \mathbf{a}.$$

Așadar, dacă $\mathcal{H} = \Delta_{\mathbf{a}}$, atunci găsirea lui $\mathcal{H}$ s-a redus la următoarea problemă de programare pătratică cu restricții liniare:

$$\begin{cases} \max_{(\mathbf{a})} \{\mathbf{a}' \mathbf{M} \mathbf{A} \mathbf{a}\} \\ \mathbf{a}' \mathbf{M} \mathbf{a} = 1 \end{cases}.$$

Pentru a rezolva problema de mai sus se utilizează metoda multiplicatorilor lui Lagrange (vezi paragraful 1.1.7). Fie, deci, lagrangeanul $\mathcal{L} = \mathbf{a}' \mathbf{M} \mathbf{A} \mathbf{a} - \lambda (\mathbf{a}' \mathbf{M} \mathbf{a} - 1)$, cu λ multiplicator Lagrange. Rezultă

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}} = 2\mathbf{M}\mathbf{A}\mathbf{a} - 2\lambda \mathbf{M}\mathbf{a} \text{ deoarece } \mathbf{M}\mathbf{A} \text{ este o matrice simetrică.}$$

Dar

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}} = 0 \Rightarrow \mathbf{M}\mathbf{A}\mathbf{a} = \lambda \mathbf{M}\mathbf{a} \quad (2)$$

Înmulțind la stânga relația (2) cu $\mathbf{a}'$ și ținând cont că $\mathbf{a}$ este $\mathbf{M}$ -normat rezultă

$$\lambda = \mathbf{a}' \mathbf{M} \mathbf{A} \mathbf{a}.$$

Valoarea parametrului λ este, deci, maximul căutat. Cum matricea $\mathbf{M}$ este pozitiv definită rezultă că ea este inversabilă și înmulțind relația (2) la stânga cu $\mathbf{M}^{-1}$ se obține

$$\mathbf{A}\mathbf{a} = \lambda \mathbf{a},$$

adică $\mathbf{a}$ este vector propriu al matricii $\mathbf{A}$, corespunzând celei mai mari valori proprii λ , dacă aceasta este unică; să le notăm cu $\mathbf{a}_1$ respectiv λ_1 .

Să căutăm vectorul $\mathbf{a}_2$ din $\mathbb{R}^p$, $\mathbf{M}$ -normat și $\mathbf{M}$ -ortogonal pe $\mathbf{a}_1$ (adică $\mathbf{a}'_2 \mathbf{M} \mathbf{a}_2 = 1$ și $\mathbf{a}'_1 \mathbf{M} \mathbf{a}_2 = 0$) care maximizează forma pătratică $\mathbf{a}'_2 \mathbf{M} \mathbf{A} \mathbf{a}_2$. Analog cu demersul de mai sus, se anulează derivatele lagrangeanului

$$\begin{aligned} \mathcal{L} &= \mathbf{a}'_2 \mathbf{M} \mathbf{A} \mathbf{a}_2 - \lambda_2 (\mathbf{a}'_2 \mathbf{M} \mathbf{a}_2 - 1) - \mu_2 \mathbf{a}'_1 \mathbf{M} \mathbf{a}_2. \\ \frac{\partial \mathcal{L}}{\partial \mathbf{a}_2} &= 0 \Rightarrow 2\mathbf{M}\mathbf{A}\mathbf{a}_2 - 2\lambda_2 \mathbf{M}\mathbf{a}_2 - \mu_2 \mathbf{M}\mathbf{a}_1 = 0. \end{aligned}$$

Înmulțind relația de mai sus cu $\mathbf{a}'_1$ la stânga, se obține

$$\begin{aligned} \mathbf{a}'_1 \mathbf{M} \mathbf{A} \mathbf{a}_2 - \lambda_2 \mathbf{a}'_1 \mathbf{M} \mathbf{a}_2 - \mu_2 \mathbf{a}'_1 \mathbf{M} \mathbf{a}_1 &= 0, \text{ sau} \\ \lambda_2 \mathbf{a}'_1 \mathbf{M} \mathbf{a}_2 - \mu_2 &= 0 \Rightarrow \mu_2 = 0. \end{aligned}$$

Rămâne, ca în cazul precedent

$$\mathbf{MAa}_2 = \lambda_2 \mathbf{Ma}_2$$

ceea ce implică faptul că $\mathbf{a}_2$ este al doilea vector al matricii $\mathbf{A}$ relativ la a doua valoare proprie λ_2 , dacă aceasta este unică.

Demonstrația se repetă analog pentru ceilalți vectori $\mathbf{M}$ -normați, $\mathbf{a}_k \in \mathbb{R}^p$, $k \leq q$, $\mathbf{M}$ -ortogonali cu vectorii $\mathbf{a}_j$ găsiți înainte (pentru $\mathbf{a}'_k \mathbf{Ma}_j = 0$, $j < k$) și care maximizează forma pătratică $\mathbf{a}'_k \mathbf{MAa}_k$. Se obține $\mathbf{MAa}_k = \lambda_k \mathbf{Ma}_k$ și cum $\mathbf{M}$ este inversabilă, $\mathbf{Aa}_k = \lambda_k \mathbf{a}_k$. ■

Observația 1.2.5

1. Teorema 1.2.1 poate fi demonstrată folosind formula proiectorului $\mathbf{M}$ -ortogonal pe $\mathcal{H}$ (conform [53]) sau bazându-se pe descompunerea $\mathbf{M} = \mathbf{T}'\mathbf{T}$ (conform [41]).
2. Cum $\mathbf{A}$ este o matrice $\mathbf{M}$ -simetrică, pozitiv definită, cu coeficienți reali, valorile sale proprii sunt reale și pozitive (conform [15]). Vectorii proprii ai matricii $\mathbf{A}$ sunt $\mathbf{M}$ -ortonormați.

Definiția 1.2.9 Matricea $\mathbf{A}$ se numește *matricea inerției*.

Definiția 1.2.10 Imaginea euclidiană a norului de puncte-individ obținută prin proiecția pe subspațiul $\mathcal{H}$ dat de Teorema 1.2.1 se numește *imaginea euclidiană a punctelor-individ asociate* aproximației de ordinul q a produselor scalare.

Lema 1.2.7

$$I_{\mathbf{g}} = \text{tr}(\mathbf{A}) = \sum_{j=1}^p \lambda_j$$

Demonstrație. Matricea inerției, $\mathbf{A} = \mathbf{VM}$, este reală și $\mathbf{M}$ -simetrică. Atunci, conform [15]

$$\mathbf{A} = \mathbf{L}\mathbf{\Lambda}\mathbf{L}^{-1}$$

cu $\mathbf{L}$ matricea vectorilor proprii corespunzători valorilor proprii $\lambda_1, \lambda_2, \dots, \lambda_p$ ai matricii $\mathbf{A}$ și $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$. Cu acestea

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{L}\mathbf{\Lambda}\mathbf{L}^{-1}) = \text{tr}(\mathbf{L}\mathbf{L}^{-1}\mathbf{\Lambda}),$$

deoarece $\text{tr}(\mathbf{BC}) = \text{tr}(\mathbf{CB})$ dacă produsele $\mathbf{BC}$ și $\mathbf{CB}$ au sens. Rezultă

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{\Lambda}) = \text{tr}(\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)) = \sum_{j=1}^p \lambda_j$$

și din Lema 1.2.4 rezultă

$$I_{\mathbf{g}} = \text{tr}(\mathbf{VM}) = \text{tr}(\mathbf{A}).$$

■

Definiția 1.2.11 Se numesc *axe principale de inerție* vectorii proprii, $\mathbf{M}$ -normați, $\mathbf{a}_j$, ai matricii de inerție $\mathbf{A}$.

Definiția 1.2.12 Se numește *factor principal* asociat axei principale $\mathbf{a}_j$ și se notează cu $\mathbf{u}_j$ forma liniară din $\mathbb{R}^p$ definită de relația $\mathbf{u}_j = \mathbf{M}\mathbf{a}_j$.

Lema 1.2.8

Factorii principali $\{\mathbf{u}_j\}_{j=1}^p$ sunt vectorii proprii ai matricii $\mathbf{M}\mathbf{V}$ asociați valorilor proprii $\{\lambda_j\}_{j=1}^p$ ale matricii $\mathbf{A} = \mathbf{V}\mathbf{M}$.

Demonstrație. Într-adevăr

$$\begin{aligned}\mathbf{M}\mathbf{V}\mathbf{u}_j &= \mathbf{M}\mathbf{V}\mathbf{M}\mathbf{a}_j = \mathbf{M}\mathbf{A}\mathbf{a}_j = \lambda_j\mathbf{M}\mathbf{a}_j = \lambda_j\mathbf{u}_j \\ \text{și } \mathbf{u}_j'\mathbf{M}^{-1}\mathbf{u}_j &= \mathbf{a}_j'\mathbf{M}\mathbf{M}^{-1}\mathbf{M}\mathbf{a}_j = \mathbf{a}_j'\mathbf{M}\mathbf{a}_j = \delta_{jk}.\end{aligned}$$

■

Definiția 1.2.13 Se numește *plan factorial principal* subsațiul $\mathcal{F}_2$, generat de vectorii $\{\mathbf{u}_1, \mathbf{u}_2\}$.

Definiția 1.2.14 Se numește *componentă principală* asociată factorului principal $\mathbf{u}_j$ și se notează cu $\mathbf{c}_j$ forma liniară din $\mathbb{R}^n$ definită de relația $\mathbf{c}_j = \mathbf{Y}\mathbf{u}_j$.

Observația 1.2.6

Din definiție, $\mathbf{c}_j$ este proiecția $\mathbf{M}$ -ortogonală a indivizilor pe axa principală $\mathbf{a}_j$. Într-adevăr,

Lema 1.2.9

Componentele principale $\{\mathbf{c}_j\}_{j=1}^p$ sunt vectorii proprii ai matricii $\mathbf{W}\mathbf{D}$, asociați valorilor proprii $\{\lambda_j\}_{j=1}^p$ ale matricii $\mathbf{A}$. Componentele principale sunt $\mathbf{D}$ -ortogonale, deci necorelate.

Demonstrație.

$$\begin{aligned}\mathbf{W}\mathbf{D}\mathbf{c}_j &= \mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{D}\mathbf{Y}\mathbf{M}\mathbf{a}_j = \mathbf{Y}\mathbf{M}\mathbf{V}\mathbf{M}\mathbf{a}_j = \mathbf{Y}\mathbf{M}\mathbf{A}\mathbf{a}_j = \\ &= \lambda_j\mathbf{Y}\mathbf{M}\mathbf{a}_j = \lambda_j\mathbf{Y}\mathbf{u}_j = \lambda_j\mathbf{c}_j. \\ \mathbf{c}_j'\mathbf{D}\mathbf{c}_k &= \mathbf{u}_j'\mathbf{Y}'\mathbf{D}\mathbf{Y}\mathbf{u}_k = \mathbf{u}_j'\mathbf{V}\mathbf{u}_k = \mathbf{a}_j'\mathbf{M}\mathbf{V}\mathbf{M}\mathbf{a}_k = \\ &= \mathbf{a}_j'\mathbf{M}\mathbf{A}\mathbf{a}_k = \mathbf{a}_j'\mathbf{M}(\lambda_k\mathbf{a}_k) = \lambda_k\mathbf{a}_j'\mathbf{M}\mathbf{a}_k = \lambda_k\delta_{jk}.\end{aligned}$$

■

Lema 1.2.10

- Mediile de selecție ale componentelor principale sunt nule (pe datele centrate și centrat-reduce).
- Dispersia de selecție a componentei principale $\mathbf{c}_j$ este λ_j - valoarea proprie a matricii inerției, $\mathbf{A}$, pentru $(\forall) j = \overline{1, p}$.

Demonstrație.

1. Într-adevăr, cum $\mathbf{c}_j = \mathbf{Y}\mathbf{u}_j$, atunci

$$\begin{aligned} m(\mathbf{c}_j) &= \sum_{i=1}^n p_i c_{ij} = \sum_{i=1}^n p_i \sum_{k=1}^p y_{ik} u_{kj} = \sum_{k=1}^p \left(\sum_{i=1}^n p_i y_{ik} \right) u_{kj} = \\ &= \sum_{k=1}^p m(\mathbf{y}_k) u_{kj} = 0, \end{aligned}$$

conform Corolarului 1.2.3. Analog pentru $\mathbf{c}_j = \mathbf{Z}\mathbf{u}_j$.

- 2.

$$\begin{aligned} s^2(\mathbf{c}_j) &= \mathbf{c}_j' \mathbf{D} \mathbf{c}_j = \mathbf{u}_j' \mathbf{Y}' \mathbf{D} \mathbf{Y} \mathbf{u}_j = \mathbf{u}_j' \mathbf{V} \mathbf{u}_j = \mathbf{a}_j' \mathbf{M} \mathbf{V} \mathbf{M} \mathbf{a}_j = \\ &= \mathbf{a}_j' \mathbf{M} \mathbf{A} \mathbf{a}_j = \mathbf{a}_j' \mathbf{M} (\lambda_j \mathbf{a}_j) = \lambda_j \mathbf{a}_j' \mathbf{M} \mathbf{a}_j = \lambda_j. \end{aligned}$$

■

Propoziția 1.2.2

1. Componentele principale sunt combinații liniare de variabilele inițiale, de dispersie maximă și care satisfac restricțiile $\mathbf{u}_j' \mathbf{M}^{-1} \mathbf{u}_j = 1$.
2. În cazul unei ACP normate, componentele principale $\{\mathbf{c}_j\}_{j=1}^p$ asociate valorilor proprii $\{\lambda_j\}_{j=1}^p$ ale matricii $\mathbf{A}$ sunt variabilele cele mai "legate" de variabilele inițiale, $\mathbf{z}_1, \dots, \mathbf{z}_p$, în sensul că suma pătratelor coeficienților de corelație $\{\text{cor}(\mathbf{c}_j, \mathbf{z}_k)\}_{k=1}^p$ este maximă, pentru oricare $j = \overline{1, p}$.

Demonstrație.

- a) Să considerăm o combinație liniară de variabilele inițiale $\mathbf{x}_1, \dots, \mathbf{x}_p$; fie aceasta $\mathbf{c} = \sum_{j=1}^p u_j \mathbf{x}_j$ sau vectorul $\mathbf{c} = \mathbf{X}\mathbf{u}$. Ne propunem să găsim pe $\mathbf{u}' = (u_1, \dots, u_p)$ astfel încât

$$\left\{ \begin{array}{l} \max_{(u)} s^2(\mathbf{c}_j) \\ \mathbf{u}' \mathbf{M}^{-1} \mathbf{u} = 1 \end{array} \right\} \Leftrightarrow \left\{ \begin{array}{l} \max_{(u)} \mathbf{c}' \mathbf{D} \mathbf{c} \\ \mathbf{u}' \mathbf{M}^{-1} \mathbf{u} = 1 \end{array} \right\} \Leftrightarrow \left\{ \begin{array}{l} \max_{(u)} \mathbf{u}' \mathbf{X}' \mathbf{D} \mathbf{X} \mathbf{u} \\ \mathbf{u}' \mathbf{M}^{-1} \mathbf{u} = 1 \end{array} \right\}$$

Soluția problemei de programare pătratică cu restricții liniare de mai sus este, conform unui raționament analog cu cel din Teorema 1.2.1, vectorul propriu $\mathbf{u}_1$ al matricii $\mathbf{M}\mathbf{V}$ asociat celei mai mari valori proprii λ_1 (cum $\mathbf{M}\mathbf{V}$ este simetrică și pozitiv definită, λ_1 există, este real și strict pozitiv). Dar $\mathbf{u}_1$ este, conform definiției, chiar factorul principal rezultat dintr-o ACP pe tabelul $\mathbf{X}$ iar valoarea maximă a funcției este λ_1 .

b) Să reamintim mai întâi că, în cazul unei ACP normate, $\mathbf{X} \rightarrow \mathbf{Z}$ și $\mathbf{M} = \mathbf{I}_p$. Cu acestea:

$$\begin{aligned} \text{cor}^2(\mathbf{c}, \mathbf{z}_j) &= \frac{\text{cov}^2(\mathbf{c}, \mathbf{z}_j)}{s^2(\mathbf{c}) s^2(\mathbf{z}_j)} = \frac{(\mathbf{c}' \mathbf{D} \mathbf{z}_j)^2}{s^2(\mathbf{c})} \\ \sum_{j=1}^p \text{cor}^2(\mathbf{c}, \mathbf{z}_j) &= \frac{1}{s^2(\mathbf{c})} \sum_{j=1}^p (\mathbf{c}' \mathbf{D} \mathbf{z}_j) (\mathbf{c}' \mathbf{D} \mathbf{z}_j)' = \\ &= \frac{1}{s^2(\mathbf{c})} \mathbf{c}' \mathbf{D} \left(\sum_{j=1}^p \mathbf{z}_j \mathbf{z}_j' \right) \mathbf{D} \mathbf{c}, \end{aligned}$$

și cum $\sum_{j=1}^p \mathbf{z}_j \mathbf{z}_j' = \mathbf{Z} \mathbf{Z}'$ rezultă $\sum_{j=1}^p \text{cor}^2(\mathbf{c}, \mathbf{z}_j) = \frac{\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}}{\mathbf{c}' \mathbf{D} \mathbf{c}}$. Problema s-a redus la a găsi $\max_{(\mathbf{c})} \frac{\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}}{\mathbf{c}' \mathbf{D} \mathbf{c}}$.

Să remarcăm că $\mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D}$ și $\mathbf{D}$ sunt matrici reale, simetrice și de ordin n . Un punct de extrem al câtului de mai sus se obține anulând derivata sa, ceea ce implică

$$\frac{(\mathbf{c}' \mathbf{D} \mathbf{c}) (2 \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}) - (\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}) (2 \mathbf{D} \mathbf{c})}{(\mathbf{c}' \mathbf{D} \mathbf{c})^2} = 0.$$

Din $(\mathbf{c}' \mathbf{D} \mathbf{c}) \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c} = (\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}) \mathbf{D} \mathbf{c}$ rezultă

$$\mathbf{D}^{-1} (\mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D}) \mathbf{c} = \left(\frac{\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}}{\mathbf{c}' \mathbf{D} \mathbf{c}} \right) \mathbf{c}.$$

Prin urmare, $\mathbf{c}$ este vectorul propriu al matricii $\mathbf{Z} \mathbf{Z}' \mathbf{D}$, asociat valorii proprii $\lambda = \left(\frac{\mathbf{c}' \mathbf{D} \mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{c}}{\mathbf{c}' \mathbf{D} \mathbf{c}} \right)$. Maximul este, deci, atins dacă această valoare proprie este cea mai mare.

Din ipoteză, $\mathbf{c}$ este o combinație liniară de variabile inițiale, adică $\mathbf{c} = \mathbf{Z} \mathbf{u}$. Înlocuind în relația de mai sus se obține

$$\mathbf{Z} \mathbf{Z}' \mathbf{D} \mathbf{Z} \mathbf{u} = \lambda \mathbf{Z} \mathbf{u}$$

și cum $\mathbf{Z}' \mathbf{D} \mathbf{Z} = \mathbf{R} \Rightarrow \mathbf{Z} \mathbf{R} \mathbf{u} = \lambda \mathbf{Z} \mathbf{u}$ iar $\mathbf{Z}$ este de rang p , rezultă $\mathbf{R} \mathbf{u} = \lambda \mathbf{u}$, adică $\mathbf{u}$ este vectorul propriu al matricii $\mathbf{R}$, asociat valorii proprii maxime. În ACP normat $\mathbf{A} = \mathbf{R}$ și axele principale coincid cu factorii principali, deci $\mathbf{c} = \mathbf{Z} \mathbf{u}$ este chiar componenta principală obținută prin proiecția indivizilor pe axa principală $\mathbf{a} \equiv \mathbf{u}$. ■

Un rezumat al elementelor principale ce intervin într-o ACP pe norul de puncte-indivd se găsește în tabelul de mai jos:

TABELUL 1.2.4. PROPRIETĂȚILE ELEMENTELOR PRINCIPALE DINTR-O ACP PE NORUL DE PUNCTE-INDIVID

Elemente principale	Definiție	Proprietăți	Relații
Axe principale: $\mathbf{a} \in \mathbb{R}^p$	$\mathbf{V}\mathbf{M}\mathbf{a} = \lambda\mathbf{a}$	$\mathbf{M}$ -ortonormate	
Factori principali: $\mathbf{u} \in (\mathbb{R}^p)^*$	$\mathbf{u} = \mathbf{M}\mathbf{a}$	$\mathbf{M}^{-1}$ -ortonormați	$\mathbf{M}\mathbf{V}\mathbf{u} = \lambda\mathbf{u}$
Componente principale: $\mathbf{c} \in \mathbb{R}^n$	$\mathbf{c} = \mathbf{Y}\mathbf{u}$ sau $\mathbf{c} = \mathbf{Z}\mathbf{u}$	$\mathbf{D}$ -ortogonale $s^2(\mathbf{c}) = \lambda$	$\mathbf{W}\mathbf{D}\mathbf{c} = \lambda\mathbf{c}$ și analoga

1.2.2.1 ANALIZA NORULUI DE PUNCTE-VARIABILĂ

Să considerăm acum spațiul $\mathcal{E} \subset \mathbb{R}^n$, al variabilelor, în care tabelul $\mathbf{Y}$ poate fi reprezentat ca un nor de p puncte-variabilă ale căror n coordonate reprezintă coloanele lui $\mathbf{Y}$.

Principiul metodei ACP în acest caz este identic cu cel utilizat pentru reprezentarea norului de puncte-individ și constă în găsirea axelor principale și a subspațiului afin q dimensional, $\mathcal{E}_q \subset \mathbb{R}^n$, generat de aceste axe și care aproximează optim norul de puncte-variabilă. Aceasta înseamnă să fie maximizată media pătratelor distanțelor dintre cele p proiecții pe $\mathcal{E}_q$, adică de rezolvat problema de programare pătratică cu restricții liniare

$$\begin{cases} \max_{(\mathbf{b})} \mathbf{b}'\mathbf{D}\mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{D}\mathbf{b} \\ \mathbf{b}'\mathbf{D}\mathbf{b} = 1 \end{cases}.$$

Teorema 1.2.1 arată că $\mathbf{b}$ este vectorul propriu al matricii $\mathbf{B} = \mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{D}$ ($\mathbf{D}$ -simetrică, reală), corespunzând celei mai mari valori proprii μ . Ecuația axei factoriale $\mathbf{b}$ din $\mathbb{R}^n$ este:

$$\begin{cases} \mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{D}\mathbf{b} = \mu\mathbf{b} \\ \mathbf{b}'\mathbf{D}\mathbf{b} = 1 \end{cases}.$$

ecuația factorului principal $\mathbf{v}$ din $(\mathbb{R}^n)^*$ este $\mathbf{v} = \mathbf{D}\mathbf{b}$ și ecuația componente principale $\mathbf{d}$ din $\mathbb{R}^p$ este $\mathbf{d} = \mathbf{Y}'\mathbf{v}$ sau $\mathbf{d} = \mathbf{Z}'\mathbf{v}$. Analog ca în cazul norului de puncte-individ se poate enunța

Lema 1.2.11

- a) Factorii principali $\mathbf{v}_i \in (\mathbb{R}^n)^*$, $i = \overline{1, n}$ sunt $\mathbf{D}^{-1}$ -ortonormați și satisfac relațiile $\mathbf{D}\mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{v}_i = \mu_i\mathbf{v}_i$.

b) Componentele principale $\mathbf{d}_i \in \mathbb{R}^p, i = \overline{1, n}$ sunt $\mathbf{M}$ -ortogonale, au dispersia de selecție egală cu μ și satisfac relațiile $\mathbf{X}'\mathbf{D}\mathbf{X}\mathbf{M}\mathbf{d}_i = \mu_i \mathbf{d}_i$.

Demonstrație.

a) Într-adevăr

$$\begin{aligned}\mathbf{v}_i' \mathbf{D}^{-1} \mathbf{v}_j &= \mathbf{b}_i' \mathbf{D} \mathbf{D}^{-1} \mathbf{D} \mathbf{b}_j = \mathbf{b}_i' \mathbf{D} \mathbf{b}_j = \delta_{ij} \text{ și} \\ \mathbf{D} \mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{v} &= \mathbf{D} \mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{D} \mathbf{b} = \mu \mathbf{D} \mathbf{b} = \mu \mathbf{v}.\end{aligned}$$

b) Într-adevăr

$$\begin{aligned}\mathbf{d}_i' \mathbf{M} \mathbf{d}_j &= \mathbf{v}_i' \mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{v}_j = \mathbf{b}_i' \mathbf{D} (\mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{D} \mathbf{b}_j) = \\ &= \mathbf{b}_i' \mathbf{D} (\mu_j \mathbf{b}_j) = \mu_j (\mathbf{b}_i' \mathbf{D} \mathbf{b}_j) = \mu_j \delta_{ij}, \\ \mathbf{X}' \mathbf{D} \mathbf{X} \mathbf{M} \mathbf{d} &= \mathbf{X}' \mathbf{D} \mathbf{X} \mathbf{M} \mathbf{X}' \mathbf{v} = \mathbf{X}' \mathbf{D} (\mathbf{X} \mathbf{M} \mathbf{X}' \mathbf{D} \mathbf{b}) = \mathbf{X}' \mathbf{D} (\mu \mathbf{b}) = \mu \mathbf{d}, \\ s^2(\mathbf{d}) &= \mathbf{d}' \mathbf{M} \mathbf{d} = \mathbf{v}' \mathbf{X} \mathbf{M} \mathbf{X}' \mathbf{v} = \mathbf{b}' \mathbf{D} \mathbf{X} \mathbf{M} \mathbf{X}' \mathbf{D} \mathbf{b} = \\ &= \mathbf{b}' \mathbf{D} (\mu \mathbf{b}) = \mu \mathbf{b}' \mathbf{D} \mathbf{b} = \mu.\end{aligned}$$

■

Definiția 1.2.15 Se numește *cerc de corelație principal* subspațiul $\mathcal{E}_2$ generat de vectorii $\{\mathbf{v}_1, \mathbf{v}_2\}$.

În cazul ACP normat norul de puncte-variabilă se află pe hipersfera de corelație deci planul factorial va intersecta această hipersferă după un cerc diametral (vezi Corolarul 1.2.3 și Observația 1.2.4).

Un rezumat al elementelor principale ce intervin într-o ACP pe norul de puncte-variabilă se găsește în tabelul de mai jos:

TABELUL 1.2.5. PROPRIETĂȚILE ELEMENTELOR PRINCIPALE DINTR-O ACP PE NORUL DE PUNCTE-VARIABILĂ

Elemente principale	Definiție	Proprietăți	Relații
Axe principale: $\mathbf{b} \in \mathbb{R}^n$	$\mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{D} \mathbf{b} = \mu \mathbf{b}$	$\mathbf{D}$ -ortonormale	
Factori principali: $\mathbf{v} \in (\mathbb{R}^n)^*$	$\mathbf{v} = \mathbf{D} \mathbf{b}$	$\mathbf{D}^{-1}$ -ortonormați	$\mathbf{D} \mathbf{Y} \mathbf{M} \mathbf{Y}' \mathbf{v} = \mu \mathbf{v}$
Componente principale: $\mathbf{d} \in \mathbb{R}^p$	$\mathbf{d} = \mathbf{Y}' \mathbf{v}$ sau $\mathbf{d} = \mathbf{Z}' \mathbf{v}$	$\mathbf{M}$ -ortogonale $s^2(\mathbf{d}) = \mu$	$\mathbf{X}' \mathbf{D} \mathbf{X} \mathbf{M} \mathbf{d} = \mu \mathbf{d}$ și analoaga

1.2.2.2 RELAȚII DE TRANZIȚIE ÎNTRE CELE DOUĂ SPAȚII

Se observă că, din punct de vedere numeric, o analiză în componente principale a unui studiu se reduce la calculul primelor q valori și vectori proprii asociați ai matricilor $\mathbf{VM} = \mathbf{Y}'\mathbf{DYM} \in \mathcal{M}_{p,p}(\mathbb{R})$ și $\mathbf{WD} = \mathbf{YMY}'\mathbf{D} \in \mathcal{M}_{n,n}(\mathbb{R})$. O întrebare naturală este următoarea: există o relație între elementele principale dintr-o ACP pe spațiul $(\mathcal{F}, \mathbf{M})$ și elementele principale dintr-o ACP pe spațiul $(\mathcal{E}, \mathbf{D})$? Răspunsul la această întrebare este oferit de următoarea propoziție:

Propoziția 1.2.3

(relația de tranziție între spațiul indivizilor și spațiul variabilelor)
Toate valorile proprii nenule ale matricilor $\mathbf{Y}'\mathbf{DYM}$ și $\mathbf{YMY}'\mathbf{D}$ sunt egale având, eventual, același ordin de multiplicitate și, pentru $\lambda_j \neq 0$, sunt adevărate următoarele relații de tranziție între cele două spații, $\mathcal{F} \subset \mathbb{R}^p$ și $\mathcal{E} \subset \mathbb{R}^n$:

$$\begin{cases} \mathbf{b}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{YMa}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{Y}\mathbf{u}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{c}_j \\ \mathbf{a}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{Y}'\mathbf{Db}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{Y}'\mathbf{v}_j = \frac{1}{\sqrt{\lambda_j}} \mathbf{d}_j \end{cases}, j = \overline{1, \text{rg}(\mathbf{Y}'\mathbf{Y})}.$$

Demonstrație. În $\mathbb{R}^p$ există relația

$$\mathbf{Y}'\mathbf{DYM}\mathbf{a}_j = \lambda_j \mathbf{a}_j \quad (1)$$

iar în $\mathbb{R}^n$ relația

$$\mathbf{YMY}'\mathbf{D}\mathbf{b}_j = \mu_j \mathbf{b}_j \quad (2)$$

Înmulțind la stânga egalitatea (1) cu $\mathbf{YM}$ se obține

$$(\mathbf{YMY}'\mathbf{D})(\mathbf{YMa}_j) = \lambda_j (\mathbf{YMa}_j) \quad (3)$$

relație care arată că oricărui vector propriu $\mathbf{a}_j$ al lui $\mathbf{Y}'\mathbf{DYM}$ corespunzător unei valori proprii $\lambda_j \neq 0$ îi corespunde un vector propriu $\mathbf{YMa}_j$ al matricii $\mathbf{YMY}'\mathbf{D}$ relativ la aceeași valoare proprie λ_j . Cum cu μ_1 a fost notată valoarea proprie maximă a matricii $\mathbf{YMY}'\mathbf{D}$ rezultă, în mod necesar, că $\lambda_1 \leq \mu_1$.

Pe de altă parte, înmulțind la stânga egalitatea (2) cu $\mathbf{Y}'\mathbf{D}$ se obține

$$(\mathbf{Y}'\mathbf{DYM})(\mathbf{Y}'\mathbf{Db}_j) = \mu_j (\mathbf{Y}'\mathbf{Db}_j) \quad (4)$$

relație care arată că oricărui vector propriu $\mathbf{b}_j$ al lui $\mathbf{YMY}'\mathbf{D}$ corespunzător unei valori proprii $\mu_j \neq 0$ îi corespunde un vector propriu $\mathbf{Y}'\mathbf{Db}_j$ al matricii $\mathbf{Y}'\mathbf{DYM}$ relativ la aceeași valoare proprie μ_j . Cum cu λ_1 a fost notată valoarea proprie maximă a matricii $\mathbf{Y}'\mathbf{DYM}$ rezultă, în mod necesar, că $\mu_1 \leq \lambda_1$, ceea ce arată, în final, că $\mu_1 = \lambda_1$.

Analog se poate arăta că toate valorile proprii nenule ale celor două matrici, $\mathbf{Y}'\mathbf{DYM}$ și $\mathbf{YMY}'\mathbf{D}$, sunt egale, având eventual același ordin de

multiplicitate, adică⁵:

$$\begin{aligned}\lambda_j &= \mu_j \neq 0, & j = \overline{1, \operatorname{rg}(\mathbf{Y}'\mathbf{Y})} \\ \lambda_j &= 0, & j = \overline{\operatorname{rg}(\mathbf{Y}'\mathbf{Y}) + 1, p} \\ \mu_j &= 0, & j = \overline{\operatorname{rg}(\mathbf{Y}'\mathbf{Y}) + 1, n}\end{aligned}$$

(se poate arăta ușor, având în vedere proprietățile matricilor $\mathbf{M}$ și $\mathbf{D}$, că $\operatorname{rg}(\mathbf{Y}'\mathbf{D}\mathbf{Y}\mathbf{M}) = \operatorname{rg}(\mathbf{Y}'\mathbf{Y}) = \operatorname{rg}(\mathbf{Y}\mathbf{M}\mathbf{Y}'\mathbf{D}) = \operatorname{rg}(\mathbf{Y}\mathbf{Y}')$).

Revenind la relația (3) se observă că aceasta este verificată de orice vector de forma $\mathbf{b} = k\mathbf{Y}\mathbf{M}\mathbf{a}$, cu k constantă ce se determină din condiția de $\mathbf{D}$ -ortonormalitate a lui $\mathbf{b}$. Într-adevăr:

$$1 = \mathbf{b}'\mathbf{D}\mathbf{b} = k^2 \mathbf{a}'\mathbf{M}\mathbf{Y}'\mathbf{D}\mathbf{Y}\mathbf{M}\mathbf{a} = k^2 \mathbf{a}'\mathbf{M}(\lambda\mathbf{a}) = k^2 \lambda \mathbf{a}'\mathbf{M}\mathbf{a} = k^2 \lambda,$$

ceea ce implică $k = \frac{1}{\sqrt{\lambda}}$ deci $\mathbf{b} = \frac{1}{\sqrt{\lambda}}\mathbf{Y}\mathbf{M}\mathbf{a}$ dacă $\lambda \neq 0$.

Analog, relația (4) este verificată de orice vector de forma $\mathbf{a} = k\mathbf{Y}'\mathbf{D}\mathbf{b}$ cu k constantă ce se determină din condiția de $\mathbf{M}$ -ortonormalitate a lui $\mathbf{a}$. Se obține $k = \frac{1}{\sqrt{\mu}}$ deci $\mathbf{b} = \frac{1}{\sqrt{\mu}}\mathbf{Y}\mathbf{M}\mathbf{a} = \frac{1}{\sqrt{\lambda}}\mathbf{Y}\mathbf{M}\mathbf{a}$ pentru $\mu = \lambda \neq 0$. ■

Observația 1.2.7

1. Propoziția 1.2.3 demonstrează că este suficient să calculăm valorile și vectorii proprii ai matricii cu dimensiunea cea mai mică iar apoi, prin relațiile de tranziție, să obținem elementele principale din celălalt spațiu. Cum, în general, numărul de variabile este mai mic decât numărul de indivizi, adică $p < n$, este suficient ca analiza în componente principale să se efectueze pe norul de puncte-individ, elementele principale pentru norul de puncte-variabilă obținându-se prin relațiile de tranziție.
2. Coordonatele punctelor pe o axă factorială în $\mathbb{R}^p$ sunt proporționale cu componentele axei factoriale din $\mathbb{R}^n$ corespunzătoare aceleiași valori proprii și reciproc. Într-adevăr $\mathbf{c} = \mathbf{X}\mathbf{u}$ și $\mathbf{d} = \mathbf{X}'\mathbf{v}$ și ținând cont de relațiile de tranziție rezultă $\mathbf{c} = \sqrt{\lambda}\mathbf{b}$ și $\mathbf{d} = \sqrt{\lambda}\mathbf{a}$.

Referitor la analiza în componente principale trebuie să remarcăm:

3. Orientarea axelor factoriale este arbitrară deoarece vectorii proprii sunt determinați modulo semnul lor. Acest lucru nu împietează asupra formei norului, adică a distanțelor între puncte.
4. Analiza în componente principale nu pune în evidență decât legăturile liniare între variabile. Un coeficient de corelație slab între două variabile semnifică doar că acestea sunt independente liniar, în timp ce poate exista o relație de ordin superior lui 1 (relație neliniară).

⁵În relațiile alăturate, ca și în cele ce urmează, se utilizează convenția: în *Relație(j)*, $j = \overline{a, b}$, dacă $a > b$ atunci *Relație(j)* nu există.

5. Coordonata unui punct-variabilă $\mathbf{z}_k$ pe axa $\mathbf{b}_j$ este mai mică sau egală cu 1 în valoare absolută, nefiind altceva decât coeficientul de corelație al variabilei cu factorul $\mathbf{v}_j$ considerat ca o variabilă artificială ale cărei coordonate sunt date de cele n proiecții ale indivizilor pe această axă, conform relațiilor de tranziție. În plus, în cazul datelor centrat-reduce,
- $$\sum_{j=1}^p \text{cor}^2(\mathbf{z}_k, \mathbf{v}_j) = \mathbf{a}'_k \mathbf{M} \mathbf{a}_k = \mathbf{1} .$$

1.2.2.3 RECONSTITUIREA DATELOR ÎNȚIALE

Metodele de analiză factorială rezidă toate pe reprezentarea geometrică a unei proprietăți a matricilor dreptunghiulare și anume *descompunerea în valori singulare*. Descompunerea a fost obținută de Eckart și Young în 1936 pentru matrici dreptunghiulare și generalizează lucrările lui Sylvester din 1889 relativ la matrici pătratice; Gifi în [28] menționează, relativ la această problemă, și lucrările lui Beltrami din 1873 și pe acelea ale lui Jordan din 1874.

În principal, descompunerea în valori singulare semnifică faptul că, în condiții destul de generale, o matrice dreptunghiulară poate fi reprezentată în mod unic ca o „sumă optimală” (în sensul minimului celor mai mici pătrate) de matrici de rang 1 (produse de matrici coloană cu matrici linie). În cazul acesta, pornind de la relația $\mathbf{c} = \mathbf{Y}\mathbf{u}$, înmulțind la dreapta membrii egalității

cu $\mathbf{u}'\mathbf{M}^{-1}$ și sumând după numărul de axe⁶ se obține $\mathbf{Y} \left\{ \sum_{j=1}^p \mathbf{u}_j \mathbf{u}'_j \mathbf{M}^{-1} \right\} =$

$\sum_{j=1}^p \mathbf{c}_j \mathbf{u}'_j \mathbf{M}^{-1}$. Dar $\sum_{j=1}^p \mathbf{u}_j \mathbf{u}'_j \mathbf{M}^{-1} = \mathbf{1}$ căci $\mathbf{u}_j$ sunt $\mathbf{M}^{-1}$ -ortonormați, deci

$$\mathbf{Y} = \sum_{j=1}^p \mathbf{c}_j \mathbf{u}'_j \mathbf{M}^{-1}.$$

Relația de mai sus se numește *formula de reconstituire* a tabelului de date $\mathbf{Y}$ pornind de la componentele și factorii principali. Analog, se poate reconstitui tabelul $\mathbf{X}$ și, de asemenea,

$$\begin{aligned} \mathbf{M}\mathbf{V} &= \sum_{j=1}^p \lambda_j \mathbf{u}_j \mathbf{u}'_j \mathbf{M}^{-1} \text{ și} \\ \mathbf{V}\mathbf{M} &= \sum_{j=1}^p \lambda_j \mathbf{a}_j \mathbf{a}'_j \mathbf{M}. \end{aligned}$$

Dacă $\mathbf{M} = \mathbf{I}$, adică în cazul metricii euclidiene, axele principale coincid cu factorii principali și, conform formulelor de tranziție, se obține formula de

⁶Unii vectori proprii $\mathbf{b}$ pot să corespundă unei valori proprii nule. În acest caz ei sunt aleși astfel încât să completeze baza ortonormată formată din axele precedente.

reconstituire

$$\mathbf{Y} = \sum_{j=1}^p \mathbf{c}_j \mathbf{u}'_j = \sum_{j=1}^p \sqrt{\lambda_j} \mathbf{v}_j \mathbf{u}'_j$$

cu $\mathbf{v}_j$ vectori proprii normați ai matricii $\mathbf{Y}\mathbf{Y}'$ și $\mathbf{u}_j$ vectori proprii normați ai matricii $\mathbf{Y}'\mathbf{Y}$.

Dacă în formula de mai sus sumarea se face doar după primii $q < p$ termeni atunci se obține cea mai bună aproximare, în sensul celor mai mici pătrate, a lui $\mathbf{Y}$ printr-o matrice de rang q (desigur dacă în sumarea de mai sus valorile proprii sunt ordonate descrescător). Să observăm că, privite doar din acest punct de vedere, metodele de analiză factorială se reduc la *metode de compresie a datelor*.

1.2.3 Interpretarea și calitatea rezultatelor unei ACP

ACP construiește variabile noi, artificiale și reprezentări grafice ce permit vizualizarea relațiilor între variabile și a eventualelor grupe de indivizi și de variabile. Interpretarea rezultatelor este o fază delicată ce trebuie întreprinsă respectând următoarele etape:

1. studiul calității reprezentărilor în planurile factoriale;
2. interpretarea rezultatelor pornind de la datele utilizate în ACP (interpretarea „internă”);
3. interpretarea rezultatelor pornind de la indivizi și / sau variabile suplimentare care nu au fost utilizate în construirea reprezentărilor ACP (interpretarea „externă”);
4. reprezentarea simultană a indivizilor și variabilelor ce fac obiectul ACP.

1.2.3.1 CALITATEA REPREZENTĂRILOR ÎN PLANURILE FACTORIALE

Axele factoriale permit obținerea celei mai bune vizualizări aproximative, în sensul celor mai mici pătrate, ale distanțelor dintre indivizi, respectiv dintre variabile. În acest sens, primul demers care se impune este legat de măsurarea calității acestei aproximări.

Se observă că, dacă ultimele $p-q$ valori proprii ale matricii $\mathbf{Y}$, ordonate în prealabil descrescător, sunt considerate "neglijabile" atunci, conform descompunerii în valori singulare, $\mathbf{Y} \approx \mathbf{Y}^* = \sum_{j=1}^q \sqrt{\lambda_j} \mathbf{v}_j \mathbf{u}'_j$ în cazul metricii euclidiene.

Aceasta înseamnă că cei np coeficienți ai matricii $\mathbf{Y}$ pot fi reprezentați doar prin cei $q(n+p)$ termeni ai sumei de mai sus, ceea ce reprezintă, din punct

de vedere numeric, un câștig important dacă $q \ll p$. Cu acestea, o măsură naturală a calității aproximării este dată de raportul

$$\tau_q = \frac{\sum_i \sum_j p_i p_j (y_{ij}^*)^2}{\sum_i \sum_j p_i p_j y_{ij}^2}$$

sau, conform Lemei **1.2.7**

$$\tau_q = \frac{\text{tr}((\mathbf{Y}^*)' \mathbf{D} \mathbf{Y}^*)}{\text{tr}(\mathbf{Y}' \mathbf{D} \mathbf{Y})} = \frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^p \lambda_j} = \frac{\sum_{j=1}^q \lambda_j}{I_{\mathbf{g}}}.$$

Raportul $\tau_q \leq 1$ se numește *rata inerției* sau *procentul de dispersie* datorat primilor q factori. Interpretarea sa ca măsură a calității numerice a aproximării este destul de clară dar semnificația sa statistică este delicată. Într-adevăr, din punct de vedere statistic, interpretarea raportului comportă două aspecte:

- alegerea numărului de axe principale;
- găsirea intervalului de încredere pentru dispersia coordonatelor punctelor-individ pe axa principală corespunzătoare.

Principalul scop al ACP constând în reducerea dimensiunii spațiului indivizilor, alegerea lui q - numărul de axe principale ce trebuie reținute, este o problemă importantă care, din păcate, nu are o soluție riguroasă. Să remarcăm, înainte de toate, că reducerea dimensiunii nu este posibilă decât dacă există o redundanță între variabilele. Dacă acestea sunt independente, ceea ce este un rezultat important în sine, ACP va fi inefficientă în reducerea dimensiunii. Există mai multe proceduri care să ghideze alegerea numărului de axe (vezi [41]). În cele ce urmează ne vom opri asupra:

- a) regulilor empirice, și
- b) criteriilor bazate pe anumite proprietăți statistice ale valorilor proprii.

a)Reguli empirice Regulile empirice se bazează pe forma secvenței de valori proprii; două reguli, atribuite lui Cattell și respectiv Kaiser vor fi citate cu titlu istoric.

Regula „cotului” (sau the *scree-test*) introdusă de Cattell în 1966 (vezi, de exemplu, [41]) constă în studiul histogramei valorilor proprii ordonate descrescător în vederea decelării unei schimbări de pantă urmând a fi reținute acele valori proprii, deci număr de axe, aflate la stânga punctului „de discontinuitate” observat.

Fundamentarea criteriului cotului este dată de observația că valorile proprii descresc regulat dacă datele sunt puțin structurate (variabilele nu sunt prea corelate între ele); se poate deci presupune că a intervenit un factor de structurare de fiecare dată când diagrama valorilor proprii prezintă o schimbare evidentă de pantă.

Al doilea criteriu empiric este cel enunțat de Kaiser în 1961 (vezi, de exemplu, [41]) ce recomandă reținerea acelor valori proprii superioare mediei tuturor valorilor proprii (să remarcăm, conform Lemei 1.2.7 și Observației 1.2.3, că în cazul ACP normate media valorilor este 1). Datorită simplității sale, acest criteriu este foarte răspândit și implementat drept criteriu standard în majoritatea pachetelor de programe de analiză factorială.

b) Criterii bazate pe proprietățile statistice ale valorilor proprii Lucrările relative la studiul distribuției valorilor și vectorilor proprii cât și lucrările relative la comportamentul asimptotic al acestor elemente sunt în număr mare dar puține rezultate sunt utilizabile practic. Cu excepția mențiunilor explicate toate rezultatele ce vor fi prezentate presupun că observațiile, în număr de n , urmează o lege normală p -dimensională $\mathbf{N}_p(\mu, \Sigma)$. În 1951, Bartlett propune o metodă pentru testarea egalității a $p - q$ valori proprii ale matricilor Σ sau $\mathbf{R}$. Lawley este cel care, în 1956, aprofundează studiul la cazul celor mai mici $p - q$ valori proprii ale lui Σ . Anderson, generalizează în 1963 aceste rezultate și determină legile limită ale valorilor proprii fără să presupună, în mod necesar, că valorile teoretice corespunzătoare sunt distincte. El demonstrează în particular, pentru a testa egalitatea celor mai mici r valori proprii $\hat{\lambda}_j$ ale matricii de covarianță de selecție corectate, $\mathbf{V}^* = \frac{n}{n-1} \mathbf{V}$, că statistica

$$X^2 = nr \log \frac{\left(\frac{1}{r}\right) \sum_{j=p-r+1}^p \hat{\lambda}_j}{\left(\prod_{j=p-r+1}^p \hat{\lambda}_j\right)^{\frac{1}{p}}}$$

este asimptotic distribuită χ^2 cu $\frac{r(r+1)}{2} - 1$ grade de libertate.

Legat de găsirea intervalului de încredere pentru dispersia coordonatelor punctelor-individ pe axa principală, reamintim că aceasta este egală cu valoarea proprie corespunzătoare (conform Lemei 1.2.10). T.W.Anderson a arătat că, dacă valorile teoretice λ_j ale lui Σ sunt distincte, $\sqrt{n-1}(\hat{\lambda}_j - \lambda_j)$ converge către o lege normală $\mathbf{N}(0, 2\lambda_j^2)$. Se deduce imediat că intervalul de încredere cu pragul de semnificație de 95% este:

$$\hat{\lambda}_j \left(1 - 1,96\sqrt{2/(n-1)}\right) < \lambda_j < \hat{\lambda}_j \left(1 + 1,96\sqrt{2/(n-1)}\right).$$

Lungimea intervalului este o indicație asupra stabilității valorii proprii față de fluctuațiile eșantionului presupus repartizat gaussian. Intersecția intervalelor a două valori proprii consecutive sugerează, deci, egalitatea acestor

valori proprii. Axele corespunzătoare sunt atunci definite modulo o rotație, ceea ce permite utilizatorului să evite interpretarea unei axe instabile după acest criteriu.

O îmbunătățire a criteriului lui Kaiser este dată în 2000 de Enăchescu și Enăchescu. Aceștia demonstrează că, în cazul analizei în componente principale normate, $\hat{\lambda}_i$ este semnificativ mai mare decât unu dacă

$$\hat{\lambda}_i > 1 + 2\sqrt{\frac{p-1}{n-1}}.$$

Generalizări ale rezultatelor asimptotice ale lui T.W.Anderson la cazul ne-gaussian se pot găsi, printre alții, în [13] fără a avea, însă, o utilizare practică.

Intervalele de încredere ale lui Anderson se referă atât la valorile proprii ale matricilor de covarianță cât și la valorile proprii ale matricilor de corelație. Simulările întreprinse au arătat că rezultatele obținute sunt în general „prudente”: procentul de acoperire al adevăratei valori proprii este cel mai adesea superior pragului de semnificație anunțat ([41]). În orice caz, natura asimptotică a rezultatelor ca și ipoteza subiacentă de normalitate, fac ca acestea să aibă doar un caracter indicativ.

Concluzionând asupra calității reprezentărilor în planurile factoriale vom spune că rata inerției definește "puterea explicativă" a factorilor; ea reprezintă partea din dispersia totală datorată celor q factori reținuți. Această apreciere trebuie să țină cont atât de numărul de indivizi cât și de numărul de variabile; o rată de inerție (relativ la o axă) de 10% poate fi o valoare importantă dacă tabelul posedă 100 de variabile și poate fi o valoare neglijabilă dacă nu sunt decât 10 variabile. Rata inerției este deci o *măsură pesimistă* a calității proiecției imaginii euclidiene a indivizilor. Rata inerției este, în plus, o *măsură globală* a calității reprezentării în planul factorial. Ea trebuie completată cu alte măsuri, locale, ale calității acestei reprezentări.

Printre măsurile locale cele mai "populare" se numără cea a cosinusului pătrat al unghiului dintre planul factorial și vectorul cu originea în proiecția centrului de greutate al norului și cu vârful în punctul-individ. Fundamentarea teoretică a utilizării acestei măsuri se bazează pe faptul că distanțele între puncte se deformează prin proiecție cu atât mai puțin cu cât punctele sunt mai apropiate de planul în care sunt proiectate (desigur, cazul în care punctele se află pe o dreaptă paralelă cu planul de proiecție este neinteresant în acest context). Valoarea acestei măsuri este dată de următoarea lemă.

Lema 1.2.12

Calitatea reprezentării unui punct-individ, A_i , în planul factorial principal este

$$\text{cal}(i) = \frac{c_{1i}^2 + c_{2i}^2}{\sum_{j=1}^p c_{ji}^2}$$

Demonstrație. Fie A_i punctul considerat, P_i proiecția sa în planul factorial principal și G proiecția centrului de greutate al norului în planul factorial principal. Conform definiției componentelor principale, în $\mathcal{F}$, A_i are coordonatele $(c_{1i}, c_{2i}, \dots, c_{pi})$ iar P_i are coordonatele $(c_{1i}, c_{2i})'$.

Cosinusul unghiului dintre $\overrightarrow{GA_i}$ și planul factorial principal este cosinusul unghiului dintre $\overrightarrow{GA_i}$ și $\overrightarrow{GP_i}$, notat cu θ . În triunghiul A_iP_iG , dreptunghic în P_i (din construcție) $\cos^2 \theta = \frac{\overrightarrow{GP_i}^2}{\overrightarrow{GA_i}^2}$ și cum $\overrightarrow{GP_i}^2 = c_{1i}^2 + c_{2i}^2$, conform teoremei lui Pitagora, rezultă $\cos^2 \theta = \frac{c_{1i}^2 + c_{2i}^2}{\sum_{j=1}^p c_{ji}^2}$. ■

Un mod mai bun de a afla dacă o observație este bine reprezentată într-un subspațiu este acela de a da o interpretare statistică pătratului distanței de la observație la acel subspațiu. Astfel, pentru observații repartizate normal, inerția globală este o sumă ponderată de p variabile independente repartizate χ_1^2 , adică $I_{\mathbf{g}} = \sum_{j=1}^p \lambda_j \chi_{1,j}^2$. Cum, în această ipoteză $E(I_{\mathbf{g}}) = \sum_{j=1}^p \lambda_j$ și $D^2(I_{\mathbf{g}}) = 2 \sum_{j=1}^p \lambda_j^2$ și, pe de altă parte, distanța de la un punct-individ la planul factorial principal este

$$d^2(A_i, \{\mathbf{w} \in \mathbb{R}^2 | \mathbf{w} = a_1 \mathbf{u}_1 + a_2 \mathbf{u}_2\}) = \sum_{j=3}^p c_{ji}^2 = \sum_{j=3}^p \lambda_j \frac{c_{ji}^2}{\lambda_j},$$

o modalitate de a da o semnificație statistică acestei distanțe este de a o compara cu o combinație liniară de χ_1^2 . Utilizând intervalele de încredere de tip 2σ se poate conchide că punctele aflate față de planul factorial principal la o distanță mai mare de

$$\sum_{j=3}^p \lambda_j + 2 \sqrt{2 \sum_{j=3}^p \lambda_j^2}$$

sunt prost reprezentate în acest subspațiu cu o probabilitate de 95% (conform [24]).

Datorită egalității $\lambda_j = \mu_j$ (conform Propoziției 1.2.3) măsura globală a calității proiecției imaginii euclidiene a norului de puncte-variabilă este tot τ_q , cu aceleași observații ca pentru norul de puncte-individ. În ceea ce privește măsurile locale trebuie să remarcăm că, în cazul punctelor-variabilă interesează unghiurile dintre proiecțiile vectorilor cu vâfurile în aceste puncte și nu proximitatea proiecțiilor în planul factorial principal (cercul de corelație în cazul ACP normate).

1.2.3.2 INTERPRETAREA "INTERNĂ"

Metoda cea mai naturală de a da o semnificație unei componente principale $\mathbf{c}$ este de a o corela cu variabilele inițiale $\mathbf{x}_j$. În acest sens se vor calcula coeficienții de corelație

liniară $\text{cor}(\mathbf{c}, \mathbf{x}_j)$ și se vor pune în evidență coeficienții cu valori absolute mari. Valorile acestor coeficienți sunt date de următoarea leamnă.

Lema 1.2.13

În cazul unei ACP normate $\text{cor}(\mathbf{c}, \mathbf{z}_j) = \sqrt{\lambda} \mathbf{u}_j$.

Demonstrație. Din definiție, $\text{cor}(\mathbf{c}, \mathbf{z}_j) = \frac{\text{cov}(\mathbf{c}, \mathbf{z}_j)}{s(\mathbf{c})s(\mathbf{z}_j)} = \frac{\text{cov}(\mathbf{c}, \mathbf{z}_j)}{\sqrt{\lambda}}$ (conform Corolarului 1.2.3 și Lemei 1.2.10). Dar $\text{cov}(\mathbf{c}, \mathbf{z}_j) = \mathbf{c}'\mathbf{D}\mathbf{z}_j = \mathbf{u}'\mathbf{Z}'\mathbf{D}\mathbf{z}_j$ adică este al j -lea coeficient al vectorului $(\mathbf{Z}'\mathbf{D}\mathbf{Z})\mathbf{u}$. Cum, din definiție, $\mathbf{Z}'\mathbf{D}\mathbf{Z} = \mathbf{R}$ și cum $\mathbf{R}\mathbf{u} = \lambda\mathbf{u}$ (din Lema 1.2.8) rezultă $\text{cor}(\mathbf{c}, \mathbf{z}_j) = \sqrt{\lambda}\mathbf{u}_j$. ■

Corolarul 1.2.4

Cercul de corelație principal este, în spațiul variabilelor, corespondentul exact al planului factorial principal.

Demonstrație. Într-adevăr, în ACP normată coordonatele proiecției unui punct-variabilă B_j sunt (d_{1j}, d_{2j}) care, conform formulelor de tranziție, sunt egale cu $(\sqrt{\lambda_1}a_{1j}, \sqrt{\lambda_2}a_{2j})$. Dar în cazul unei ACP normate axele principale coincid cu factorii principali deci,

$$\begin{aligned}(d_{1j}, d_{2j}) &= (\sqrt{\lambda_1}a_{1j}, \sqrt{\lambda_2}a_{2j}) = (\sqrt{\lambda_1}u_{1j}, \sqrt{\lambda_2}u_{2j}) = \\ &= (\text{cor}(\mathbf{c}_1, \mathbf{z}_j), \text{cor}(\mathbf{c}_2, \mathbf{z}_j))\end{aligned}$$

conform Lemei 1.2.13. ■

A spune că $\mathbf{c}_1$ este foarte corelată cu o variabilă $\mathbf{x}_j$ înseamnă că indivizii cu o coordonată pozitivă mare pe axa unu sunt caracterizați de o valoare a lui $\mathbf{x}_j$ net superioară mediei (căci originea axelor principale este în centrul de greutate al norului de puncte-individ). Reciproc, dacă indivizii nu sunt anonimi, aceștia pot ajuta la interpretarea axelor și componentelor principale (vor fi evidențiați, de exemplu, indivizii opuși de-a lungul unei axe).

O măsură naturală a contribuției unui punct-individ la o axă factorială este raportul dintre dispersia individului și dispersia întregii axe. Din Lema 1.2.10 se cunoaște faptul că $\sum_{i=1}^n p_i c_{ji}^2 = \lambda_j$, deci contribuția individului i la axa principală j este

$$\text{cr}_j(i) = \frac{p_i c_{ji}^2}{\lambda_j}.$$

Când indivizii sunt anonimi, adică au toți ponderile $p_i = \frac{1}{n}$, contribuțiile "cr" nu aduc mai multe informații decât coordonatele acestora. Dacă cei n indivizi au aceeași pondere, $1/n$, inerția unui punct variază direct proporțional cu distanța la centrul de greutate. Indivizii care contribuie determinant la inerția axei sunt cei mai depărtați de punctul mediu și lectura coordonatelor factoriale sau vizualizarea graficului sunt suficiente pentru a interpreta factorii în acest caz. Prezentarea indivizilor în planul factorial permite să apreciem

repartiția lor și să reperăm zonele de densități mai mari sau mai slabe. Ca o recomandare generală se va considera importantă contribuția care depășește ponderea p_i a individului, sau $\frac{1}{4}$ în cazul indivizilor anonimi. Dacă p și n sunt mari atunci componentele principale sunt deseori considerate ca fiind selecții asupra unor variabile aleatoare repartizate normal de medie zero și dispersie λ . În acest caz $\frac{c_{ji}^2}{\lambda_j}$ este distribuită χ_1^2 și o contribuție mai mare decât $\frac{3.84}{n}$ poate fi considerată semnificativă cu un prag de încredere de 95% (conform [24]).

Considerarea contribuțiilor, când acestea nu sunt excesive, ajută la interpretarea axelor. În mod normal, în special pentru primele axe factoriale, nu este de dorit ca un individ să aibă o contribuție excesivă căci acesta poate constitui un *factor de instabilitate*, adică omiterea individului poate modifica profund rezultatele analizei. În cazul unui sondaj (indivizi anonimi) contribuția excesivă a unui individ este adesea cauzată de erori de preluare a datelor. Pentru a pune în evidență aceste anomalii (și evident pentru a le elimina) C. și D. Enăchescu recomandă următorul test empiric în cazul unei ACP normate:

dacă pătratul distanței de la un punct-individ la centrul de greutate al norului este mai mare decât $p + 2\sqrt{2 \sum_{i=1}^p \lambda_i^2}$ atunci observația respectivă poate fi considerată o valoare aberantă.

Într-adevăr, dacă observațiile sunt normal distribuite, $I_{\mathbf{g}}$ este o sumă ponderată de p variabile repartizate χ_1^2 cu media $\sum_{i=1}^p \lambda_i = p$ (datorită datelor centrat-reduce) și dispersia $2 \sum_{i=1}^p \lambda_i^2$. Considerând intervalul de încredere de 95% pentru $I_{\mathbf{g}}$ se obține marginea din recomandarea de mai sus.

Dacă observațiile sunt independente atunci λ_i estimate pe baza acestor observații sunt de medie 1 și satisfac egalitatea $\sum_{i=1}^p \lambda_i^2 = p + 2 \sum_{i>j} r_{ij}^2$. Deoarece media pătratului coeficientului de corelație între două variabile normale independente este $\frac{1}{n-1}$ rezultă că $E \left(\sum_{j=1}^p \lambda_j^2 \right) = p + \frac{p(p-1)}{n-1}$. Revenind la *marginea pentru valori aberante* găsită mai sus, în cazul independenței observațiilor o putem rafina înlocuind-o cu

$$p + 2\sqrt{2p \left(1 + \frac{p-1}{n-1} \right)}$$

sau $p + 2,8\sqrt{p}$, pentru n mare.

Analiza unui nor de variabile facându-se pornind din origine, variabilele pot fi toate situate de aceeași parte a unei axe factoriale. O astfel de dispoziție apare atunci când toate variabilele sunt corelate pozitiv între ele. În acest caz $\mathbf{c}_1$, prima componentă principală definește un *factor de talie*. Conform

teoremei lui Perron⁷ (vezi, de exemplu, [15]) $\mathbf{c}_1$ este atunci corelată pozitiv cu toate variabilele și indivizii sunt ordonați pe prima axă principală crescător după mediile $\left\{ \frac{1}{p} \sum_{j=1}^p y_{ij} \right\}_{i=1}^n$. Ortogonalitatea axelor face să nu existe decât un singur factor de „talie”. A doua componentă principală diferențiază atunci indivizii de „talie” comparabilă și această componentă se va numi *factor de formă*.

1.2.3.3 INTERPRETAREA "EXTERNĂ": VARIABLE ȘI INDIVIZI SUPLIMENTARI

Interpretările interne au dezavantajul că sunt tautologice: se explică un rezultat cu ajutorul datelor care au servit la obținerea lui. Riscul care apare într-un astfel de caz este acela de a confunda un artefact introdus de metodă cu un fenomen semnificativ. Din contră, dacă se găsește o corelație puternică între o componentă principală și o variabilă care nu a fost utilizată în analiză, caracterul probant al fenomenului va fi mult mai ridicat. De unde practica frecvent utilizată de a împărți în două mulțimea variabilelor: o parte din variabile, numite *variabile active*, vor fi utilizate pentru determinarea axelor principale și cealaltă parte a variabilelor numite *variabile pasive/suplimentare/ilustrative*, vor fi corelate a posteriori cu componentele principale. În plus, variabilele active, definite într-un spațiu și utilizate la calculul planurilor factoriale, trebuie să formeze un ansamblu omogen ca textură (trebuie, adică, să aibă aceeași natură) pentru ca distanțele între elemente să aibă un sens. Pentru a interpreta similitudinile între elemente acestea trebuie să fie omogene și în conținut, adică să privească o aceeași temă. Se compară obiectele după un anumit punct de vedere și nu utilizând fără discernământ toate atributele cunoscute și adesea disparate. Variabilele suplimentare nu sunt însă supuse acestor condiții de omogenitate.

Un tratament analog se poate aplica și mulțimii indivizilor, distingând între *indivizi activi* și *indivizi suplimentari* care nu participă la calculul matricilor de covarianță/corelație. Indivizii suplimentari permit verificarea netautologică a ipotezelor formulate asupra indivizilor activi după o ACP.

Se notează cu $\mathbf{Y}^+ \in \mathcal{M}_{n,s}(\mathbb{R})$ cele s variabile (coloane) continue, ilustrative, și cu $\mathbf{Y}_+ \in \mathcal{M}_{t,p}(\mathbb{R})$ cei t indivizi (linii) suplimentari. După eventuala normare a datelor suplimentare, coordonatele noilor variabile pe axa j sunt componentele vectorului

$$(\mathbf{Y}^+)' \mathbf{v}_j \text{ sau } (\mathbf{Z}^+)' \mathbf{v}_j$$

iar coordonatele noilor indivizi pe axa j sunt componentele vectorului

$$(\mathbf{Y}_+) \mathbf{u}_j \text{ sau } (\mathbf{Y}_+) \mathbf{u}_j$$

⁷Dacă o matrice pătratică și simetrică are toți coeficienții pozitivi atunci valoarea sa proprie cea mai mare în modul este pozitivă, rădăcină simplă a ecuației caracteristice și i se asociază un vector propriu având componente pozitive.

Dacă variabila suplimentară este nominală transformarea de mai sus nu mai poate fi aplicată. În această situație, analiza unei variabile nominale suplimentare nu se mai face în $\mathbb{R}^n$ ci în $\mathbb{R}^p$. Fiecare modalitate a variabilei nominale este reprezentată în spațiul indivizilor prin centrul de greutate al subnorului de puncte-individ care au ales respectiva modalitate.

1.2.3.4 REPREZENTAREA SIMULTANĂ Analiza norului de variabile este dedusă din analiza norului de indivizi: reprezentarea variabilelor pe axele factoriale în $\mathbb{R}^n$ ajută la interpretarea axelor factoriale în $\mathbb{R}^p$ și reciproc. Cei doi nori nu folosesc, însă, același reper, ceea ce face imposibilă reprezentarea simultană a indivizilor și variabilelor. Astfel:

- în spațiul $\mathbb{R}^p$, reprezentarea norului de n puncte-individ se face în reperul $\{\mathbf{G}, \mathbf{u}_1, \dots, \mathbf{u}_p\}$. Reprezentarea indivizilor în planul factorial furnizează cea mai bună vizualizare aproximativă a distanțelor între indivizi. Vecinătatea indivizilor în planul factorial se interpretează în termeni de similitudini de comportament față de variabilele observate;
- în spațiul $\mathbb{R}^n$, reprezentarea norului de p puncte-variabilă se face în reperul $\{\mathbf{O}, \mathbf{v}_1, \dots, \mathbf{v}_n\}$. Reprezentarea variabilelor în cercul de corelație furnizează o sinteză grafică a matricii de corelație. Vecinătatea variabilelor în planul cercului de corelație se interpretează în termeni de corelații.

Luând în considerare cele de mai sus, suprapunerea celor două planuri factoriale este lipsită de sens. **Trebuie să ne ferim a interpreta distanța dintre un punct-individ și un punct-variabilă deoarece aceste puncte nu fac parte nici din același nor, nici din același spațiu și nici nu sunt reprezentate în același reper.**

Dacă, însă, se consideră în loc de puncte-variabilă direcții de variabile în $\mathbb{R}^p$, atunci se pot reprezenta simultan, în acest spațiu, atât punctele-individ cât și vectorii reprezentând variabilele.

În spațiul $\mathbb{R}^p$ al celor n puncte-individ, după transformarea tabelului de date, dispunem de două sisteme de axe:

- vechile axe unitare $\{\mathbf{e}_1, \dots, \mathbf{e}_p\}$ corespunzând celor p variabile înainte de analiză și reprezentând sistemul de axe de referință pentru coordonatele inițiale ale indivizilor (cu $\mathbf{e}'_j = (0, \dots, 0, 1_j, 0, \dots, 0)$, $j = \overline{1, p}$);
- noile axe unitare $\{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ formate din axele factoriale.

Posibilitatea unei reprezentări simultane rezidă în acest context în proiecția, ca individ suplimentar, a vechii axe $\mathbf{e}_j$ pe noua axă $\mathbf{u}_k$. Coordonata proiecției lui $\mathbf{e}_j$ pe $\mathbf{u}_k$ este $\mathbf{e}'_j \mathbf{u}_k = u_{kj}$. Este, astfel, posibil să se reprezinte în $\mathbb{R}^p$ direcțiile date de variabilele inițiale pe planul factorial al norului de indivizi. Aceste

direcții pot fi materializate prin vectori unitari. Acești vectori constituie reperul originar în care a fost construit norul de indivizi și sunt, deci, ortogonali doi câte doi. Este, acum, evident faptul că această reprezentare a variabilelor este diferită de reprezentarea norului de variabile descrisă mai sus. Ceeace se va numi *reprezentare simultană* este, deci, proiectarea reperului ortonormat al axelor de origine în planul factorial al norului de indivizi.

Se reamintește că, în $\mathbb{R}^n$, în metrica euclidiană, coordonata variabilei j pe axa k este egală cu coeficientul de corelație (conform formulei de tranziție) între variabilă și factor și este $d_{kj} = \sqrt{\lambda_k} u_{kj}$. Cei doi nori de variabile nu coincid. Ei diferă unul de celălalt, pe fiecare axă, prin coeficientul de dilatație $\sqrt{\lambda_k}$.

În cazul reprezentării simultane, care este de fapt o reprezentare în $\mathbb{R}^n$, distanța dintre două variabile nu se interpretează în termeni de corelație deoarece este vorba de extremitățile unor vectori ortonormați (distanță egală cu $\sqrt{2}$ în spațiul complet). Interpretarea distanței între două variabile, în termeni de corelație, nu se poate face decât în $\mathbb{R}^n$ (să observăm, totuși, că norul proiectat al extremităților vectorilor unitari din $\mathbb{R}^p$ și norul extremităților vectorilor variabile în $\mathbb{R}^n$ au, în general, forme asemănătoare, mai ales dacă vectorii proprii sunt comparabili, deci dilatările sunt puțin deformante). Ținând cont de aceste considerații, este licit să comparăm, în reprezentarea simultană, poziția a doi indivizi față de ansamblul variabilelor, sau poziția a două variabile față de ansamblul indivizilor. Astfel, direcția unei variabile definește zone pentru indivizi: de o parte indivizii ce iau valori mari pentru această variabilă și în partea opusă, indivizii care iau valori mici. Ne vor interesa distanțele între indivizi în direcția variabilei. La intersecția axelor se găsesc valorile medii ale tuturor variabilelor.

1.2.4 Analize neparametrice

Metodele de analiză neparametrică nu diferă de ACP decât printr-o transformare preliminară a datelor. Aceste metode sunt recomandate atunci când datele preliminare sunt heterogene, dau rezultate foarte robuste și se pretează la interpretări simple în termeni statistici.

1.2.4.1 ANALIZA RANGURILOR În analiza rangurilor, tabelul inițial este transformat în tabel de ranguri. Observația i a variabilei j constă, în acest caz, într-un clasament q_{ij} dat de rangul observației i în ordonarea crescătoare a celor n realizări ale variabilei j . În aceste condiții, distanța între două variabile, $\mathbf{q}_j$ și $\mathbf{q}_k$, este definită de formula:

$$d^2(\mathbf{q}_j, \mathbf{q}_k) = \frac{6}{n(n-1)(n+1)} \sum_{i=1}^n (q_{ij} - q_{ik})^2.$$

Recunoaștem în această formulă complementul față de 1 al *coeficientului de corelație Spearman*.

1.3 Analiza corespondențelor simple (ACS)

Prezentată sub acest nume și dezvoltată în Franța de J.P. Benzecri [5], metoda are ca precursori pe Guttman [31] și Hayashi [36].

Analiza corespondențelor este o metodă adaptată tabelelor de contingență care permite studiul relațiilor între două sau mai multe variabile nominale (discrete).

Se distinge între:

- **Analiza corespondențelor simple (ACS)** în cazul studiului relațiilor între două variabile nominale;
- **Analiza corespondențelor multiple (ACM)** în cazul studiului relațiilor între mai multe variabile nominale;

Definiția 1.3.1 Se numește *tabel de contingență* (sau *de dependență* sau *încrucișat*) un tabel ale cărui linii, respectiv coloane desemnează două partiții ale aceleiași mulțimi, partiții date de modalitățile a două variabile nominale.

Fie $\mathcal{X}$ și $\mathcal{Y}$ două variabile nominale cu n respectiv p modalități descriind o mulțime de k indivizi.

Fie $\mathbf{K}$ tabelul de contingență cu n linii, p coloane și elementele k_{ij} , unde k_{ij} este numărul de indivizi avînd simultan modalitatea i a variabilei $\mathcal{X}$ și modalitatea j a variabilei $\mathcal{Y}$.

Se notează cu

$$\begin{aligned} k_{i.} &= \sum_j k_{ij}, & k_{.j} &= \sum_i k_{ij}, \\ k &= \sum_{i,j} k_{ij} = \sum_i k_{i.} = \sum_j k_{.j}, \end{aligned}$$

și cu

$$\begin{aligned} f_{ij} &= \frac{k_{ij}}{k} \text{ frecvențele relative, cu marjele:} \\ f_{i.} &= \sum_j f_{ij}, & f_{.j} &= \sum_i f_{ij}, & f &= \sum_{i,j} f_{ij} = 1. \end{aligned}$$

Grafic, tabelul se prezintă astfel:

$\mathcal{X} / \mathcal{Y}$	y_1	y_2	$\cdots$	y_j	$\cdots$	y_p	
x_1				$\vdots$			$k_{1.}$
x_2				$\vdots$			$k_{2.}$
$\vdots$				$\vdots$			
x_i	$\cdots$	$\cdots$	$\cdots$	k_{ij}			$k_{i.}$
$\vdots$							
x_n							$k_{n.}$
	$k_{.1}$	$k_{.2}$	$\cdots$	$k_{.j}$	$\cdots$	$k_{.p}$	k

Două lecturi sunt posibile, după cum este privilegiată una sau alta dintre variabile: pe linii, cu frecvențele $\left\{\frac{f_{ij}}{f_{i\cdot}}\right\}_{j=1,p}^{i=1,n}$, respectiv pe coloane, cu frecvențele $\left\{\frac{f_{ij}}{f_{\cdot j}}\right\}$.

1.3.1 Schema generală de ACS

Analiza corespondențelor simple revine la efectuarea unei analize generale a unui nor de puncte ponderate într-un spațiu cu o metrică specială.

1.3.1.1 GEOMETRIA NORILOR ȘI ELEMENTELE DE BAZĂ

Fie

- $\mathbf{F} = \begin{pmatrix} f_{11} & f_{12} & \dots & f_{1p} \\ \vdots & & & \vdots \\ f_{n1} & f_{n2} & \dots & f_{np} \end{pmatrix}$ - matricea de dimensiune $n \times p$ a frecvențelor relative;
- $\mathbf{D}_n = \text{diag}(f_{i\cdot})$ - matricea $n \times n$ cu diagonala principală conținând marjele liniilor;
- $\mathbf{D}_p = \text{diag}(f_{\cdot j})$ - matricea $p \times p$ cu diagonala principală conținând marjele coloanelor.




FIG. 1.3.1. TRANSFORMĂRILE TABELULUI DE CONTINGENȚĂ




FIG. 1.3.2. FRECVENȚE, MARJE, PROFILE

1.3.1.2 ALEGEREA DISTANȚEI ȘI A METRICII

Este firesc să ne gândim la distanța euclidiană între profilurile-linie, respectiv profilurile-coloană:

$$d^2(i, i') = \sum_j \left(\frac{f_{ij}}{f_{i.}} - \frac{f_{i'j}}{f_{i'.}} \right)^2$$

și analoga.

Această distanță favorizează coloanele care au o masă $f_{.j}$ importantă, adică modalitățile j care sunt bine reprezentate în populația studiată. Pentru a remedia acest lucru cît și din alte considerente discutate în continuare, se ponderează fiecare diferență cu inversa masei coloanei, obținîndu-se distanța χ^2

$$d_\chi^2(i, i') = \sum_j \frac{1}{f_{.j}} \left(\frac{f_{ij}}{f_{i.}} - \frac{f_{i'j}}{f_{i'.}} \right)^2$$

și analoga

$$d_\chi^2(j, j') = \sum_i \frac{1}{f_{i.}} \left(\frac{f_{ij}}{f_{.j}} - \frac{f_{ij'}}{f_{.j'}} \right)^2.$$

Propoziția 1.3.1

Distanța χ^2 este invariantă la agregarea liniilor, respectiv a coloanelor, cu același profil.

Demonstrație.




FIG. 1.3.3. ECHIVALENȚA DISTRIBUȚIONALĂ: INVARIANȚA DISTANȚELOR ÎNTRE COLOANE FAȚĂ DE AGREGAREA LINIILOR

$$d^2(j, j') = \sum_{i=1}^{i_1-1} \frac{1}{f_{i\cdot}} \left(\frac{f_{ij}}{f_{\cdot j}} - \frac{f_{ij'}}{f_{\cdot j'}} \right)^2 + \frac{1}{f_{i_1\cdot}} \left(\frac{f_{i_1j}}{f_{\cdot j}} - \frac{f_{i_1j'}}{f_{\cdot j'}} \right)^2 +$$

$$+ \frac{1}{f_{i_2\cdot}} \left(\frac{f_{i_2j}}{f_{\cdot j}} - \frac{f_{i_2j'}}{f_{\cdot j'}} \right)^2 + \sum_{i=i_2+1}^n \frac{1}{f_{i\cdot}} \left(\frac{f_{ij}}{f_{\cdot j}} - \frac{f_{ij'}}{f_{\cdot j'}} \right)^2$$

Distanța după agregarea liniilor cu același profil i_1 și i_2 este

$$d_r^2(j, j') = \sum_{i=1}^{i_1-1} \frac{1}{f_{i\cdot}} \left(\frac{f_{ij}}{f_{\cdot j}} - \frac{f_{ij'}}{f_{\cdot j'}} \right)^2 + \frac{1}{f_{i_0\cdot}} \left(\frac{f_{i_0j}}{f_{\cdot j}} - \frac{f_{i_0j'}}{f_{\cdot j'}} \right)^2 +$$

$$+ \sum_{i=i_2+1}^n \frac{1}{f_{i\cdot}} \left(\frac{f_{ij}}{f_{\cdot j}} - \frac{f_{ij'}}{f_{\cdot j'}} \right)^2.$$

Dar $\frac{f_{i_1j}}{f_{i_1\cdot}} = \frac{f_{i_2j}}{f_{i_2\cdot}} = r_j$, $(\forall) j = \overline{1, p}$, deoarece liniile au același profil. Pe de altă parte, prin agregarea liniilor i_1 și i_2 rezultă

$$k_{i_1j} + k_{i_2j} = k_{i_0j}, (\forall) j = \overline{1, p} \Rightarrow \begin{cases} f_{i_1j} + f_{i_2j} = f_{i_0j}, (\forall) j \\ f_{i_1\cdot} + f_{i_2\cdot} = f_{i_0\cdot} \end{cases} \Rightarrow \frac{f_{i_0j}}{f_{i_0\cdot}} = r_j$$

deoarece $k_{i_1j} = k_{i_1\cdot} r_j$, $k_{i_2j} = k_{i_2\cdot} r_j$ și $\frac{f_{i_0j}}{f_{i_0\cdot}} = \frac{f_{i_1j} + f_{i_2j}}{f_{i_1\cdot} + f_{i_2\cdot}} = \frac{k_{i_1j} + k_{i_2j}}{k_{i_1\cdot} + k_{i_2\cdot}} = \frac{r_j(k_{i_1\cdot} + k_{i_2\cdot})}{(k_{i_1\cdot} + k_{i_2\cdot})} = r_j$.

Așadar

$$\begin{aligned}
A(i_1) &= \frac{1}{f_{i_1 \cdot}} \left(\frac{f_{i_1 j}}{f_{\cdot j}} - \frac{f_{i_1 j'}}{f_{\cdot j'}} \right)^2 = f_{i_1 \cdot} \cdot \left[\left(\frac{f_{i_1 j}}{f_{i_1 \cdot}} \right) \cdot \frac{1}{f_{\cdot j}} - \left(\frac{f_{i_1 j'}}{f_{i_1 \cdot}} \right) \cdot \frac{1}{f_{\cdot j'}} \right]^2 = \\
&= f_{i_1 \cdot} \cdot \left[\frac{r_j}{f_{\cdot j}} - \frac{r_{j'}}{f_{\cdot j'}} \right]^2 = f_{i_1 \cdot} B \\
A(i_2) &= \frac{1}{f_{i_2 \cdot}} \left(\frac{f_{i_2 j}}{f_{\cdot j}} - \frac{f_{i_2 j'}}{f_{\cdot j'}} \right)^2 = f_{i_2 \cdot} \cdot \left[\left(\frac{f_{i_2 j}}{f_{i_2 \cdot}} \right) \cdot \frac{1}{f_{\cdot j}} - \left(\frac{f_{i_2 j'}}{f_{i_2 \cdot}} \right) \cdot \frac{1}{f_{\cdot j'}} \right]^2 = \\
&= f_{i_2 \cdot} \cdot \left[\frac{r_j}{f_{\cdot j}} - \frac{r_{j'}}{f_{\cdot j'}} \right]^2 = f_{i_2 \cdot} B \\
\Rightarrow A(i_1) + A(i_2) &= f_{i_1 \cdot} B + f_{i_2 \cdot} B = (f_{i_1 \cdot} + f_{i_2 \cdot}) B = f_{i_0 \cdot} B. \\
A(i_0) &= \frac{1}{f_{i_0 \cdot}} \left(\frac{f_{i_0 j}}{f_{\cdot j}} - \frac{f_{i_0 j'}}{f_{\cdot j'}} \right)^2 = f_{i_0 \cdot} \cdot \left[\left(\frac{f_{i_0 j}}{f_{i_0 \cdot}} \right) \cdot \frac{1}{f_{\cdot j}} - \left(\frac{f_{i_0 j'}}{f_{i_0 \cdot}} \right) \cdot \frac{1}{f_{\cdot j'}} \right]^2 = \\
&= f_{i_0 \cdot} \cdot \left[\frac{r_j}{f_{\cdot j}} - \frac{r_{j'}}{f_{\cdot j'}} \right]^2 = f_{i_0 \cdot} B \\
\Rightarrow A(i_1) + A(i_2) &= A(i_0) \Rightarrow d^2(j, j') = d_r^2(j, j').
\end{aligned}$$

Analog pentru invarianța distanței între liniile profil la agregarea coloanelor.

■

Observația 1.3.1

- Proprietatea demonstrată în propoziția de mai sus se numește *principiul echivalenței distribuțiilor*. Distanța euclidiană nu are această proprietate, spre deosebire de distanța Hellinger.
- Echivalența distribuțională permite agregarea a două modalități (ale aceleiași variabile) cu profile identice (ceea ce face ca în $\mathbb{R}^p$ ele să se confunde) într-o nouă modalitate cu o pondere sumată fără însă a afecta prin aceasta nici distanțele între modalitățile variabilei nou formate, nici distanțele între modalitățile celeilalte variabile.




FIG. 1.3.4. ANALIZA ÎN $\mathbb{R}^3$

Din punct de vedere practic, această proprietate este fundamentală deoarece garantează o oarecare invarianță a rezultatelor față de nomenclatura aleasă pentru construcția modalităților unei variabile, cu condiția regrupării modalităților asemănătoare. Nu se pierde astfel informația prin agregarea unor clase și nu se câștigă informație prin divizarea claselor omogene.

- c) **Metrica** spațiului $\mathbb{R}^p$, respectiv a spațiului $\mathbb{R}^n$, este, în acest caz $\mathbf{M} = \mathbf{D}_p^{-1}$, respectiv $\mathbf{M} = \mathbf{D}_n^{-1}$.
- d) Cum profilurile-linie, respectiv profilurile-coloană au mase $\{f_i\}_{i=1}^n$, respectiv $\{f_j\}_{j=1}^p$, **matricile de pondere** sunt $\mathbf{N} = \mathbf{D}_n$ respectiv $\mathbf{N} = \mathbf{D}_p$.

TABELUL 1.3.1. TABEL RECAPITULATIV CU ELEMENTELE DE BAZĂ ALE UNEI ACS

Elemente de bază	Norul de n puncte-linie în $\mathbb{R}^p$	Norul de p puncte-coloană în $\mathbb{R}^n$
Matricea $\mathbf{X}$ (tabelul)	$\mathbf{X} = \mathbf{D}_n^{-1} \mathbf{F} =$ $= \left\{ \frac{f_{ij}}{f_i} \right\}_{i=1, \overline{n}}^{j=1, \overline{p}}$	$\mathbf{X} = \mathbf{D}_p^{-1} \mathbf{F}' =$ $= \left\{ \frac{f_{ij}}{f_j} \right\}_{j=1, \overline{p}}^{i=1, \overline{n}}$
Metrica și distanța	$\mathbf{M} = \mathbf{D}_p^{-1}$ $d^2(i, i') =$ $= \sum_{j=1}^p \frac{1}{f_j} \left(\frac{f_{ij}}{f_i} - \frac{f_{i'j}}{f_{i'}} \right)^2$	$\mathbf{M} = \mathbf{D}_n^{-1}$ $d^2(j, j') =$ $= \sum_{i=1}^n \frac{1}{f_i} \left(\frac{f_{ij}}{f_j} - \frac{f_{ij'}}{f_{j'}} \right)^2$
Ponderea (masa)	$\mathbf{N} = \mathbf{D}_n = \text{diag}(f_i)$ masa liniei i : f_i	$\mathbf{N} = \mathbf{D}_p = \text{diag}(f_j)$ masa coloanei j : f_j

Lema 1.3.1

1. Centrul de greutate al profilurilor-linie este $\mathbf{x}_{G_l} = (f_{\cdot 1}, \dots, f_{\cdot p})'$, centrul de greutate al profilurilor-coloană este $\mathbf{x}_{G_c} = (f_1, \dots, f_n)'$.
2. Inerția globală a norului de puncte-linie, respectiv puncte-coloană măsoară ecartul între legile empirice f_{ij} și $f_i \cdot f_j$.

Demonstrație.

1. Din definiție $\mathbf{g} = \mathbf{X}' \cdot \mathbf{D} \cdot \mathbf{1}$ deci în acest caz $\mathbf{x}_G = \mathbf{X}' \cdot \mathbf{N} \cdot \mathbf{1}$ cu ponderi

normate, deci

$$\mathbf{x}_{G_l} = (\mathbf{D}_n^{-1} \mathbf{F})' \cdot \mathbf{D}_n \cdot \mathbf{1}_n = \begin{pmatrix} f_{\cdot 1} \\ f_{\cdot 2} \\ \vdots \\ f_{\cdot p} \end{pmatrix}, \quad \mathbf{x}_{G_c} = (\mathbf{D}_p^{-1} \mathbf{F})' \cdot \mathbf{D}_p \cdot \mathbf{1}_p = \begin{pmatrix} f_{1 \cdot} \\ f_{2 \cdot} \\ \vdots \\ f_{n \cdot} \end{pmatrix}.$$

2. Din definiție $I_{G_l} = \sum_i p_i d^2(i, G_l)$ respectiv $I_{G_c} = \sum_j p_j d^2(j, G_c)$, deci

$$I_{G_l} = \sum_i f_{i \cdot} d_{\chi}^2(i, G_l) = \sum_i \sum_j f_{i \cdot} \cdot \frac{1}{f_{\cdot j}} \left(\frac{f_{ij}}{f_{i \cdot}} - f_{\cdot j} \right)^2 = \sum_i \sum_j \frac{(f_{ij} - f_{i \cdot} f_{\cdot j})^2}{f_{i \cdot} f_{\cdot j}}$$

respectiv

$$I_{G_c} = \sum_j f_{\cdot j} d_{\chi}^2(j, G_c) = \sum_j \sum_i f_{\cdot j} \cdot \frac{1}{f_{i \cdot}} \left(\frac{f_{ij}}{f_{\cdot j}} - f_{i \cdot} \right)^2 = \sum_j \sum_i \frac{(f_{ij} - f_{i \cdot} f_{\cdot j})^2}{f_{i \cdot} f_{\cdot j}}.$$

■

Reamintim că două variabile aleatoare discrete, luînd n , respectiv p valori, cu distribuția de probabilitate comună $\{p_{ij}\}_{i=1, n}^{j=1, p}$ și distribuțiile marginale $\{p_{i \cdot}\}$ respectiv $\{p_{\cdot j}\}$ sunt independente dacă și numai dacă $p_{ij} = p_{i \cdot} \cdot p_{\cdot j}$, ceea ce se traduce în termeni de estimății empirice ale acestor distribuții în

$$f_{ij} = f_{i \cdot} \cdot f_{\cdot j}.$$

Statistica testului

$$H_0 : p_{ij} = p_{i \cdot} \cdot p_{\cdot j} \quad (\forall) i, j$$

$$H_A : (\exists) i_1 \text{ astfel încât } p_{i_1 j} \neq p_{i_1 \cdot} \cdot p_{\cdot j}$$

este $X^2 = k \cdot \sum_i \sum_j \frac{(f_{ij} - f_{i \cdot} f_{\cdot j})^2}{f_{i \cdot} f_{\cdot j}}$ care, conform demonstrației lui K. Pearson,

$\sim \chi_{(n-1)(p-1)}^2$ dacă volumul de selecție pe baza căruia au fost estimate f_{ij} , adică k , tinde la ∞ . Aceasta este motivația pentru care distanța folosită în ACS se numește χ^2 și măsoară cât de „independente” din punct de vedere statistic sunt liniile față de coloanele tabelului de contingență $\mathbf{K}$ și reciproc.

1.3.1.3. CRITERIUL DE MAXIMIZAT ȘI MATRICEA DE DIAGONALIZAT

Dorim să reprezentăm grafic proximitatea între profile. Ne plasăm, pe rînd, în cele două spații, în centrul de greutate al norului corespunzător. Este o particularitate a ACS, în comparație cu ACP, echivalența dintre analiza generală realizată pe tabloul necentrat (adică cu originea în $\mathbf{O}$) și cea realizată

pe tabloul centrat (adică cu originea în G) cu condiția să neglijăm, în primul caz, axa factorială care unește pe $\mathbf{O}$ cu G (această axă este asociată valorii proprii egală cu unu, numită valoare proprie trivială). Pentru simplificarea calculelor vom întreprinde analiza generală pe tabloul necentrat în $\mathbb{R}^p$ - spațiul profilurilor-linie.

Conform celor anterioare

$$\left\{ \begin{array}{l} \max_u \left\{ \sum_i f_i \cdot d^2(i, 0) \right\} \\ \mathbf{u}' \mathbf{D}_p^{-1} \mathbf{u} = 1 \end{array} \right\}$$

$$\Rightarrow \mathbf{u} \text{ este vector propriu al matricii } \mathbf{S} = \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{F} \mathbf{D}_p^{-1}, \text{ asociat } \left[\begin{array}{l} \mathbf{u}' \mathbf{M} \mathbf{u} = 1 \\ \mathbf{X}' \mathbf{N} \mathbf{X} \mathbf{M} \mathbf{u} = \lambda \mathbf{u} \\ \boldsymbol{\Psi} = \mathbf{X}' \mathbf{M} \mathbf{u} \end{array} \right]$$

cele mai mari valori proprii $\lambda \neq 1$.

Analog, în $\mathbb{R}^n$

$$\left\{ \begin{array}{l} \max_v \left\{ \sum_j f_j \cdot d^2(j, 0) \right\} \\ \mathbf{v}' \mathbf{D}_n^{-1} \mathbf{v} = 1 \end{array} \right\}, \left[\begin{array}{l} \mathbf{v}' \mathbf{M} \mathbf{v} = 1 \\ \mathbf{X}' \mathbf{N} \mathbf{X} \mathbf{M} \mathbf{v} = \lambda \mathbf{v} \\ \boldsymbol{\varphi} = \mathbf{X} \mathbf{M} \mathbf{v} \end{array} \right]$$

$\Rightarrow \mathbf{v}$ este vector propriu al matricii $\mathbf{T} = \mathbf{F} \mathbf{D}_p^{-1} \mathbf{F}' \mathbf{D}_n^{-1}$ asociat celei mai mari valori proprii $\lambda \neq 1$.

Propoziția 1.3.2

ACS pe tabloul centrat este echivalentă cu ACS pe tabelul necentrat.

Demonstrație. Pentru fixarea ideilor să raționăm în $\mathbb{R}^p$.

În cazul tabelului necentrat, se observă că

$$\mathbf{x}'_{G_l} \cdot \underbrace{\mathbf{D}_p^{-1}}_{\mathbf{M}} \cdot \mathbf{x}_{G_l} = 1 \quad (1)$$

$$\text{deoarece } \mathbf{D}_p^{-1} \cdot \mathbf{x}_{G_l} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \begin{array}{c} \uparrow \\ p \\ \downarrow \end{array} \text{ și } \mathbf{x}'_{G_l} \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} = \sum_{j=1}^p f_j = 1,$$

$$\text{și că } \mathbf{S} \cdot \mathbf{x}_{G_l} = \mathbf{x}_{G_l}, \quad (2)$$

$$\text{deoarece } \mathbf{S} = \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{F} \mathbf{D}_p^{-1} \Rightarrow s_{jj'} = \sum_i \frac{f_{ij} f_{ij'}}{f_i \cdot f_{j'}}$$

$$\text{iar } \sum_{j'} s_{jj'} \cdot \mathbf{x}_{G_l}^{j'} = \sum_j \sum_i \frac{f_{ij} f_{ij'}}{f_i \cdot f_{j'}} \cdot f_{j'} = \sum_i \frac{f_{ij}}{f_i} \sum_{j'} f_{ij'} = f_{\cdot j} = \mathbf{x}_{G_l}^j$$

altfel spus, $\mathbf{x}_{G_l}$ este vector propriu $\mathbf{M}$ -normat al matricii $\mathbf{S}$, asociat valorii proprii $\lambda_1 = 1$. Să îl notăm cu $\mathbf{u}_1 = \mathbf{x}_{G_l}$. Din construcția spațiului H

$$\mathbf{u}'_1 \mathbf{M} \mathbf{u}_\alpha = 0, \quad \alpha = \overline{2, p}$$

unde

$$\begin{cases} \mathbf{u}'_{\alpha} \mathbf{M} \mathbf{u}_{\alpha} = 1 \\ \mathbf{S} \mathbf{u}_{\alpha} = \lambda_{\alpha} \cdot \mathbf{u}_{\alpha} \end{cases}.$$

În cazul tabelului centrat, se notează cu $\mathbf{S}^{\circ}$ matricea obținută prin centrarea tabelului $\mathbf{X}$. Se observă că

$$\begin{aligned} \mathbf{S}^{\circ} &= \mathbf{S} - \mathbf{x}_{G_l} \cdot \mathbf{x}'_{G_l} \cdot \mathbf{D}_p^{-1} = \mathbf{S} - \mathbf{u}_1 \mathbf{u}'_1 \mathbf{M}, \\ \mathbf{S}^{\circ} \mathbf{u}_{\alpha} &= \mathbf{S} \mathbf{u}_{\alpha} - \mathbf{u}_1 \mathbf{u}'_1 \mathbf{M} \mathbf{u}_{\alpha} = \mathbf{S} \mathbf{u}_{\alpha} = \lambda_{\alpha} \cdot \mathbf{u}_{\alpha}, \quad \alpha = \overline{2, p} \\ \mathbf{S}^{\circ} \mathbf{u}_1 &= \mathbf{S} \mathbf{u}_1 - \mathbf{u}_1 \mathbf{u}'_1 \mathbf{M} \mathbf{u}_1 = \mathbf{u}_1 - \mathbf{u}_1 = \mathbf{0} = \mathbf{0} \cdot \mathbf{u}_1. \end{aligned}$$

Așadar

$$\begin{aligned} \mathbf{u}_{\alpha}^{\circ} &= \mathbf{u}_{\alpha+1} \text{ și } \lambda_{\alpha}^{\circ} = \lambda_{\alpha+1}, \quad \alpha = \overline{1, p-1} \\ \mathbf{u}_p^{\circ} &= \mathbf{u}_1 \text{ și } \lambda_p^{\circ} = 0 \text{ și } \lambda_1 = 1. \end{aligned}$$

Așadar în $\mathbb{R}^p$, analog în $\mathbb{R}^n$, ACS pe tabloul centrat cu termenul general $\frac{f_{ij}}{f_{i.}} - f_{.j}$ este echivalentă cu ACS pe tabloul cu termenul general $\frac{f_{ij}}{f_{i.}}$. ■

Observația 1.3.2

- a) În ACS punctele sunt conținute în hiperplanul $\mathcal{H}$ de dimensiune $p-1$ (pentru $\mathbb{R}^p$) datorită faptului că $\sum_i \frac{f_{ij}}{f_{i.}} = 1$, $(\forall) i = \overline{1, n}$.
- b) i) Cum $\sum_j \mathbf{x}_{G_l}^j = \sum_j f_{.j} = 1 \Rightarrow G_l \in \mathcal{H}$.
- ii) $\mathbf{x}_{G_l}' \mathbf{M} \mathbf{x}_{G_l} = 1 \Rightarrow G_l$ se află la distanța 1 de origine. Cum $\langle OG_l, \mathbf{x}_{G_l} \rangle = 0$ (deoarece $(\mathbf{x} - \mathbf{x}_{G_l}) \mathbf{M} \mathbf{x}_{G_l} = \sum_j x_j - \sum_j x_{G_l}^j$ căci $\mathbf{x} \in \mathcal{H}$ deci $\sum_j x_j = 1$) $\Rightarrow OG_l \perp \mathcal{H}$.




FIG. 1.3.5. ANALIZA ÎN $\mathbb{R}^3$

În analiza în raport cu originea, prima direcție $\mathbf{u}_1$ este axa ce leagă originea de centrul de greutate al norului și este ortonormală pe $\mathcal{H}$. Inerția proiectată pe această axă este 1, egală cu distanța dintre O și G_l deoarece toate punctele norului se proiectează pe această axă în același punct G_l . Următoarele $p-1$ axe $(\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_p)$ conținute în $\mathcal{H}$ constituie o bază, definind direcții de inerție maximă ale norului. Ele coincid cu primele $p-1$ axe ale ACS în raport cu G_l și $(\mathbf{u}_1^\circ, \mathbf{u}_2^\circ, \dots, \mathbf{u}_p^\circ)$. În această analiză, a p -a axă corespunde lui $\mathbf{u}_1 = OG_l$ și nu indică nicio direcție în $\mathcal{H}$ deoarece nu este conținută în $\mathcal{H}$. Inerția sa (valoarea proprie asociată) este nulă.

1.3.1.4 AXELE FACTORIALE

Presupunem că $p \ll n$. Conform analizei generale:

TABELUL 1.3.2. TABEL RECAPITULATIV CU ELEMENTELE DE BAZĂ ALE UNEI ACS

Elemente de bază	în $\mathbb{R}^p$	în $\mathbb{R}^n$
Matricea de diagonalizat	$\mathbf{S} = \mathbf{F}'\mathbf{D}_n^{-1}\mathbf{F}\mathbf{D}_p^{-1}$	$\mathbf{T} = \mathbf{F}\mathbf{D}_p^{-1}\mathbf{F}'\mathbf{D}_n^{-1}$
Axele factoriale	$\mathbf{S}\mathbf{u}_\alpha = \lambda_\alpha \mathbf{u}_\alpha$	$\mathbf{T}\mathbf{v}_\alpha = \lambda_\alpha \mathbf{v}_\alpha$
Coordonatele factoriale	$\Psi_\alpha = \mathbf{D}_n^{-1}\mathbf{F}\mathbf{D}_p^{-1}\mathbf{u}_\alpha$ $\Psi_{\alpha i} = \sum_j \frac{f_{ij}}{f_{i\cdot}f_{\cdot j}} u_{\alpha j}$	$\varphi_\alpha = \mathbf{D}_p^{-1}\mathbf{F}'\mathbf{D}_n^{-1}\mathbf{v}_\alpha$ $\varphi_{\alpha j} = \sum_i \frac{f_{ij}}{f_{i\cdot}f_{\cdot j}} v_{\alpha i}$

Lema 1.3.2

Coordonatele factoriale sunt **variabile** cu media empirică 0 și dispersia empirică λ_α .

Demonstrație. Datorită echivalenței dintre ACS necentrată și ACS centrată, media empirică este

$$\begin{aligned}
 \sum_i f_{i\cdot} \Psi_{\alpha i} &= \sum_i f_{i\cdot} \sum_j \left(\frac{f_{ij}}{f_{i\cdot}} - f_{\cdot j} \right) \frac{1}{f_{\cdot j}} u_{\alpha j} = \\
 &= \sum_i f_{i\cdot} \sum_j \frac{f_{ij}}{f_{i\cdot}f_{\cdot j}} u_{\alpha j} - \sum_i f_{i\cdot} \sum_j u_{\alpha j} = \\
 &= \sum_j \left(\sum_i f_{ij} \right) \frac{u_{\alpha j}}{f_{\cdot j}} - \sum_j u_{\alpha j} = 0.
 \end{aligned}$$

Deci, conform definiției dispersiei empirice,

$$\begin{aligned}
 \sum_i f_{i\cdot} \Psi_{\alpha i}^2 &= \Psi_{\alpha}' \mathbf{D}_n \Psi_{\alpha} = \mathbf{u}_{\alpha}' \mathbf{D}_p^{-1} \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{D}_n \mathbf{D}_n^{-1} \mathbf{F} \mathbf{D}_p^{-1} \mathbf{u}_{\alpha} = \\
 &= \mathbf{u}_{\alpha}' \mathbf{D}_p^{-1} \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{F} \mathbf{D}_p^{-1} \mathbf{u}_{\alpha} = \mathbf{u}_{\alpha}' \mathbf{D}_p^{-1} \mathbf{S} \mathbf{u}_{\alpha} = \\
 &= \mathbf{u}_{\alpha}' \mathbf{D}_p^{-1} \lambda_{\alpha} \mathbf{u}_{\alpha} = \lambda_{\alpha} \underbrace{\mathbf{u}_{\alpha}' \mathbf{D}_p^{-1} \mathbf{u}_{\alpha}}_1 = \lambda_{\alpha}
 \end{aligned}$$

Analog pentru $\sum_j f_{\cdot j} \varphi_{\alpha j}^2 = \lambda_{\alpha}$. ■

1.3.1.4 RELAȚIILE DINTRE CELE DOUĂ SPAȚII

Analiza generală a arătat că matricile $\mathbf{S}$ și $\mathbf{T}$ au aceleași valori proprii nenule și că între vectorii proprii normați $\mathbf{u}_{\alpha}$ ai lui $\mathbf{S}$ asociați lui λ_{α} și vectorii proprii normați $\mathbf{v}_{\alpha}$ ai lui $\mathbf{T}$ asociați aceleași valori proprii există relațiile:

$$\begin{aligned}
 \mathbf{v}_{\alpha} &= \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{F} \mathbf{D}_p^{-1} \mathbf{u}_{\alpha}, \\
 \mathbf{u}_{\alpha} &= \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{v}_{\alpha}.
 \end{aligned}$$

Înlocuind în formulele coordonatelor factoriale:

$$\begin{aligned}
 \Psi_{\alpha} &= \sqrt{\lambda_{\alpha}} \mathbf{D}_n^{-1} \mathbf{v}_{\alpha} \text{ (pe componentele } \Psi_{\alpha i} = \frac{\sqrt{\lambda_{\alpha}}}{f_{i\cdot}} v_{\alpha i}) \Rightarrow \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{D}_n \Psi_{\alpha} = \mathbf{v}_{\alpha}, \\
 \varphi_{\alpha} &= \sqrt{\lambda_{\alpha}} \mathbf{D}_p^{-1} \mathbf{u}_{\alpha} \text{ (pe componentele } \varphi_{\alpha j} = \frac{\sqrt{\lambda_{\alpha}}}{f_{\cdot j}} u_{\alpha j}) \Rightarrow \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{D}_p \varphi_{\alpha} = \mathbf{u}_{\alpha},
 \end{aligned}$$

care înlocuite în formulele coordonatelor factoriale dau **formulele quasi-baricentrice**

$$\begin{aligned}
 \Psi_{\alpha} &= \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{D}_n^{-1} \mathbf{F} \varphi_{\alpha} \text{ cu } \Psi_{\alpha i} = \frac{1}{\sqrt{\lambda_{\alpha}}} \sum_{j=1}^p \frac{f_{ij}}{f_{i\cdot}} \varphi_{\alpha j}, \\
 \varphi_{\alpha} &= \frac{1}{\sqrt{\lambda_{\alpha}}} \mathbf{D}_p^{-1} \mathbf{F} \Psi_{\alpha} \text{ cu } \varphi_{\alpha j} = \frac{1}{\sqrt{\lambda_{\alpha}}} \sum_{i=1}^n \frac{f_{ij}}{f_{\cdot j}} \Psi_{\alpha i}.
 \end{aligned}$$

Astfel, modulo coeficientul de dilatație $\frac{1}{\sqrt{\lambda_{\alpha}}}$, **proiecțiile punctelor unui nor sunt, pe o axă, coordonatele baricentrice ale proiecțiilor punctelor celuilalt nor.**

Matricea cu termenul general $\left\{ \frac{f_{ij}}{f_{i\cdot}} \right\}_{i=1, n}^{j=1, p}$ ce permite calculul coordonatelor unui punct i pe baza tuturor punctelor j nu este alta decât matricea profilurilor linie. Coordonata modalității i a unei variabile reprezintă media modalităților j ale celeilalte variabile, ponderate de frecvențele condiționate ale profilului i . Analog, coordonata modalității j reprezintă media mulțimii modalităților i ponderate de frecvențele condiționate ale profilului j .

Lema 1.3.3

Valorile proprii λ_α sunt subunitare ($\lambda_\alpha \leq 1, (\forall) \alpha$).

Demonstrație. Din $\Psi_{\alpha i} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{j=1}^p \frac{f_{ij}}{f_{i\cdot}} \varphi_{\alpha j} \Rightarrow \sqrt{\lambda_\alpha} \Psi_{\alpha i} = \sum_{j=1}^p \frac{f_{ij}}{f_{i\cdot}} \varphi_{\alpha j} \Rightarrow$

$$\min_j \{ \varphi_{\alpha j} \} \underbrace{\sum_{j=1}^p \frac{f_{ij}}{f_{i\cdot}}}_1 \leq \sqrt{\lambda_\alpha} \Psi_{\alpha i} \leq \max_j \{ \varphi_{\alpha j} \} \underbrace{\sum_{j=1}^p \frac{f_{ij}}{f_{i\cdot}}}_1 \Rightarrow$$

$$\max_i \left(\sqrt{\lambda_\alpha} \Psi_{\alpha i} \right) \leq \max_j \left(\varphi_{\alpha j} \right). \quad (1)$$

Analog

$$\max_j \left(\sqrt{\lambda_\alpha} \varphi_{\alpha j} \right) \leq \max_i \left(\Psi_{\alpha i} \right). \quad (2)$$

Cum $\lambda_\alpha \geq 0$, din (1) și (2) $\Rightarrow \max_j \left(\sqrt{\lambda_\alpha} \varphi_{\alpha j} \right) \leq \max_j \left(\varphi_{\alpha j} \right) \Rightarrow \lambda_\alpha \leq 1$. ■

Relațiile quasi-baricentrice justifică **reprezentarea simultană** a liniilor și a coloanelor.




FIG. 1.3.6. SCHEMA REPREZENTĂRII SIMULTANE

Rămîne în continuare valabilă observația de la ACP legată de faptul că distanța dintre un punct-linie și un punct-coloană este lipsită de sens deoarece acestea se situează în spații diferite. ACS oferă totuși posibilitatea de a





poziționa și interpreta un punct dintr-un nor în raport cu punctele din celălalt nor.

1.3.2 Reguli de interpretare a rezultatelor

Inerția Măsurînd distanța de la independența statistică, $I_G \approx 0$ și $\lambda_1 \geq \lambda_2$ semnifică puncte grupate în jurul lui G într-o formă aproximativ circulară (nu există direcție privilegiată) generată de profile independente statistic.

Dacă

$$\begin{aligned}\lambda_1 &\rightarrow 1 \Rightarrow \text{o dihotomie a punctelor,} \\ \lambda_2 &\rightarrow 1 \Rightarrow 3 \text{ subnori,} \\ \lambda_1, \lambda_2, \dots, \lambda_p &\rightarrow 1 \Rightarrow \text{există o corespondență aproape} \\ &\quad \text{biunivocă între modalitățile variabilelor.}\end{aligned}$$

Inerție slabă	 1. INDEPENDENȚĂ · $I_G \approx 0$ · $\lambda_1 \geq \lambda_2$	 2. DEPENDENȚĂ · $I_G \approx 0$ · $\lambda_1 \gg \lambda_2$
Inerție mare	 3. DEPENDENȚĂ · $I_G > 0$ · $\lambda_1 \geq \lambda_2$	 4. DEPENDENȚĂ · $I_G > 0$ · $\lambda_1 \gg \lambda_2$
	Formă "sferică"	Formă "nesferică"

Să considerăm câteva forme clasice de nori de puncte pentru a arăta cum poate fi reorganizat tabelul de date corespunzător, pornind de la proiecția acestora.

În cazul norului de puncte împărțit în doi subnori, tabelul de date poate fi reorganizat prin ordonarea coordonatelor liniilor și coloanelor pe primul factor. Se obține schematic figura 1.3.7.:




FIG. 1.3.7. NORUL DE PUNCTE ÎMPĂRȚIT ÎN DOUĂ.

Pot exista situații în care analiza separată a celor doi subnori definiți de tabelele corespunzătoare (I_1, J_1) și (I_2, J_2) să fie interesantă.

În cazul norului de puncte împărțit în trei subnori, tabelul de date poate fi reorganizat analog prin permutarea liniilor și coloanelor. El poate face de asemenea obiectul unor ACS separate.




FIG 1.3.8. NORUL DE PUNCTE ÎMPĂRȚIT ÎN TREI

Se poate întâlni situația în care norul de puncte are o formă parabolică. Permutând liniile și coloanele, tabelul poate fi reordonat sub forma unei matrici diagonale relativ încărcate:




FIG 1.3.9. EFECTUL GUTTMAN ȘI STRUCTURA POSIBILĂ A TABELULUI

Această situație pune în evidență **efectul Guttman** care corespunde unei redundanțe a celor două variabile: cunoașterea liniei i permite deducerea coloanei j . Toată informația este dată aproape în totalitate de primul factor.

Matricea asociată tabelului nu este, totuși, de rang 1 și dispunem de $p-1$ factori. Al doilea factor este o funcție de ordinul doi de primul factor, al treilea factor este o funcție de ordinul trei, etc. Informația dată de axele de rang superior traduce același fenomen, totuși examinarea celui de-al doilea factor rafinează interpretarea primului factor (conform [61]).

În general efectul Guttman apare atunci când variabilele sunt ordonate (variabile continue transformate în variabile nominale). O axă, adesea prima, opune valorile extreme iar o altă axă opune valorile intermediare valorilor extreme. Uneori, efectul Guttman pune în evidență o structură neliniară care poate fi interesantă dacă forma parabolică nu este perfectă. Punctele de rup-tură sunt, în acest caz, interesante.

Inerția (dispersia) explicată de un factor $\lambda_\alpha = \sum_i f_i \cdot \Psi_{\alpha i}^2 \Rightarrow Cr_\alpha(i) = \frac{f_i \cdot \Psi_{\alpha i}^2}{\lambda_\alpha}$, $(\forall) i = \overline{1, n}$ în $\mathbb{R}^p$ reprezintă contribuția elementului i la axa α ($f_i \cdot \Psi_{\alpha i}^2 =$ dispersia individului, $\lambda_\alpha =$ dispersia întregii axe).

Analog $Cr_\alpha(j) = \frac{f_j \cdot \varphi_{\alpha j}^2}{\lambda_\alpha}$, $(\forall) j = \overline{1, p}$ în $\mathbb{R}^n$.





FIG. 1.3.10. CONTRIBUȚIA LA AXA α : TREI SITUAȚII POSIBILE

Calitatea reprezentării unui punct Din definiție $d_\alpha^2(i, G) = \Psi_{\alpha i}^2$. Cum în ACS punctele se află în spațiul $\mathcal{H}$ de dimensiune $p-1 \Rightarrow \sum_\alpha d_\alpha^2(i, G) = d^2(i, G)$.


Un punct i din $\mathbb{R}^p$ poate fi mai aproape sau mai departe de axa α . Proximitatea între două puncte proiectate pe axa α este cu atât mai bine reflectată cu cât aceste puncte sunt mai apropiate de axa pe care sunt proiectate.

FIG. 1.3.11. PROIECȚIA PUNCTULUI i PE AXA α

Calitatea reprezentării unui punct i pe axa α poate fi evaluată de:

$$\cos_{\alpha}^2(i) = \frac{d_{\alpha}^2(i, G)}{d^2(i, G)}$$

Această cantitate, numită *cosinusul pătrat*, reprezintă *contribuția relativă a factorului α la poziția punctului i* . Cu cât cosinusul pătrat este mai apropiat de 1 cu atât proiecția punctului este mai aproape de poziția acestuia în spațiu.

FIG. 1.3.1.2. CALITATEA REPREZENTĂRII UNUI PUNCT i PE AXA α

Din definiție rezultă că $\sum_{\alpha} \cos_{\alpha}^2(i) = 1, (\forall) i$ puncte active.

Cosinusul pătrat pentru un *element ilustrativ* este subunitar dacă acesta aparține lui $\mathbb{R}^p$. În ACS *elementele active* aparțin lui $\mathbb{R}^{p-1}$.

1.3.3 Exemplu

Descrierea datelor

Un exemplu de aplicare a metodei analizei corespondențelor simple îl constituie identificarea și descrierea unor afinități între diverse categorii socioprofesionale și diverse tipuri de media. Studiul a fost realizat pe 4433 de persoane ce ilustrează categoriile socioprofesionale menționate mai jos și care

1.4 Analiza corespondențelor multiple (ACM)

Analiza corespondențelor multiple (ACM) este o generalizare posibilă a analizei de corespondență.

Numele apare într-o lucrare a lui Lebart [40] dar principiile metodei urcă pînă la Guttman [31], Burt [8], Hayashi [36].

Sub numele de *Homogeneity Analysis* este dezvoltată de echipa lui J. De Leeuw începând cu 1973, iar sub numele de *Dual Scaling* de către Nishisato [49].

Se notează cu:

- s - numărul întrebărilor puse la n indivizi;
- p_q - numărul modalităților întrebării q , $q = \overline{1, s}$;
- $\mathbf{R} = (r_{iq})_{i=\overline{1, n}}^{q=\overline{1, s}}$ - tabelul de date condensat, unde r_{iq} = numărul modalității întrebării q aleasă de individul i , deci $r_{iq} \leq p_q$.

Ipoteza fundamentală: *Modalitățile fiecărei întrebări se exclud reciproc, iar o modalitate este obligatoriu aleasă.*

Exemplul 1.4.1

La întrebarea " *Starea dvs. civilă este...* ", cu modalitățile

1. *celibatar*
2. *căsătorit sau trăind marital*
3. *văduv*
4. *divorțat*
5. *nu răspund*

există cinci modalități de răspuns ce satisfac ipoteza fundamentală

Un astfel de tabel (fig 1.4.1.) nu este exploatabil: sumele pe linii și pe coloane nu au niciun sens. Variabilele trebuie recodate.

	$s=3$		
1	2	2	4
	2	1	3
	3	1	2
	1	2	4
	1	2	3
	2	2	3
	3	1	1
	1	1	1
	2	1	2
	2	2	3
	3	2	2
n	1	1	4

FIG. 1.4.1 TABEL DE DATE SUB FORMĂ CODIFICATĂ CONDENSATĂ.

În acest sens se notează cu $p = \sum_{q=1}^s p_q$ numărul total de modalități ale celor s întrebări și se construiește, pornind de la $\mathbf{R}$ tabelul

$$\mathbf{Z} = [\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_q, \dots, \mathbf{Z}_s]$$

cu n linii și p coloane, tabel ce descrie cele s răspunsuri ale celor n indivizi printr-un codaj binar.

$\mathbf{Z}$ se obține din $\mathbf{R}$ astfel:

$$z_{ij,q} = \begin{cases} 1, & \text{dacă } r_{iq} \neq 0 \\ 0, & \text{altfel} \end{cases}$$

În notația de mai sus $\mathbf{Z}_q$ este un tabel $n \times p_q$ fiecare linie conținând $p_q - 1$ zerouri și un singur unu.

Definiția 1.4.1 Tabelul $\mathbf{Z}$ se numește *tabel disjunctiv complet*.




FIG. 1.4.2. CONSTRUCȚIA TABELULUI DISJUNCTIV COMPLET

Marjele tabelului $\mathbf{Z}$ sunt:

$$z_{i.} = \sum_{j=1}^p z_{ij,q} = s,$$

$$z_{.j} = \sum_{i=1}^n z_{ij,q} = \text{numărul de indivizi care au ales modalitatea } j \text{ a întrebării } q.$$

Rezultă

$$n = \sum_{j=1}^{p_q} z_{.j} = z_q \text{ și}$$

$$z = \sum_{i=1}^n z_{i.} = \sum_{q=1}^s z_q = \sum_{i=1}^n \sum_{j=1}^p z_{ij} = ns = \text{efectivul total.}$$

Definiția 1.4.2 $\mathbf{B} = \mathbf{Z}'\mathbf{Z}$ se numește *tabelul de contingență Burt* asociat tabelului disjunctiv complet $\mathbf{Z}$.

$$\text{Termenul general se scrie : } b_{jj'} = \sum_{i=1}^n z_{ij}z_{ij'}$$

$$\text{Marjele sunt : } b_j = \sum_{j'=1}^p b_{jj'} = s \cdot z_{.j}$$

$$\text{Efectivul total este : } b = \sum_{j=1}^p b_j = s^2 n.$$

Tabelul $\mathbf{B}$ este format din s^2 blocuri unde se disting:

- blocurile de tip $\mathbf{Z}'_q \times \mathbf{Z}_{q'}$ indexate de (q, q') , de dimensiune $p_q \times p_{q'}$, care se obțin prin “încrucișarea” răspunsurilor la întrebările q și q' ;
- blocurile de tip $\mathbf{Z}'_q \times \mathbf{Z}_q$, obținute prin “încrucișarea” răspunsurilor la aceeași întrebare.

Tabelul $\mathbf{B}$ este o matrice diagonală având în vedere că două modalități ale aceleiași întrebări nu pot fi alese simultan (datorită ipotezei fundamentale). Termenii de pe diagonală sunt efectivele $\{z_{.j}\}$ ale modalităților întrebării q .




FIG. 1.4.3. CONSTRUCȚIA TABELULUI BURT PORNIND DE LA TABELUL DISJUNCTIV COMPLET $\mathbf{Z}$

Se notează cu $\mathbf{D}$ matricea diagonală $p \times p$ definită de relațiile

$$\begin{aligned} d_{jj} &= b_{jj} = z_{.j} \\ d_{jj'} &= 0, \quad (\forall) \ j \neq j' \text{ cu } j, j' = \overline{1, p} \end{aligned}$$

Matricea $\mathbf{D}$ poate fi de asemenea considerată ca fiind formată din s^2 blocuri. Numai cele s matrici diagonale $\mathbf{D}_q = \mathbf{Z}'_q \mathbf{Z}_q$, $q = \overline{1, s}$ ce formează blocurile diagonale ale lui $\mathbf{B}$ sunt matrici nenule:

		$p=9$					$p=9$		
$\mathbf{B}_{(p,p)} =$	4 0 0 0 5 0 0 0 3	2 2 2 3 2 1	1 0 1 2 0 1 3 1 1 2 0 0				4 0 0 0 5 0 0 0 3	0 0 0 0 0 0	0 0 0 0 0 0 0 0 0 0 0 0
	2 2 2 2 3 1	6 0 0 6	2 2 1 1 0 1 3 2				0 0 0 0 0 0	6 0 0 6	0 0 0 0 0 0 0 0
	1 0 1 0 1 2 1 3 0 2 1 0	2 0 2 1 1 3 1 2	2 0 0 0 0 3 0 0 0 0 4 0 0 0 0 3				0 0 0 0 0 0 0 0 0 0 0 0	0 0 0 0 0 0 0 0	2 0 0 0 0 3 0 0 0 0 4 0 0 0 0 3

FIG. 1.4.4. TABLOUL BURT $\mathbf{B}$ ȘI MATRICEA DIAGONALĂ $\mathbf{D}$ ASOCIATĂ (DATELE SUNT DIN FIG. 1.4.1. ȘI DIN FIG. 1.4.2.)

1.4.1 Principiile ACM

Analiza corespondențelor multiple este analiza corespondențelor simple aplicată unui tabel disjunctiv complet.




FIG. 1.4.5. ANALIZA DE CORESPONDENȚĂ MULTIPLĂ

În consecință:

- se aplică aceleași transformări tabelului de date pentru obținerea profilurilor-linie/profilurilor-coloană;
- aceleași ponderi ale punctelor funcție de profilurile marginale;
- aceeași distanță, distanța χ^2 .

Așadar indivizii sunt toți afectați de o pondere identică, egală cu $m_i = \frac{z_{i.}}{ns} = \frac{1}{n}$, $i = \overline{1, n}$.

Fiecare modalitate j este ponderată de frecvența sa, $m_j = \frac{z_{.j}}{ns}$.

În $\mathbb{R}^n$ distanța χ^2 între modalități, pe un tabel disjunctiv se scrie:

$$d^2(j, j') = \sum_{i=1}^n n \left(\frac{z_{ij}}{z_{.j}} - \frac{z_{ij'}}{z_{.j'}} \right)^2$$

și este nulă dacă modalitățile j și j' sunt alese de aceeași indivizi. În plus, modalitățile de efectiv scăzut, adică cele alese de puțini indivizi, sunt depărtate față de celelalte modalități.

În $\mathbb{R}^p$ distanța χ^2 între indivizi, pe un tabel disjunctiv, se scrie

$$d^2(i, i') = \frac{1}{s} \sum_{j=1}^p \frac{n}{z_{.j}} (z_{ij} - z_{i'j})^2$$

și este nulă dacă indivizii i și i' au ales aceleași modalități. Ei sunt cu atât mai depărtați cu cât au răspuns mai diferit.

În plus, trebuie observat că o modalitate j intervine în distanța dintre indivizi cu atât mai mult cu cât masa ei este mai mică.

Reluând rezultatele analizei de corespondență și notațiile adoptate rezultă:

$$\begin{aligned} \mathbf{F} &= \frac{1}{ns} \mathbf{Z}, \text{ cu termenul general } f_{ij} = \frac{z_{ij}}{ns}, \\ \mathbf{D}_p &= \frac{1}{ns} \mathbf{D}, \text{ cu termenul general } f_{.j} = \delta_{ij} \frac{z_{.j}}{ns}, \\ \mathbf{D}_n &= \frac{1}{n} \mathbf{I}_n, \text{ cu termenul general } f_{i.} = \frac{\delta_{ij}}{n}. \end{aligned}$$

Pentru a găsi axele factoriale $\mathbf{u}_\alpha$ se diagonalizează matricea

$$\mathbf{S} = \mathbf{F}' \mathbf{D}_n^{-1} \mathbf{F} \mathbf{D}_p^{-1} = \frac{1}{s} \mathbf{Z}' \mathbf{Z} \mathbf{D}^{-1}$$

cu termenul general (**atenție!** s neindexat semnifică, în acest subcapitol, numărul de întrebări)

$$s_{jj'} = \frac{1}{s \cdot z_{.j'}} \sum_{i=1}^n z_{ij} z_{ij'}.$$

În $\mathbb{R}^p$, ecuația celei de-a α -a axe factoriale $\mathbf{u}_\alpha$ este

$$\frac{1}{s} \mathbf{Z}' \mathbf{Z} \mathbf{D}^{-1} \mathbf{u}_\alpha = \lambda_\alpha \mathbf{u}_\alpha.$$

și ecuația celui de-al α -lea factor $\varphi_\alpha = \mathbf{D}^{-1} \mathbf{u}_\alpha$ (modulo o constantă) este

$$\frac{1}{s} \mathbf{D}^{-1} \mathbf{Z}' \mathbf{Z} \varphi_\alpha = \lambda_\alpha \varphi_\alpha.$$

Analog, în $\mathbb{R}^n$, ecuația celui de-al α -lea factor Ψ_α este

$$\frac{1}{s} \mathbf{Z} \mathbf{D}^{-1} \mathbf{Z}' \Psi_\alpha = \lambda_\alpha \Psi_\alpha.$$

Factorii φ_α și Ψ_α (de normă λ_α) reprezintă coordonatele punctelor linie și ale punctelor coloană pe axa factorială α .

Relațiile de tranziție între factorii φ_α și Ψ_α sunt:

$$\begin{aligned} \varphi_\alpha &= \frac{1}{\sqrt{\lambda_\alpha}} \mathbf{D}^{-1} \mathbf{Z}' \Psi_\alpha; \\ \Psi_\alpha &= \frac{1}{s \sqrt{\lambda_\alpha}} \mathbf{Z} \varphi_\alpha. \end{aligned}$$

Coordonatele factoriale ale individului i pe axa α sunt date de:

$$\Psi_{\alpha,i} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{j=1}^p \frac{z_{ij}}{z_{i\cdot}} \varphi_{\alpha,j} = \frac{1}{s \sqrt{\lambda_\alpha}} \sum_{j \in p(i)} \varphi_{\alpha,j}$$

unde $p(i)$ desemnează mulțimea modalităților alese de individul i .

Corolarul 1.4.1

Modulo coeficientul $\frac{1}{\sqrt{\lambda_\alpha}}$ individul i se găsește proiectat în planul factorial principal în centrul de greutate (punctul de coordonate media aritmetică) al modalităților pe care le-a ales.

Analog, coordonatele factoriale ale modalității j pe axa α sunt date de:

$$\varphi_{\alpha,j} = \frac{1}{\sqrt{\lambda_\alpha}} \sum_{i=1}^n \frac{z_{ij}}{z_{\cdot j}} \Psi_{\alpha,i} = \frac{1}{z_{\cdot j} \sqrt{\lambda_\alpha}} \sum_{i \in n(j)} \Psi_{\alpha,i}$$

unde $n(j)$ desemnează mulțimea indivizilor care au ales modalitatea j .

Observația 1.4.1

În formulele de mai sus, modalitățile/indivizii nu sunt ponderați; coordonatele sunt simple medii aritmetice.

Norul modalităților din $\mathbb{R}^n$ poate fi descompus în s submulțimi, a q -a submulțime (subnor) corespunzând mulțimii p_q a modalităților variabilei q .

Corolarul 1.4.2

Centrele de greutate ale celor s submulțimi ale norului modalităților din $\mathbb{R}^n$ coincid cu centrul de greutate al norului global.

Demonstrație. Într-adevăr, coordonatele punctelor subnorului relativ la variabila q sunt coordonatele lui $\mathbf{Z}_q \mathbf{D}_q^{-1}$ iar elementele de pe diagonala principală a lui $\frac{1}{n} \mathbf{D}_q$ sunt masele relative ale celor p_q puncte ale subnorului.

Deoarece $\sum_{j \in p(q)} z_{ij} = 1$, a i -a componentă a centrului de greutate al subnorului este

$$G_{q,i} = \sum_{j \in p(q)} \frac{d_{jj}}{n} \cdot \frac{z_{ij}}{d_{jj}} = \frac{1}{n} = G_i,$$

unde $p(q)$ desemnează mulțimea modalităților variabilei nominale q . Rezultă că $G_{q,i}$ nu depinde de q . ■

Observația 1.4.2

1. Dacă tabelul $\mathbf{Z}$ nu este complet disjunctiv, adică dacă pentru cel puțin un individ nicio modalitate a unei întrebări nu a fost aleasă, modalitățile acelei variabile nu mai sunt centrate în centrul de greutate al norului global.
2. Codificarea disjunctivă completă permite transformarea unei variabile continue într-o variabilă nominală ale cărei modalități sunt clase ordonate. În această situație este util să se traseze traiectoria care poate sugera legături neliniare între această variabilă și axele factoriale.

Coordonatele modalităților în $\mathbb{R}^n$ sunt coloanele tabelului $\mathbf{ZD}^{-1}$. Acestea generează un subspațiu a cărui dimensiune este rangul lui $\mathbf{ZD}^{-1}$, deci rangul lui $\mathbf{Z} = [\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_q, \dots, \mathbf{Z}_s]$. Reamintim că toate subspațiile generate de coloanele lui $\mathbf{Z}_q$, $q = \overline{1, s}$ au în comun prima bisectoare, deoarece $\sum_{j \in p(q)} z_{ij} = 1$. Rangul maxim al lui $\mathbf{Z}$ este deci

$$p_1 + (p_2 - 1) + \dots + (p_s - 1) = p - s + 1.$$

Rangul maxim al matricii de diagonalizat $\mathbf{D}^{-1} \mathbf{Z}' \mathbf{Z}$ va fi deci $p - s + 1$. Dar în analiza norului în raport cu originea $\mathbf{O}$, prima bisectoare este vectorul propriu corespunzând valorii proprii $\mathbf{1}$.

În analiza în raport cu centrul de greutate $\mathbf{G}$ vor fi găsite deci $p - s$ valori proprii nenule. Alegând o bază în suportul norului, ne putem restrânge la a căuta valorile proprii ale unei matrici de ordin $p - s$.

1.4.2 Calculul inerției

Distanța de la o modalitate j la centrul de greutate G este

$$\begin{aligned}
 d^2(j, G) &= (j - G)' \mathbf{D}_n^{-1} (j - G) = n \sum_{i=1}^n \left(\frac{z_{ij}}{z_{.j}} - \frac{1}{n} \right)^2 = \\
 &= n \left[\sum_{i=1}^n \frac{z_{ij}^2}{z_{.j}^2} - 2 \frac{1}{n} \sum_{i=1}^n \frac{z_{ij}}{z_{.j}} + \frac{1}{n^2} \sum_{i=1}^n 1 \right] = \\
 &= n \left[\frac{1}{z_{.j}^2} \sum_{i=1}^n z_{ij}^2 - 2 \cdot \frac{1}{n} \cdot \frac{1}{z_{.j}} \sum_{i=1}^n z_{ij} + \frac{1}{n^2} n \right] = \\
 &= n \left(\frac{1}{z_{.j}} - 2 \frac{1}{n} + \frac{1}{n} \right) = \frac{n}{z_{.j}} - 1
 \end{aligned}$$

deoarece $z_{ij}^2 = z_{ij}$ și $\sum_{i=1}^n z_{ij} = z_{.j}$.

Inerția $I(j)$ a unei modalități j este, prin definiție:

$$I(j) = m_j d^2(j, G) \text{ cu } m_j = \frac{z_{.j}}{ns}$$

rezultă

$$I(j) = \frac{1}{s} \left(1 - \frac{z_{.j}}{n} \right).$$

Corolarul 1.4.3

Inerția unei modalități este cu atât mai mare cu cât efectivul $z_{.j}$ al acestei modalități, adică numărul de indivizi care au ales-o, este mai mic.

Maximul $\frac{1}{s}$ va fi atins pentru modalitățile de efectiv nul. În consecință, se va evita în momentul codificării, introducerea unor modalități susceptibile de a fi alese de puțini indivizi, tocmai pentru a nu introduce perturbații în primele axe factoriale.

Inerția $I(q)$ a unei întrebări q este, prin definiție,

$$I(q) = \sum_{j=1}^{p_q} I(j) = \frac{1}{s} (p_q - 1).$$

Corolarul 1.4.4

Inerția unei întrebări este cu atât mai mare cu cât numărul de modalități asociat, p_q , este mai mare. Minimul $\frac{1}{s}$ este atins de întrebările cu doar două modalități de răspuns. În consecință, dacă se dorește ca toate întrebările să joace un rol aproximativ egal atunci se va echilibra sistemul de întrebări (variabilele vor fi “decupate” într-un număr egal de modalități).

Inerția totală este

$$I = \sum_{q=1}^s I(q) = \sum_{j=1}^p \frac{z_{.j}}{ns} d^2(j, G) = \frac{p}{s} - 1, \text{ deoarece } \sum_{q=1}^s p_q = p$$

În particular $I = 1$ dacă toate întrebările au două modalități de răspuns, adică $p = 2s$.

În consecință depinzînd exclusiv de numărul de întrebări și de modalitățile asociate acestora, inerția globală nu are, în cazul ACM (ca și în cazul ACP normat, de altfel), nicio semnificație statistică, deoarece nu depinde de legătura între variabile.

1.4.3 Reguli de interpretare

A spune că există afinități între răspunsuri este același lucru cu a spune că există indivizi care au profile asemănătoare din punct de vedere al atributelor alese spre a-i descrie. Ținînd cont de distanțele între elementele tabelului disjunctiv complet și de relațiile baricentrice particulare se poate afirma că:

- Proximitatea între indivizi semnifică faptul că au ales global aceleași modalități ca răspuns la întrebările puse.
- Proximitatea între modalități ale unor întrebări diferite semnifică faptul că ele au fost alese ca răspuns de grupe de indivizi asemănători (căci așa cum s-a demonstrat mai sus, ele corespund centrelor de greutate ale acelor grupe de indivizi).
- Proximitatea între modalitățile aceleiași întrebări semnifică faptul că grupele de indivizi care le-au ales sunt asemănătoare (din construcție, modalitățile unei aceleiași variabile se exclud).

Regulile de interpretare a rezultatelor (coordonate, contribuții, cosinus pătrat) privind elementele active ale unei ACM sunt asemănătoare cu cele corespunzătoare unei ACS. În plus, se poate calcula **contribuția unei variabile-întrebări la factorul α** sumând contribuțiile modalităților acesteia la factorul respectiv:

$$Cr_{\alpha}(q) = \sum_{j \in p(q)} Cr_{\alpha}(j) = \sum_{j=1}^{p_q} \frac{z_{.j}}{ns} \cdot \frac{\varphi_{\alpha,j}^2}{\lambda_{\alpha}} = \frac{1}{ns\lambda_{\alpha}} \sum_{j=1}^{p_q} z_{.j} \varphi_{\alpha,j}^2$$

1.4.4 Principii de transformare a variabilei continue în variabilă discretă

Pentru a fi active într-o ACM, variabilele continue trebuie transformate în variabile nominale (discrete). În acest proces apar următoarele probleme:

Capitolul 2

METODE DE CLASIFICARE

Tehnicile de clasificare automată sunt destinate să producă grupări de linii sau de coloane ale unui tabel; este vorba, cel mai adesea, de obiecte sau indivizi descriși printr-un număr de variabile sau de caractere.

Circumstanțele utilizării acestor metode sunt analoage cu cele ale metodelor de analiză factorială descrise în capitolul 1: utilizatorul se găsește în fața unui tabel rectangular de valori numerice. Acest tabel poate fi un *tabel de variabile continue*, un *tabel de contingență* sau un *tabel de prezență-absență* (tabel ce conține valori de zero sau unu după cum un individ sau un obiect posedă sau nu un anumit caracter sau atribut). În anumite aplicații, utilizatorul poate dispune de un tabel pătrat, simetric, de similarități sau de distanțe.

Există mai multe familii de algoritmi de clasificare: algoritmi ce conduc direct la *partiții*, cum sunt metodele de *agregare în jurul centrilor mobili*, *algoritmi ascendenți* (sau algoritmi care construiesc clasele prin aglomerarea succesivă a câte două obiecte și care furnizează o ierarhie de repartiții de obiecte), în fine, *algoritmi descendenți* (sau divizivi) care procedează prin dihotomii succesive ale mulțimii obiectelor și care furnizează o ierarhie de partiții. Ne vom limita în această lucrare la primele două tehnici de clasificare:

- grupările se pot face prin căutarea directă a unei partiții, afectând elementele la centrii provizorii ai claselor, apoi prin recentrarea claselor și agregarea iterativă a elementelor. Este vorba de tehnicile de *agregare în jurul centrilor mobili*, tehnici înrudite cu *metoda norilor dinamici* sau *metoda k-means*, metode gratifiante în cazul tabelelor mari (secțiunea 2.1).
- grupările se pot face prin aglomerarea progresivă a elementelor două câte două. Este cazul clasificării ascendente ierarhice cu agregare după mai multe criterii. În lucrare sunt prezentate *tehnica saltului minimal*, echivalentă dintr-un anumit punct de vedere cu căutarea arborelui mini-

mal, și *tehnica agregării după dispersie*, interesantă prin compatibilitatea rezultatelor sale cu unele rezultate din analiza factorială (secțiunea 2.2).

Aceste tehnici prezintă avantaje diferite, dar pot fi utilizate și împreună. Este, astfel, posibilă o strategie de clasificare bazată pe un *algorithm mixt* bine adaptat partiționării mulțimilor formate din mii de indivizi (secțiunea 2.3).

Metodele de clasificare sau de tipologie (știința care le studiază se numește *taxonomie*) au ca scop regruparea indivizilor într-un număr restrâns de clase omogene. Este vorba deci, spre deosebire de demersul analizei factoriale, despre descrierea datelor procedând la o reducere a numărului de indivizi (față de o reducere a numărului de variabile).

În cele ce urmează se vor avea în vedere doar metodele de clasificare automată. Clasele vor fi obținute pe baza algoritmilor formalizați și nu prin metode subiective sau vizuale ce fac apel la inițiativa practicianului!

2.1 Generalități

În taxonomie, informația utilă se prezintă sub forma unui tabel $n \times n$, conținând distanțele sau disimilaritățile dintre cei n indivizi de clasificat.

Reamintim

Definiția 2.1.1 Fie $\mathbf{E}$ mulțimea celor n obiecte de clasificat. Se numește *distanță* o funcție $d : E \times E \rightarrow \mathbb{R}_+$, cu proprietățile:

1. $d(i, j) = d(j, i)$, $(\forall) i, j \in E$ (simetrică);
2. $d(i, j) \geq 0$, $(\forall) i, j \in E$ (pozitivă);
3. $d(i, j) = 0 \Leftrightarrow i = j$, $(\forall) i, j \in E$ (idempotentă);
4. $d(i, j) \leq d(i, k) + d(k, j)$, $(\forall) i, j, k \in E$ (tranzitivă).

Pentru ca o distanță să fie euclidiană ea trebuie să fie generată de un produs scalar.

Când datele sunt prezentate sub forma unui tabel $\mathbf{X}$ de n indivizi cu p caracteristici numerice, cele mai des utilizate distanțe sunt:

- distanța euclidiană clasică, cu metrica $\mathbf{M} = \mathbf{I}$;
- distanța euclidiană cu metrica $\mathbf{M} = \mathbf{D}_{\frac{1}{s^2}}$;
- distanța Mahanalobis, cu metrica $\mathbf{M} = \mathbf{V}^{-1}$;
- distanța L_1 în care $d(i, j) = \sum_k |x_i^k - x_j^k|$;

- distanța Minkowski, L_q , în care $d(i, j) = \left(\sum_k (x_i^k - x_j^k)^q \right)^{\frac{1}{q}}$.

Definiția 2.1.2 Se numește *similaritate* o funcție $s : E \times E \rightarrow \mathbb{R}_+$, cu proprietățile:

1. $s(i, j) = s(j, i)$, $(\forall) i, j \in E$ (simetrică);
2. $s(i, j) \geq 0$, $(\forall) i, j \in E$ (pozitivă);
3. $s(i, i) \geq s(i, j)$, $(\forall) i, j \in E$ (nu există un individ mai asemănător decât el însuși).

Definiția 2.1.3 Se numește *disimilaritate* o funcție $d : E \times E \rightarrow \mathbb{R}_+$, cu proprietățile:

1. $d(i, j) = d(j, i)$, $(\forall) i, j \in E$ (simetrică);
2. $d(i, j) \geq 0$, $(\forall) i, j \in E$ (pozitivă);
3. $d(i, i) = 0$, $(\forall) i, j \in E$.

O situație frecvent întâlnită este cea în care datele se prezintă sub forma următoare: n indivizi sunt descriși prin prezența/absența a p caracteristici (datele inițiale sunt, deci, sub formă binară).

Datele binare sunt "compactate" în n numere ce caracterizează fiecare cuplu de indivizi (deci 4 tabele $n \times n$) astfel:

- a = numărul de caracteristici comune;
- b = numărul de caracteristici posedate de i dar nu de j ;
- c = numărul de caracteristici posedate de j dar nu de i ;
- d = numărul de caracteristici neposedate nici de i și nici de j ;

Atenție! Cu toate că logic a și d sunt complementare, cele două numere nu joacă același rol pentru datele reale; de exemplu, faptul că două vegetale nu cresc în același loc, nu înseamnă în mod necesar că sunt asemănătoare.

Pe baza acestor 4 tabele se construiește tabelul de similaritate sau, prin complementare față de 1, tabelul de disimilaritate, utilizând diferiți indici:

- Jaccard: $\frac{a}{a+b+c}$;
- Dice: $\frac{2a}{2a+b+c}$;
- Ochiai: $\frac{a}{\sqrt{(a-b)(a+c)}}$;
- Russel și Rao: $\frac{a}{a+b+c+d}$;
- Rogers și Tanimoto: $\frac{a+d}{a+d+2(b+c)}$ etc.

2.2 Aspecte combinatorii ale clasificării

La prima vedere s-ar putea crede, deoarece $\mathbf{E}$ – mulțimea indivizilor de clasificat este finită ($\text{card}(\mathbf{E}) = n < \infty$), că problema clasificării este relativ facilă: se generează toate partițiile posibile iar apoi se alege aceea/acelea care satisface/satisfac un criteriu de optimalitate dat.

Din păcate, acest algoritm nu poate fi implementat încă în practică deoarece, chiar un calculator ce poate trata un milion de partiții pe secundă are nevoie de 126 de mii de ani pentru a putea genera toate partițiile unei mulțimi de numai 25 de indivizi!

Va trebui deci, în majoritatea situațiilor, să ne mulțumim cu soluții aproximative.

Se notează cu $P_{n,k}$ numărul de partiții în k clase a unei mulțimi de n elemente (numărul lui Stirling de speța a doua).

Se observă ușor că:

$$\begin{aligned} P_{n,1} &= 1 = P_{n,n}, \quad P_{n,n-1} = \frac{n(n-1)}{2} \\ P_{n,1} &= 2^{n-1} - 1. \end{aligned}$$

Se demonstrează prin inducție că:

$$P_{n,k} = P_{n-1,k-1} + kP_{n-1,k}.$$

Se poate, de asemenea, arăta că:

$$P_{n,k} = \frac{1}{k!} \sum_{i=1}^k C_k^i (-1)^{k-i} i^n$$

și deci, când $n \rightarrow \infty$, $P_{n,k} \approx \frac{k^n}{n!}$.

Se notează cu $P_n = \sum_{k=1}^n P_{n,k}$ numărul total de partiții ale unei mulțimi de n elemente (numerele lui Bell). Dacă se convine ca $P_0 = 1$, atunci se poate arăta prin inducție că

$$P_n = P_0 + (n-1)P_1 + C_{n+1}^2 P_2 + \dots + P_{n-1} \text{ și că } P_n = \frac{1}{e} \sum_{k=1}^{\infty} \frac{k^n}{n!}.$$

2.3 Metode de clasificare neierarhică

Aceste metode permit clasificarea rapidă a unor mulțimi destul de mari, optimizând local un criteriu de tip inerție.

Se presupune că:

- cei n indivizi sunt puncte dintr-un spațiu euclidian din $\mathbb{R}^p$, ceea ce permite definirea distanțelor euclidiene dintre indivizi;

- se dorește clasificarea indivizilor în k clase, unde k este cunoscut à priori.

Scopul fiecărei clasificări fiind acela de a obține clase cât mai omogene, iar omogenitatea fiind caracterizată, din punct de vedere statistic, de dispersie, rezultă că o clasă va fi cu atât mai omogenă cu cât inerția norului de puncte ce o alcătuiește este mai mică.

Fie deci $\mathbf{g}_1, \mathbf{g}_2, \dots, \mathbf{g}_k$ centrele de greutate ale celor k clase. Atunci

- *inerția clasei* C_i este:

$$I_i = \sum_{j \in C_i} p_j d^2(j, \mathbf{g}_i),$$

cu p_j ponderea individului j ;

- *inerția intraclass* este:

$$I_W = \sum_{i=1}^k P_i I_i,$$

cu P_i ponderea clasei i (numărul de indivizi din clasa i);

- *inerția interclass* este:

$$I_B = \sum_{i=1}^k P_i d^2(\mathbf{g}_i, \mathbf{g}),$$

cu $\mathbf{g}$ centrul de greutate al întregului nor de n indivizi.

Cum, conform principiului lui König-Huygens, *inerția totală* a norului este

$$I = I_W + I_B,$$

un criteriu vizual de clasificare pentru a determina, în medie, clase omogene, constă în a căuta acea partiție în k clase pentru care inerția intraclass este minimă, deci inerția interclass este maximă.




FIG. 2.3.1. DESCOMPUNEREA INERȚIEI CONFORM PRINCIPIULUI LUI HUYGENS

Trebuie să remarcăm, mai întâi, că acest criteriu presupune cunoașterea a priori a numărului de clase și că nu este posibilă compararea a două partiții cu număr diferit de clase, având în vedere că cea mai bună partiție de k clase va avea o inerție intraclase superioară oricărei partiții de $k + 1$ clase, iar la limită, cea mai bună partiție este cea trivială, în care fiecare individ formează o clasă (în acest caz $I_W = 0$, căci fiecare individ este propriul său centru de greutate).

2.3.1 Metoda centrelor mobile (a lui Forgy)

Fie E o mulțime de n indivizi caracterizați de p variabile. Vom presupune spațiul $\mathbb{R}^p$, ce conține norul de n puncte-individ, dotat cu o distanță corespunzătoare, notată d (adesea distanța euclidiană uzuală sau distanța χ^2). Se dorește constituirea a k clase. Etapele algoritmului sunt următoarele:

Pasul 1: Se aleg, în general aleator, k puncte distincte din E . Fie acestea $\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_k$. Se inițializează:

$$\begin{aligned} j &= 0, & \text{contorul de numărare a iterațiilor} \\ I_W^{(j)} &= \infty, & \text{inerția intraclase (cu un număr foarte mare, dat).} \end{aligned}$$

Pasul 2: Se împarte mulțimea E în k clase astfel: pentru fiecare i , cu $i = \overline{1, k}$,

$$E_{\mathbf{c}_i} = \{\mathbf{e} \in E \mid d(\mathbf{e}, \mathbf{c}_i) < d(\mathbf{e}, \mathbf{c}_m), m = \overline{1, k}, m \neq i\}$$

Cazul egalității se rezolvă prin tragere la sorți, în sensul că $\mathbf{e}$ este asignat aleator acelor partiții pentru care $d(\mathbf{e}, \mathbf{c}_{i_1}) = d(\mathbf{e}, \mathbf{c}_{i_2}) = \dots = d(\mathbf{e}, \mathbf{c}_{i_e})$. Dacă $\text{card}(E_{\mathbf{c}_i}) = 0$, atunci se generează aleator un nou centru $\mathbf{c}_i$. Geometric, fiecare clasă este un domeniu poliedral convex determinat de hiperplanele mediatoare pe segmentele $\overline{\mathbf{c}_i \mathbf{c}_m}$ cu $m \neq i$ și $m = \overline{1, k}$.

Pasul 3: Se calculează centrele de greutate ale partiției $\{E_{\mathbf{c}_i}\}_{i=1}^k$ și se notează cu $\{\mathbf{g}_i\}_{i=1}^k$.

Se calculează $I_W^{(j+1)}$ = inerția intraclase a partiției $\{E_{\mathbf{c}_i}\}_{i=1}^k$.

Pasul 4: Dacă $j > N$, unde N , dat, reprezintă numărul total de iterații admis sau dacă $|I_W^{(j+1)} - I_W^{(j)}| \leq \varepsilon$, unde ε , dat, reprezintă pragul sub care ameliorarea inerției intraclase este considerată nesemnificativă, atunci **STOP**.

Altfel

$$\begin{aligned} \mathbf{c}_i &= \mathbf{g}_i, \quad i = \overline{1, k}; \\ j &= j + 1; \\ &\text{salt la } \mathbf{Pasul 2}. \end{aligned}$$

Propoziția 2.3.1

Algoritmul converge într-un număr finit de pași, altfel spus $I_W^{(j+1)} \leq I_W^{(j)}$ și $j < \infty$.

Demonstrație. Având în vedere că algoritmul este iterativ, este suficient să demonstrăm inegalitatea pentru $j = 1$, iar pentru simplificarea calculelor presupunem că ponderile indivizilor sunt egale cu p iar ponderile claselor cu P .

Atunci, trebuie demonstrat că $I_W^{(2)} \leq I_W^{(1)}$.

Conform algoritmului, $\{E_{\mathbf{c}_i}\}$ este partiția având punctele fiecărei clase grupate cât mai aproape de $\{\mathbf{c}_i\}$ și cu centrele de greutate $\{\mathbf{g}_i^{(1)}\}$, deci

$$I_W^{(1)} = \sum_{i=1}^k P \sum_{j \in E_{\mathbf{c}_i}} p d^2(j, \mathbf{g}_i^{(1)}) = pP \sum_{i=1}^k \sum_{j \in E_{\mathbf{c}_i}} d^2(j, \mathbf{g}_i^{(1)}),$$

iar $\{E_{\mathbf{g}_i}\}$ este partiția având punctele fiecărei clase grupate cât mai aproape de $\{\mathbf{g}_i^{(1)}\}$ și cu centrele de greutate $\{\mathbf{g}_i^{(2)}\}$, deci

$$I_W^{(2)} = \sum_{i=1}^k P \sum_{j \in E_{\mathbf{g}_i}} p d^2(j, \mathbf{g}_i^{(2)}) = pP \sum_{i=1}^k \sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(2)}),$$




FIG. 2.3.2. ETAPELE ALGORITMULUI LUI FORGY

Conform relației lui Huygens

$$\sum_{i=1}^k \sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(1)}) = I_W^{(2)} + \sum_i d^2(\mathbf{g}_i^{(1)}, \mathbf{g}_i^{(2)}),$$

deoarece $\{\mathbf{g}_i^{(1)}\}_i$ nu sunt centrele de greutate ale lui $\{E_{\mathbf{g}_i}\}$.

Rezultă

$$I_W^{(2)} \leq \sum_{i=1}^k \sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(1)}),$$

cu inegalitate strictă dacă $\mathbf{g}_i^{(1)} \neq \mathbf{g}_i^{(2)}$, $(\forall) i = \overline{1, k}$.

Dar $\sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(1)}) \leq \sum_{j \in E_{c_i}} d^2(j, \mathbf{g}_i^{(1)})$ prin construcția celor două partiții, deoarece $\{E_{\mathbf{g}_i}\}$ este partiția în care fiecare clasă $E_{\mathbf{g}_i}$ păstrează punctele cele mai apropiate de $\mathbf{g}_i^{(1)}$, deci $\sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(1)})$ este minimă. Egalitatea are loc doar dacă $\{E_{\mathbf{g}_i}\} \equiv \{E_{c_i}\}$.

Cu acestea

$$I_W^{(2)} \leq \sum_{i=1}^k \sum_{j \in E_{\mathbf{g}_i}} d^2(j, \mathbf{g}_i^{(1)}) \leq I_W^{(1)}$$

Cum $\text{card}(E_{\mathbf{c}_i}) = n < \infty$ rezultă $P_{n,k} < \infty$ ceea ce implică $j < \infty$. ■

Experiența arată că viteza de convergență este rapidă.

Trebuie remarcat și faptul că, la fiecare pas nefiind necesar decât calculul a nk distanțe, acelea dintre cei n indivizi și cele k centre de greutate, nu este necesară menținerea în memorie a tabelului cu cele $\frac{n(n-1)}{2}$ distanțe dintre indivizi.

Inconveniențele metodei sunt:

- k trebuie cunoscut a priori;
- optimul este dependent de alegerea inițială a punctelor.

În metoda precedentă se așteaptă ca toți indivizii să fie afectați unei clase pentru a calcula centrul de greutate.

Metoda k -mediilor (k -means) a lui MacQueen (conform [42]), recalculează centrele de greutate după fiecare afectare.

Pentru a înlătura dependența metodei de punctele inițiale se utilizează *metoda norilor dinamici* a lui E. Diday (conform [17]), care este o generalizare a metodei centrelor mobile în sensul că fiecare clasă nu mai este reprezentată de centrul său de greutate ci de un nucleu de g -puncte (cele mai centrale, de exemplu), de o axă principală, de un plan principal.

2.3.2 Exemplu

Descrierea datelor

Revenind la exemplul raselor de câini (subcapitolul 1.4.6) reamintim că în urma aplicării analizei corespondențelor multiple au fost identificate patru grupări principale:

- câinii de vânătoare
- câinii de pază
- câinii de companie
- rase lente și mai puțin inteligente.

Acest rezultat va fi comparat cu rezultatul obținut utilizând metoda de clasificare neierarhică k -means pentru identificarea partiției optime în $k = 4$ clustere a mulțimii raselor de câini. Reamintim că o condiție principală pentru utilizarea acestei metode este cunoașterea a priori a numărului de clase (vezi subcapitolul 2.3). Datele de intrare se regăsesc în tabelul A.4. (Anexă) cu

Concluzii:

- clasificarea obținută prin metoda k-means se regăsește aproape identic în reprezentarea grafică a variabilelor obținută prin *analiza corespondențelor multiple*.
- cu toate acestea, clusterelor obținute prin metoda k-means nu coincid în totalitate cu grupările identificate conform interpretării rezultatelor ACM.

Această nepotrivire se datorează, probabil, faptului că:

- informațiile asupra raselor de câini (talie, masă...) nu sunt suficiente pentru a încadra cu precizie o rasă într-o anumită clasă;
- valorile reale ale variabilelor talie, masă, etc. au fost "reduse" la o singură valoare, în funcție de numărul de modalități ale variabilei - 1, 2, 3 sau 1, 2, conform apartenenței la un anumit interval de valori.
- alegerea unui număr prea mic de intervale de valori, deci de modalități, pentru fiecare variabilă.

2.4 Metode de clasificare ierarhică

Principiile generale comune diverselor tehnici de clasificare ascendente ierarhice sunt simple. Aceste principii țin mai mult de bunul simț decât de o teorie formalizată de aceea este dificil să li se găsească o paternitate. Expunerile cele mai sistematice și cele mai vechi sunt poate cele ale lui Sokal și Sneath (în [57]) apoi cele ale lui Lance și Williams (în [39]).

Algoritmul constă în crearea, la fiecare etapă, a unei partiții obținute prin agregarea celor mai apropiate două elemente. Se va desemna prin *element* în același timp indivizii sau obiectele de clasat cât și grupările de indivizi generate de algoritm. Există diferite criterii de agregare, de unde și un număr important de variante ale acestei tehnici.

Algoritmul nu furnizează o partiție în q clase a unei mulțimi de n obiecte, ci o ierarhie de partiții. Această ierarhie se prezintă sub forma unui arbore numit și *dendogramă* și conține $n - 1$ partiții. Interesul pentru acest arbore este dat de faptul că acesta poate furniza o idee despre numărul de clase ce există efectiv în populație. Fiecare „tăiere” a dendogramei furnizează o partiție având cu atât mai puține clase, și acestea fiind cu atât mai puțin omogene, cu cât tăierea se face mai sus.

2.4.1 Aspecte formale

Definiția 2.4.1 Fie E o mulțime finită. O mulțime de mulțimi, $\mathcal{H} \subset \mathcal{P}(E)$, se numește *ierarhie* dacă și numai dacă

- a) E și părțile lui E formate dintr-un element aparțin lui $\mathcal{H}$;
- b) $A \cap B \in \{A, B, \emptyset\}$, $(\forall) A, B \in \mathcal{H}$.

Definiția 2.4.2 Elementele din $\mathcal{H}$ se numesc *partiții* ale mulțimii E .

Definiția 2.4.3 Elementele unei partiții a lui E se numesc *clase*.

Observația 2.4.1

1. Fiecărei ierarhii îi corespunde un arbore de clasificare.
2. Fiecare clasă dintr-o ierarhie este reuniunea claselor incluse în ea.

Dacă $\text{card}(E) = n < \infty$, atunci $\text{card}(\mathcal{H}) = 2^n$ deoarece, datorită condiției b) din definiție, o partiție cu k clase se formează prin regrouparea a două clase ale partiției cu $k + 1$ clase.


Cum partiția P_n , cu n clase, este formată din elementele mulțimii E și conține câte un element în fiecare clasă, iar partiția P_1 , cu o clasă, este formată din mulțimea E (ambele partiții aparțin ierarhiei $\mathcal{H}$, conform condiției a) din definiție), $\mathcal{H}$ conține practic $n - 2$ partiții netriviale ale lui E .

Definiția 2.4.4 Se numește *indice al ierarhiei* $\mathcal{H}$, o aplicație $i: \mathcal{H} \rightarrow \mathbb{R}_+$ crescătoare $((\forall) A, B \in \mathcal{H} \text{ cu } A \subset B \Rightarrow i(A) < i(B))$ și care îndeplinește condiția $i(C) = 0$, $(\forall) C \in P_n$.

Definiția 2.4.5 Indicele i al ierarhiei $\mathcal{H}$, dacă există, se mai numește și *nivel de agregare* iar ierarhia dotată cu un astfel de indice se numește *ierarhie indexată*.

Exemplul 2.4.1

Fie $E = \{a, b, c, d, e\}$, atunci $n = 5 = \text{card}(E)$



cu

$$\begin{aligned}
 i(\{a\}) &= i(\{b\}) = i(\{c\}) = i(\{d\}) = i(\{e\}) = 0 \\
 i(\{f\}) &= i(\{a, b\}) = 0,5 & i(\{h\}) &= i(\{c, d, e\}) = 2,5 \\
 i(\{g\}) &= i(\{c, d\}) = 2 & i(\{j\}) &= i(\{a, b, c, d, e\}) = 4
 \end{aligned}$$

Observația 2.4.2

- a) În exemplul de mai sus indicele indică nivelul la care două clase s-au grupat (motivație pentru utilizarea denumirii de nivel de agregare). Cu cât indicele este mai mare cu atât mulțimea este mai eterogenă.
- b) Cunoșcând arborele de clasificare este facil să se obțină o partiție cu un număr mai mic sau mai mare de clase. Pentru aceasta, este suficient să se taie arborele la un nivel dat și să se considere clasele date de ramurile care cad. Astfel, dacă în exemplul de mai sus se taie arborele de-a lungul liniei punctate, se obține o partiție în 3 clase: $\{\{a, b\}, \{c, d\}, \{e\}\}$.

Propoziția 2.4.1

Fie E o mulțime și $\delta : E \times E \rightarrow \mathbb{R}_+$ o disimilaritate strictă pe E . Atunci

$$i(A) = \begin{cases} 0, & \text{dacă } A = \{i\}, i \in E \\ \min \delta(i, j), & \text{dacă } A = A_1 \cup A_2, A_1 \cap A_2 = \emptyset, i \in A_1, j \in A_2 \end{cases}$$

induce pe E o ierarhie indexată cu nivelul de agregare i .

Demonstrație. Din definiție, i este o funcție pozitivă și simetrică.

Trebuie demonstrate două afirmații:

- a) că i induce pe E o ierarhie, $\mathcal{H}$;
- b) că i este indicele acelei ierarhii, adică i este o funcție crescătoare de partiții din $\mathcal{H}$.
- a) Fie P_n partiția formată din n clase a mulțimii E . Din definiția funcției de disimilaritate, $i(A) = 0, (\forall) A \in P_n$. Se formează partiția P_{n-1} agregând elementele i și j din P_n pentru care $\delta(i, j)$ este minim. Cum δ este o disimilaritate strictă, perechea (i, j) este unică. Din construcție, $A \cap B \in \{A, B, \emptyset\}, (\forall) A, B \in \mathcal{H}$.
- Se formează partiția P_{n-2} agregând elementele i, j din P_{n-1} pentru care $\delta(i, j)$ este minim și așa mai departe până la obținerea partiției P_1 .
- Se definește $\mathcal{H} = \{P_1, P_2, \dots, P_n\}$. Din construcție, $\mathcal{H}$ verifică cele două condiții din definiția ierarhiei.
- b) Fie $A, B \in \mathcal{H}$ cu $A \subset B$. Rezultă $B = A \cup C$ și $A \cap C = \emptyset$. Din definiție $\delta(i, j) < \delta(i, k), (\forall) i, j \in A, k \in C$, deoarece δ este strictă și dacă $(\exists) k_0$ astfel încât $\delta(i, j) < \delta(i, k_0)$ atunci din agregarea lui A rezultă k_0 aparține lui A și nu lui C .

Pentru un $j \in A$, fixat pentru moment dar altfel oarecare, $\min_{i \in A} \delta(i, j) <$

$$\min_{i \in A} \left(\min_{k \in C} \delta(i, k) \right) = i(B) \text{ (din definiție).}$$

Din construcție, $i(A) \in \left\{ \min_{i \in A} \delta(i, j) \mid j \in A \right\}$. Cum inegalitatea de mai sus este valabilă oricare ar fi $j \in A$, rezultă $i(A) < i(B)$. ■

2.4.2 Strategii de agregare

În funcție de natura spațiului în care se găsesc indivizii de agregat, se vor folosi:

- metoda Ward, dacă indivizii formează un nor într-un spațiu euclidian, de exemplu $\mathbb{R}^p$, deci dacă între ei se poate calcula o distanță euclidiană;
- strategii de agregare pe disimilarități, dacă între indivizi se poate calcula o disimilaritate strictă.

2.4.2.1 METODA WARD Pe baza distanței euclidiene se poate evalua inerția și astfel se poate utiliza principiul de agregare ce reunește acele clase pentru care inerția interclase descrește cel mai puțin. Conform principiului lui Huygens, inerția globală este suma inerțiilor interclase și intraclase. Cu cât clasele sunt mai omogene cu atât inerția intraclase este mai mică, deci inerția interclase este mai mare. Clase omogene înseamnă clase cu indivizi cât mai puțini, deci partiții cât mai bogate. Este firesc ca, prin fuzionarea a două clase, inerția intraclase să crească, deci inerția interclase să scadă. Se va alege, deci, acea fuzionare pentru care inerția interclase scade cel mai puțin, adică sunt grupate clasele cele mai asemănătoare (adică cele mai apropiate).

Lema 2.4.1

Pierderea de inerție interclase este dată de formula

$$\delta(A, B) = \frac{P_A P_B}{P_A + P_B} d^2(\mathbf{g}_A, \mathbf{g}_B),$$

unde A și B sunt două clase cu ponderile P_A , respectiv P_B și centrele de greutate $\mathbf{g}_A$, respectiv $\mathbf{g}_B$.

Demonstrație. Inerția interclase este $I_B = \sum_{j=1}^k P_j d^2(\mathbf{g}_j, \mathbf{g})$. Suma va conține, deci, și termenii $P_A d^2(\mathbf{g}_A, \mathbf{g}) + P_B d^2(\mathbf{g}_B, \mathbf{g})$.

După fuziunea celor două clase, dacă se notează cu $\mathbf{g}_{AB}$ centrul de greutate al noii clase, atunci cei doi termeni vor fi înlocuiți de $(P_A + P_B) d^2(\mathbf{g}_{AB}, \mathbf{g})$.


Deci pierderea de inerție interclase este dată de diferența

$$P_A d^2(\mathbf{g}_A, \mathbf{g}) + P_B d^2(\mathbf{g}_B, \mathbf{g}) - (P_A + P_B) d^2(\mathbf{g}_{AB}, \mathbf{g}). \quad (1)$$

Din construcție, $\mathbf{g}_{AB} = \frac{P_A \mathbf{g}_B + P_B \mathbf{g}_A}{P_A + P_B}$ adică centrul de greutate al noii clase este pe segmentul $\overline{\mathbf{g}_A \mathbf{g}_B}$.

În $\triangle \mathbf{g} \mathbf{g}_A \mathbf{g}_B$, utilizând o generalizare a teoremei medianei, $m_c^2 = \frac{1}{2}a^2 + \frac{1}{2}b^2 - \frac{1}{4}c^2$, rezultă

$$d^2(\mathbf{g}, \mathbf{g}_{AB}) = \frac{P_A}{P_A + P_B} d^2(\mathbf{g}_A, \mathbf{g}) + \frac{P_B}{P_A + P_B} d^2(\mathbf{g}_B, \mathbf{g}) - \frac{P_A P_B}{(P_A + P_B)^2} d^2(\mathbf{g}_A, \mathbf{g}_B). \quad (2)$$

FIG. 2.4.1. TEOREMA GENERALIZATĂ A MEDIANEI, APLICATĂ ÎN $\triangle g g_A g_B$

Introducând rezultatul din formula (2) în formula (1) se obține rezultatul din enunțul lemei. ■

Lema 2.4.2

Într-o ierarhie indexată, agregată pe baza unei distanțe euclidiene, suma indicilor de agregare este egală cu inerția totală.

Demonstrație. Conform principiului lui Huygens $I = I_W + I_B$, unde I_B este inerția interclase și I_W este inerția intraclase.

La momentul inițial, când E este împărțită în n clase,

$$I_W(P_n) = 0 \Rightarrow I_B(P_n) = I.$$

La momentul final, când E are o singură clasă,

$$I_B(P_1) = 0 \Rightarrow I_W(P_1) = I.$$

Cum pierderea de inerție interclase, adică $I_B(P_s) - I_B(P_{s-1})$, este egală tocmai cu indicele de agregare, rezultă

$$\sum_{s=2}^n i(P_s) = \sum_{s=2}^n [I_B(P_s) - I_B(P_{s-1})] = I_B(P_n) - I_B(P_1) = I$$

■

Lema 2.4.3 (generalizarea formulei Lance-Williams)

$$\delta(C; (A, B)) = \frac{(P_A + P_C) \delta(A, C) + (P_B + P_C) \delta(B, C) - P_C \delta(A, B)}{P_A + P_B + P_C}.$$

Observația 2.4.3

Lema 2.4.3 permite calculul disimilarității dintre două clase fără a fi necesară folosirea distanțelor euclidiene între centrele de greutate ale acestor clase. În plus, nici centrele de greutate nu mai trebuie calculate.

Așadar, odată calculate disimilaritățile dintre indivizi, se poate lucra numai pe matrici de disimilarități prin aplicarea succesivă a formulei Lance-Williams.

Demonstrație. Conform Lemei 2.4.1

$$\delta(C, (A, B)) = \frac{P_C P_{AB}}{P_C + P_{AB}} d^2(\mathbf{g}_C, \mathbf{g}_{AB}),$$

unde $P_{AB} = P_A + P_B$, conform teoremei generalizate a medianei. Cum

$$\begin{aligned} d^2(\mathbf{g}_C, \mathbf{g}_{AB}) &= \frac{P_A}{P_A + P_B} d^2(\mathbf{g}_A, \mathbf{g}_C) + \frac{P_B}{P_A + P_B} d^2(\mathbf{g}_B, \mathbf{g}_C) - \\ &\quad - \frac{P_A P_B}{(P_A + P_B)^2} d^2(\mathbf{g}_A, \mathbf{g}_B), \end{aligned}$$

iar, pe de altă parte, tot din Lema 2.4.1

$$\begin{aligned} \frac{P_C P_A}{P_C + P_A} d^2(\mathbf{g}_C, \mathbf{g}_A) &= \delta(A, C), \\ \frac{P_C P_B}{P_C + P_B} d^2(\mathbf{g}_C, \mathbf{g}_B) &= \delta(B, C), \\ \frac{P_A P_B}{P_A + P_B} d^2(\mathbf{g}_A, \mathbf{g}_B) &= \delta(A, B). \end{aligned}$$

Rezultă

$$\begin{aligned} d^2(\mathbf{g}_C, \mathbf{g}_{AB}) &= \frac{1}{P_C P_{AB}} [(P_C + P_A) \delta(A, C) + (P_C + P_B) \delta(B, C) - \\ &\quad - P_C \delta(A, B)] \end{aligned}$$

deci

$$\delta(C; (A, B)) = \frac{(P_A + P_C) \delta(A, C) + (P_B + P_C) \delta(B, C) - P_C \delta(A, B)}{P_A + P_B + P_C}.$$

■

Rezultatul lemei permite enunțarea următorului **ALGORITM**:

Pasul 1 Se înlocuiește matricea **D** a distanțelor euclidiene dintre indivizi cu matricea

$$\Delta_n = (\delta_{ij})_{i=1, n}^{j>i} \quad \text{cu} \quad \delta_{ij} = \delta(A, B) = \frac{P_i P_j}{P_i + P_j} d^2(\mathbf{e}_i, \mathbf{e}_j).$$

Pasul 2 În matricea Δ_n se caută $\min_{i,j} \delta(i, j)$, se elimină linia și coloana j , iar linia și coloana lui i se notează cu $\hat{i}\hat{j}$, formându-se matricea Δ_{n-1} . Indicele de agregare al clasei $\hat{i}\hat{j}$ este δ_{ij} .

Pasul 3 Se calculează elementele matricii Δ_{n-1} astfel:

- se copiază coloanele matricii Δ_n ;

- coloana $\hat{ij}$ se calculează după formula generalizată a lui Lance-Williams:

$$\delta(k; \hat{ij}) = \frac{(P_i + P_k) \delta_{ik} + (P_j + P_k) \delta_{jk} - P_k \delta_{ij}}{P_i + P_j + P_k}$$

Pasul 4 Se pune $n = n - 1$ și $\Delta_n = \Delta_{n-1}$;

Dacă $n = 1$ atunci **STOP**; altfel, salt la **Pasul 2**.




FIG. 2.4.2. AGLOMERAREA PROGRESIVĂ A 5 PUNCTE

Observația 2.4.4

La etapa inițială, inerția intraclase este nulă și inerția interclase este egală cu inerția totală a norului deoarece fiecare element terminal constituie, la acest nivel, o clasă. În etapa finală, inerția interclase devine nulă iar inerția intraclase este echivalentă cu inerția totală pentru că, la acest nivel, există o partiție cu o singură clasă (fig. 2.4.2).




FIG. 2.4.3. CALITATEA GLOBALĂ A UNEI PARTIȚII

2.4.2.2 STRATEGII DE AGREGARE PE DISIMILARITĂȚI Dacă între indivizi este dată o matrice de disimilaritate strictă, atunci se pot imagina mai multe soluții, mai mult sau mai puțin arbitrare. Cele mai utilizate sunt:

- distanța *saltului minimal* (single linkage), care favorizează mulțimile cu puncte apropiate:

$$d(A, B) = \min \delta(e_i, e_j), \quad e_i \in A, \quad e_j \in B$$

- distanța *diametrului* (complete linkage), ce repară limitele primei distanțe, dar punctele trebuie să fie apropiate:

$$d(A, B) = \max \delta(e_i, e_j), \quad e_i \in A, \quad e_j \in B$$

- distanța *mediei* (unweighted pair-group average linkage)

$$d(A, B) = \frac{P_x \delta(x, z) + P_y \delta(y, z)}{P_x + P_y} \text{ cu } A = \{x, y\}, B = \{z\}.$$

Observația 2.4.5

Ierarhiile induse de diferitele distanțe sunt în general diferite. Se recomandă așadar, utilizarea mai multor tipuri de clasificări. Acestea nu trebuie să difere prea mult când se privește partea superioară a arborelui de clasificare. Dacă totuși acest lucru se întâmplă, se poate conchide că mulțimea indivizilor se pretează prost la orice clasificare.

Exemplu:

Fie matricea de disimilaritate dintre indivizii $\{a, b, c, d, e\}$:

	a	b	c	d	e
a	0	3	7	3	4
b		0	4	4	1
c			0	2	6
d				0	$\frac{1}{2}$
e					0

Intr-adevăr, aceasta este o matrice de disimilaritate deoarece $\delta(c, e) > \delta(c, d) + \delta(d, e) \Leftrightarrow 6 > 2 + \frac{1}{2}$.

Să aplicăm algoritmul de clasificare ierarhică ascendentă folosind, pe rând, tipurile de disimilarități enumerate mai sus.

- Astfel, pentru disimilaritatea saltului minimal (Inf) se obțin următoarele etape:

1. $f = \{d, e\}; i(f) = \frac{1}{2}$

	a	b	c	f
a	0	3	7	3
b		0	4	1
c			0	2
f				0


2. $g = \{f, b\}; i(g) = 1$

	a	c	g
a	0	7	3
c		0	2
g			0

3. $h = \{c, g\}; i(h) = 2$

	a	h
a	0	3
h		0

4. $i = \{a, h\}; i(i) = 3$.



- Pentru disimilaritatea diametrului (Sup) se obțin următoarele etape :

1. $f = \{d, e\}; i(f) = \frac{1}{2}$

	a	b	c	f
a	0	3	7	4
b		0	4	4
c			0	6
f				0


2. $g = \{a, b\}; i(g) = 3$

	c	f	g
c	0	6	7
f		0	4
g			0


3. $h = \{f, g\}; i(h) = 4$

	c	h
c	0	6
h		0

4. $i = \{h, c\}; i(i) = 7$.



- Analog pentru disimilaritatea medie se obține următoarea dendogramă:



În pofda faptului că fiecare arbore începe cu agregarea lui d și e într-o singură clasă, f , urmează imediat diferențe importante atunci când se calculează distanțele de la f la ceilalți indivizi:

- $d_{\inf}(b, f) = \inf(d(b, d); d(b, e)) = 1;$
- $d_{\sup}(b, f) = \sup(d(b, d); d(b, e)) = 4;$
- $d_{\text{med}}(b, f) = 2,5.$

Să notăm, însă, că una din principalele dificultăți în clasificare constă în definirea unei distanțe sau disimilarități între indivizi, mai ales când aceștia sunt descriși prin caractere calitative.

2.5 Clasificare mixtă

Algoritmii de clasificare sunt mai mult sau mai puțin adaptați pentru volume mari de date. Astfel:

- metodele de agregare în jurul centrilor mobili pot manipula volume mari cu prețuri mici dar au dezavantajul că produc partiții dependente de numărul ales de clase și de centrii inițiali;
- metodele de agregare ierarhice sunt „deterministe” (în sensul că dau întotdeauna același rezultat dacă datele inițiale sunt aceleași), dau indicații privind numărul de clase ce trebuie reținut dar sunt prost adaptate la volume mari de date.

Combinarea celor două metode a dat naștere unui algoritm mixt (*hybrid clustering*, [64]).

Algoritmul de clasificare mixtă conține trei etape: mulțimea elementelor de clasificat este partiționată (centrii mobili) în câteva zeci, eventual sute de partiții omogene; se procedează apoi la agregarea ierarhică a acestor grupe cu scopul ca dendrograma obținută să sugereze numărul de clase finale ce trebuie reținute; în fine, se optimizează (folosind iarăși tehnica centrilor mobili) partiția obținută prin tăierea arborelui.

Etapele algoritmului sunt:

1. **Partiționarea inițială.** Această etapă vizează obținerea rapidă și cu un preț scăzut a unei partiții de n obiecte în k clase omogene, unde k este mult mai mare decât s , numărul de clase dorit, dar mult mai mic decât n . În acest scop este utilizat algoritmul centrilor mobili. Optimalitatea nu este, desigur, atinsă, dar partiția obținută poate fi ameliorată pornind de la grupările stabile (grupuri de indivizi sau elemente care apar mereu în aceleași clase). Aceste grupări vor fi elementele de bază în etapa următoare.
2. **Agregarea ierarhică a claselor obținute.** Această etapă constă în efectuarea unei clasificări ierarhice ascendente în care elementele terminale ale arborelui sunt cele k clase ale partiției inițiale. Scopul acestei etape este de a reconstitui clasele care au fost fragmentate și de a agrega elementele aparent dispersate în jurul centrelor de origine. Arborele este construit după strategia Ward care ține seamă de mase în momentul alegerii elementelor de agregat.
3. **Partiția finală.** Partiția finală a populației este dată prin tăierea arborelui obținut în etapa precedentă. Omogenitatea claselor obținute poate fi optimizată prin reafectare.

Figura 2.5.1. schematizează etapele algoritmului de clasificare mixtă.




FIG. 2.5.1. SCHEMA CLASIFICĂRII MIXTE

2.5.1 Alegerea claselor prin "tăierea" arborelui

Alegerea nivelului de tăiere și astfel, al numărului de clase ale partiției, poate fi facilitată de inspecția vizuală a arborelui. Tăierea trebuie să se facă în intervalul dintre indici de valori mici, corespunzând unor clase omogene, și indici de valori mari ce disociază clase bine conturate.

Într-o manieră generală, cu cât se grupează mai mulți indivizi, altfel spus cu cât ne apropiem de vârful arborelui, cu atât mai mare va fi distanța între două clase vecine iar indicele de agregare va fi mai mare. Tăind arborele la nivelul unui salt important al acestui indice se poate spera în obținerea unei partiții de bună calitate, în sensul că indivizii grupați sub nivelul de tăiere erau apropiați și cei grupați deasupra nivelului de tăiere sunt necesarmente depărtați (ceea ce corespunde definiției unei bune partiții).

În practică situația nu este însă atât de clar definită. Ca și în cazul analizei factoriale, se utilizează criterii empirice: *histograma indicilor de agregare*.




FIG 2.5.2 HISTOGRAMELE INDICILOR DE NIVEL

2.5.2 Caracterizarea statistică a claselor

Elementele unei aceleiași clase se aseamănă din punct de vedere al criteriilor alese pentru a le descrie. Rămâne de precizat care sunt criteriile care se află la originea grupărilor obținute. Se procedează la descrierea automată a claselor, ceea ce constituie în practică o etapă indispensabilă oricărei proceduri de clasificare.

Descrierea automată a claselor este, în general, bazată pe compararea mediilor sau a procentelor din interiorul claselor cu mediile sau procentele obținute pe întreaga populație. Pentru a selecționa variabilele continue sau modalitățile variabilelor nominale caracteristice fiecărei clase, se măsoară ecartul dintre valorile specifice clasei și valorile globale. Aceste statistici pot fi convertite într-un criteriu numit *valoare-test*, care permite operarea unei selecții asupra variabilelor, desemnând astfel variabilele cele mai reprezentative (conform [47]).

2.5.2.1 VALORI-TEST PENTRU VARIABLE CONTINUE Pentru a caracteriza o clasă prin variabile continue, se compară $\bar{x}_k$, media variabilei x în clasa k , cu media $\bar{x}$ în întreg norul. Valoarea-test este aici

$$t_k = \frac{\bar{x}_k - \bar{x}}{s_k(x)},$$

cu $s_k^2(x) = \frac{n-n_k}{n-1} \frac{s^2(x)}{n_k}$, estimatorul dispersiei lui x în clasa k și $s^2(x)$ dispersia empirică a lui x în întreg norul. Se recunoaște aici, în $s_k^2(x)$, dispersia unei medii în cazul extragerii fără revenire a k elemente.

În ipoteza nulă a unei extrageri aleatoare, fără revenire, a n_k indivizi din clasa k , variabila $\bar{x}_k$, reprezentând media empirică în acea clasă, are ca medie și dispersie empirică globală pe $\bar{x}$ respectiv $s_k^2(x)$.

Capitolul 4

MODELE LINIARE

Modelele liniare urmăresc să explice sau să prezică o variabilă continuă, numită *variabilă dependentă/de explicat/endogenă* cu ajutorul unor variabile numite *explicative/exogene/predictori*. În general, termenul de *model de regresie* este rezervat cazului în care variabilele explicative sunt continue. În cazul în care acestea sunt variabile discrete (nominale) modelul se va numi *de analiză dispersională* (sau *analiză de varianță* - *ANOVA*) iar dacă mulțimea variabilelor exogene este mixtă vom vorbi de *analiză de covarianță*.

Regresia reprezintă, fără îndoială, metoda statistică cea mai utilizată, în pofida faptului că limitele ei nu sunt întotdeauna bine cunoscute. Literatura privind modelele de regresie este foarte vastă. O bibliografie comentată a câtorva sute de articole și cărți se găsește în [34]. Searle [54] și Seber [55] tratează exhaustiv problemele de analiză dispersională și de covarianță. Lucrarea lui Rao [50] - reeditare a unui manual clasic, studiază inducția statistică asupra modelului liniar. Un alt manual clasic este lucrarea lui Draper și Smith, [20]. Mosteller și Tukey [48], Besley [6], Atkinson [4], prezintă puncte de vedere mai moderne, incluzând diverse metode de selecție de variabile, în timp ce Chatterjee și Price [11] insistă asupra implementării în practică a modelelor. Saporta [53] realizează o prezentare mai concisă a problematicii.

4.1 Modelul de regresie

4.1.1 Formularea problemei

Se dispune de n observații asupra $p + 1$ variabile: $y, x_1, x_2, \dots, x_p$. Se urmărește explicarea sau prezicerea variabilei dependente y cu ajutorul variabilelor predictor $x_1, x_2, \dots, x_p$, presupuse cunoscute. Relația dintre y și

$x_1, x_2, \dots, x_p$ este presupusă liniară¹, adică

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i, \quad i = \overline{1, n}$$

unde $\beta_0, \beta_1, \dots, \beta_p$ sunt coeficienții necunoscuți ai modelului. Termenul constant β_0 poate fi considerat drept coeficientul unei variabile explicative artificiale, x_0 , ale cărei valori x_{i0} sunt întotdeauna egale cu 1. Variabila ε_i se numește *reziduu/eroare* și reprezintă distanța dintre valoarea observată, y_i , și cea calculată de modelul liniar, $\sum_j \beta_j x_{ij}$. În cazul în care nu se specifică altfel, ε_i sunt presupuse cantități aleatoare independente.

Pus sub o formă matriceală modelul se exprimă:

$$\mathbf{y}_{n \times 1} = \mathbf{X}_{n \times (p+1)} \boldsymbol{\beta}_{(p+1) \times 1} + \boldsymbol{\varepsilon}_{n \times 1}$$

unde $\mathbf{y} = (y_1, \dots, y_n)'$ este vectorul observațiilor asupra variabilei dependente,

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \text{ este matricea observațiilor asupra variabilelor ex-}$$

plicative, $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)'$ este vectorul coeficienților, $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)'$ este vectorul erorilor.

Pentru evaluarea coeficienților necunoscuți ai modelului, inclusiv a reziduurilor ε_i se dispune de un sistem de n ecuații liniare având $n+p+1$ necunoscute. Prin urmare, sistemul admite o infinitate de soluții. Fie $b_0, b_1, \dots, b_p$ o soluție posibilă. Aceasta va trebui să minimizeze global mulțimea distanțelor de la modelul liniar urmând un criteriu ce va fi precizat, altfel spus:

se aleg $(b_0, b_1, \dots, b_p)$ care minimizează mulțimea valorilor e_i unde

$$e_i = y_i - (b_0 + b_1 x_{i1} + \dots + b_p x_{ip}).$$

Un criteriu posibil este norma L_k care implică minimizarea $\sum |e_i|^k$. Cazuri particulare sunt:

- norma L_2 - caz în care procedeul de minimizare este denumit *Metoda celor mai mici pătrate* și determină soluția ce minimizează $\sum (e_i)^2$;
- norma L_1 - caz în care procedeul de minimizare este denumit *Metoda celor mai mici valori absolute* și determină soluția ce minimizează $\sum |e_i|$;
- norma L_∞ - caz în care procedeul de minimizare este denumit *Metoda minmax* și determină soluția ce minimizează $\left\{ \max_i e_i \right\}$;

¹Liniaritatea relațiilor în raport cu coeficienții poate să apară după o transformare prealabilă a datelor. De exemplu: $y = \alpha_3 x_1^{\alpha_1} x_2^{\alpha_2} (1 + \varepsilon)$ devine liniar după transformarea logaritmică $\log y = \alpha_1 \log x_1 + \alpha_2 \log x_2 + \log \alpha_3 + \log (1 + \varepsilon)$

Criteriul celor mai mici pătrate conduce la calcule algebrice simple, se pretează la interpretări geometrice clare și permite interpretări statistice interesante, motiv pentru care se utilizează cel mai des.

Folosirea normei L_1 în cazul regresiei liniare apare pentru prima dată la Laplace în 1793. Acest criteriu care nu privilegiază ecarturile importante stă la baza metodelor de regresie mai robuste [35].

4.1.2 Estimarea funcției de regresie

Definiția 4.1.1 Se numește *funcție de regresie liniară multiplă* funcția:

$$\tilde{y} \equiv f(x_0, x_1, \dots, x_p) = b_0 x_0 + b_1 x_1 + \dots + b_p x_p.$$

Estimarea acestei funcții, în această prezentare, presupune determinarea coeficienților $b_0, b_1, \dots, b_p$ prin metoda celor mai mici pătrate, pornind de la observațiile $\{y_i, x_{i0} = 1, x_{i1}, \dots, x_{ip}\}_{i=1}^n$.

În cazul *regresiei simple liniare* ($p = 1$):

- funcția de regresie se mai numește și *dreaptă de regresie*,
- b_0 se numește *intercepție* sau *bias* și reprezintă punctul de intersecție al dreptei de regresie cu axa Oy ,
- b_1 se numește *panta* dreptei de regresie și indică modificarea proporțională a variabilei dependente y la modificarea cu o unitate a variabilei predictor x_1 .

În cele ce urmează vom presupune că variabilele sunt centrate, ceea ce implică $b_0 = 0$. Una dintre proprietățile regresiei multiple este aceea că, excepție făcând b_0 , toate estimațiile coeficienților rămân neschimbate indiferent dacă variabilele sunt sau nu centrate.

Lema 4.1.1

Coeficienții funcției de regresie liniară multiplă sunt:

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}.$$

Demonstrație. Fie sistemul de ecuații de condiție:

$$\mathbf{y}_{n \times 1} = \mathbf{X}_{n \times p} \mathbf{b}_{p \times 1} + \mathbf{e}_{n \times 1}$$

și $\tilde{\mathbf{y}} = \mathbf{X}\mathbf{b}$ valorile prezise de modelul de regresie liniară multiplă. Într-o manieră generală se caută $\tilde{\mathbf{y}}$ cât mai aproape de $\mathbf{y}$. Deci estimarea funcției de regresie se reduce la determinarea coeficienților $\mathbf{b}$ care minimizează

$$\mathbf{e}'\mathbf{e} = \sum e_i^2 = \|\mathbf{y} - \tilde{\mathbf{y}}\|^2$$

Termenul $\mathbf{e}'\mathbf{e}$ este un produs scalar care depinde de $b_1, \dots, b_p$, așadar o condiție necesară pentru aflarea unui punct de extrem este anularea derivatelor parțiale de ordinul întâi, adică

$$\frac{\partial}{\partial \mathbf{b}} (\mathbf{e}'\mathbf{e}) = \mathbf{0}.$$

Cum

$$\mathbf{e}'\mathbf{e} = (\mathbf{y} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{y}'\mathbf{y} - 2\mathbf{b}'\mathbf{X}'\mathbf{y} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b}$$

deoarece

$$\mathbf{y}'\mathbf{X}\mathbf{b} = \mathbf{b}'\mathbf{X}'\mathbf{y} = \text{scalar}$$

rezultă că

$$\frac{\partial}{\partial \mathbf{b}} (\mathbf{e}'\mathbf{e}) = -2\mathbf{X}'\mathbf{y} + 2\mathbf{X}'\mathbf{X}\mathbf{b}.$$

Astfel, condiția de extrem devine:

$$\mathbf{X}'\mathbf{X}\mathbf{b} = \mathbf{X}'\mathbf{y} \quad (4.1.1)$$

care este un sistem de p ecuații cu p necunoscute, numit și *sistem de ecuații normale*. Dacă $n \geq p$ (mai multe ecuații de condiție decât necunoscute) și dacă $\mathbf{X}$ este de rang maxim p , atunci $\mathbf{X}'\mathbf{X}$ este inversabilă. Așadar soluția sistemului (4.1.1) este:

$$\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \quad (4.1.2)$$

Rămâne de verificat că $\mathbf{b}$ este un punct de minim. Fie $\tilde{\mathbf{b}}$ o altă soluție și $\tilde{\mathbf{e}}$ vectorul ecarturilor corespunzătoare:

$$\tilde{\mathbf{e}} = \mathbf{y} - \mathbf{X}\tilde{\mathbf{b}} = (\mathbf{y} - \mathbf{X}\mathbf{b}) + (\mathbf{X}\mathbf{b} - \mathbf{X}\tilde{\mathbf{b}}) = \mathbf{e} + \mathbf{X}(\mathbf{b} - \tilde{\mathbf{b}})$$

Atunci

$$\tilde{\mathbf{e}}'\tilde{\mathbf{e}} = \mathbf{e}'\mathbf{e} + 2(\mathbf{b} - \tilde{\mathbf{b}})' \mathbf{X}'(\mathbf{y} - \mathbf{X}\mathbf{b}) + (\mathbf{b} - \tilde{\mathbf{b}})' \mathbf{X}'\mathbf{X}(\mathbf{b} - \tilde{\mathbf{b}})$$

iar în membrul drept, conform relației 4.1.1, termenul central este nul și egalitatea se reduce la

$$\tilde{\mathbf{e}}'\tilde{\mathbf{e}} = \mathbf{e}'\mathbf{e} + (\mathbf{X}(\mathbf{b} - \tilde{\mathbf{b}}))' \mathbf{X}(\mathbf{b} - \tilde{\mathbf{b}}).$$

Membrul drept al identității este o sumă de pătrate ce nu poate fi decât pozitivă sau nulă. În concluzie $\mathbf{e}'\mathbf{e}$ este cea mai mică sumă a pătratelor ecarturilor, deci $\mathbf{b}$ este minim. ■

Proprietățile algebrice ale coeficienților $\mathbf{b}$ permit și o *interpretare geometrică* a operațiilor efectuate. Ne plasăm în spațiul $\mathbb{R}^n$, unde n este numărul observațiilor făcute asupra a $p + 1$ variabile: $y, x_1, \dots, x_p$. Căutarea lui y sub forma unei combinații liniare de $x_1, \dots, x_p$ se reduce la a defini $\tilde{\mathbf{y}}$ într-un subspațiu, V_X , generat de variabilele explicative. Tehnica ajustării celor mai

mici pătrate se reduce la aproximarea lui y prin proiecția sa ortogonală $\tilde{y}$, pe subspațiul V_X . Înlocuind $\mathbf{b}$ prin valoarea dată de (4.1.2), se obține

$$\tilde{\mathbf{y}} = \mathbf{X}\mathbf{b} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = \mathbf{P}_X\mathbf{y}$$

unde

$$\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}', \quad (4.1.3)$$

este *operatorul proiecției ortogonale pe V_X* .

Cum rezultă din fig. 4.4.1, modelul teoretic $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ definește o descompunere a lui $\mathbf{y}$ în doi termeni necunoscuți: $\mathbf{X}\boldsymbol{\beta}$ în V_X și $\boldsymbol{\varepsilon}$ în $\mathbb{R}^n$. Metoda celor mai mici pătrate propune ca soluție descompunerea $\mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{e}$, care minimizează „lungimea” lui $\mathbf{e}$ proiectând ortogonal $\mathbf{y}$ pe $\mathbf{X}\mathbf{b}$ în V_X și $\mathbf{e}$ pe $\mathbf{e}$ în subspațiul din $\mathbb{R}^n$, ortogonal pe V_X , notat $V_X^\perp$. Cei doi vectori, $\mathbf{X}\mathbf{b}$ și $\mathbf{e}$, sunt ortogonali.




FIG. 4.1.1. PROIECȚIA LUI $\mathbf{y}$ PE V_X

Să remarcăm că variabilele fiind centrate, lungimile în $\mathbb{R}^n$ pot fi interpretate în termeni de dispersie. Teorema lui Pitagora aplicată în triunghiul dreptunghic de catete $\mathbf{X}\mathbf{b}$ și $\mathbf{e}$ și ipotenuză $\mathbf{y}$ se scrie

$$\mathbf{y}'\mathbf{y} = \mathbf{e}'\mathbf{e} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b}.$$

Împărțind cu n fiecare termen se obține relația

$$\frac{1}{n} \sum y_i^2 = \frac{1}{n} \sum (y_i - \tilde{y})^2 + \frac{1}{n} \sum \tilde{y}_i^2$$

unde

$$\begin{aligned} \frac{1}{n} \sum y_i^2 & \text{ reprezintă } \textit{dispersia totală}, \\ \frac{1}{n} \sum (y_i - \tilde{y})^2 & \text{ reprezintă } \textit{dispersia reziduală}, \\ \frac{1}{n} \sum \tilde{y}_i^2 & \text{ reprezintă } \textit{dispersia explicată}. \end{aligned}$$

Pentru a avea o idee globală asupra calității aproximării se definește *coeficientul de corelație multiplă*, R , ca fiind cosinusul unghiului între $\mathbf{y}$ și $\mathbf{Xb}$, sau coeficientul de corelație între valorile inițiale și cele ajustate:

$$R = \text{cor}(\mathbf{y}, \tilde{\mathbf{y}}) = \text{cor}(\mathbf{y}, \mathbf{Xb})$$

Pătratul său poate fi exprimat sub diferite forme:

$$R^2 = \frac{\text{cov}^2(\mathbf{y}, \tilde{\mathbf{y}})}{\text{var}(\mathbf{y}) \text{var}(\tilde{\mathbf{y}})} = \frac{\text{var}(\tilde{\mathbf{y}})}{\text{var}(\mathbf{y})} = \frac{\sum \tilde{y}_i^2}{\sum y_i^2} = \frac{\text{dispersia explicată}}{\text{dispersia totală}}.$$

Termenul R^2 se numește *coeficient de determinare*. Dacă $R^2 = 1$, atunci $\tilde{y}_i = y_i$ pentru orice i , deci modelul liniar ajustează perfect datele.

În mod explicit, în funcție de datele inițiale, R^2 se scrie ca

$$R^2 = \frac{\mathbf{b}'\mathbf{X}'\mathbf{Xb}}{\mathbf{y}'\mathbf{y}} = \frac{\mathbf{y}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}}{\mathbf{y}'\mathbf{y}}$$

Acest coeficient descrie împărțirea dispersiei totale între dispersia explicată și cea reziduală:

$$\begin{cases} \text{dispersia explicată: } R^2 \text{var}(\mathbf{y}) = \text{var}(\tilde{\mathbf{y}}) \\ \text{dispersia reziduală: } (1 - R^2) \text{var}(\mathbf{y}) = \text{var}(\mathbf{e}) \end{cases} \\ \Rightarrow \text{dispersia totală: } \text{var}(\mathbf{y}) = \text{var}(\tilde{\mathbf{y}}) + \text{var}(\mathbf{e})$$

Astfel, prin minimizarea termenului $\sum e_i^2$ se maximizează termenul R^2 . Cu alte cuvinte, *metoda celor mai mici pătrate determină acea combinație liniară a variabilelor explicative ce maximizează corelația cu variabila explicată $\mathbf{y}$.*

Observația 4.1.1

Valoarea lui R nu poate fi totuși un criteriu absolut de apreciere a calității estimării. Într-adevăr, trebuie remarcat că introducerea în model a unei noi variabile explicative nu poate decât să micșoreze suma pătratelor ecarturilor și în consecință să crească valoarea lui R . Adăugând o dimensiune spațiului V_X distanța de la $\mathbf{y}$ la acest subspațiu scade.

4.1.3 Calitatea estimării

Până acum ne-am limitat la a rezolva o problemă pur numerică de interpolare, cu o măsură globală a calității dată de coeficientul de corelație multiplă, R . Ne propunem, în cele ce urmează, să testăm

- calitatea acestei interpolări și
- semnificația statistică a coeficienților de regresie,

ceea ce implică noi ipoteze asupra lui $\mathbf{y}$ și $\boldsymbol{\varepsilon}$.

Să presupunem că reziduul ε_i este efectul cumulat al unui mare număr de cauze neidentificate și în consecință îl putem considera ca o perturbație aleatoare. Acest punct de vedere, extins la cele n relații ale modelului, introduce un vector aleator de reziduuri, $\boldsymbol{\varepsilon}$, și definește $\mathbf{y} = \mathbf{X}\mathbf{b} + \boldsymbol{\varepsilon}$ ca vector aleator.

Tabelul 4.4.1. rezumă caracteristicile diferitelor elemente ale modelului.

TABELUL 4.1.1. CARACTERISTICILE ELEMENTELOR MODELULUI DE

$\mathbf{y} = \mathbf{X}\boldsymbol{\alpha} + \boldsymbol{\varepsilon}$	REGRESIE	
	Observat	Neobservabil
Aleator	$\mathbf{y}$	$\boldsymbol{\varepsilon}$
Nealeator	$\mathbf{X}$	$\boldsymbol{\beta}$

Se presupune că reziduurile ε_i au $M(\varepsilon_i) = 0$, au aceeași dispersie $\text{var}(\varepsilon_i) = \sigma^2$ și sunt două câte două necorelate, $\text{var}(\varepsilon_i, \varepsilon_j) = 0, \forall i = \overline{1, n}, j = \overline{1, n}$. Deci

$$M(\boldsymbol{\varepsilon}) = \mathbf{0}; \text{var}(\boldsymbol{\varepsilon}) = M(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}') = \sigma^2\mathbf{I}$$

ceea ce implică relațiile

$$M(\mathbf{y}) = \mathbf{X}\boldsymbol{\beta}; \text{var}(\mathbf{y}) = \text{var}(\boldsymbol{\varepsilon}) = \sigma^2\mathbf{I} \quad (4.1.4)$$

Vectorul $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ al coeficienților de regresie, fiind o funcție de $\mathbf{y}$, este la rândul său un vector aleator. Cu acestea se poate formula următoarea leamnă.

Lema 4.1.2

1. (a) $\mathbf{b}$ este un estimator nedeplasat al lui $\boldsymbol{\beta}$;

(b) $\text{var}(\mathbf{b}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$

Demonstrație.

- (a) Din formula 4.1.4

$$M(\mathbf{b}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'M(\mathbf{y}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \boldsymbol{\beta}.$$

- (b) Dispersia lui $\mathbf{b}$ se scrie ca

$$\text{var}(\mathbf{b}) = M((\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})').$$

Dar

$$\begin{aligned} \mathbf{b} - \boldsymbol{\beta} &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} - \boldsymbol{\beta} = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) - \boldsymbol{\beta} = \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\varepsilon}. \end{aligned}$$

Se obține deci

$$\begin{aligned} M((\mathbf{b} - \boldsymbol{\beta})(\mathbf{b} - \boldsymbol{\beta})') &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' M(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}') \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} = \\ &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \sigma^2 \mathbf{I} \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} = \\ &= \sigma^2 (\mathbf{X}'\mathbf{X})^{-1} \end{aligned}$$

■

Teorema 4.1.1 (Gauss-Markov) $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$ este estimatorul de dispersie minimă al lui $\boldsymbol{\beta}$ în clasa estimatorilor liniari nedeplasați.

Demonstrație. Fie $\mathbf{B}\mathbf{y}$ un alt estimator liniar nedeplasat al lui $\boldsymbol{\beta}$ și fie $(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} - \mathbf{B}\mathbf{y}$ diferența dintre cei doi estimatori. Cum aceștia sunt nedeplasați rezultă că

$$(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \mathbf{B}\mathbf{X}\boldsymbol{\beta}.$$

Această relație este adevărată pentru orice $\boldsymbol{\beta}$, deci

$$\mathbf{B}\mathbf{X} = \mathbf{I}_{p+1}.$$

Să alegem $\mathbf{B} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' + \mathbf{C}$. Cum $\mathbf{B}\mathbf{X} = \mathbf{I}_{p+1}$ rezultă $\mathbf{C}\mathbf{X} = \mathbf{0}$. Matricea de varianță-covarianță a lui $\mathbf{B}\mathbf{y}$ este:

$$\begin{aligned} \text{var}(\mathbf{B}\mathbf{y}) &= \mathbf{B} \text{var}(\mathbf{y}) \mathbf{B}' = \left[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' + \mathbf{C} \right] \sigma^2 \mathbf{I} \left[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' + \mathbf{C} \right]' = \\ &= \sigma^2 \left[(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} + \mathbf{C}\mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{C}' + \mathbf{C}\mathbf{C}' \right] \end{aligned}$$

Cum $\mathbf{C}\mathbf{X} = \mathbf{0}$ rezultă, conform lemei 4.1.2:

$$\begin{aligned} \text{var}(\mathbf{B}\mathbf{y}) &= \sigma^2 \left[(\mathbf{X}'\mathbf{X})^{-1} + \mathbf{C}\mathbf{C}' \right] = \\ &= \text{var}(\mathbf{b}) + \sigma^2 \mathbf{C}\mathbf{C}' \end{aligned}$$

Așadar, fiecare componentă b_i a lui $\mathbf{b}$ are o dispersie mai mică decât $(\mathbf{B}\mathbf{y})_i$ iar pe de altă parte $\text{var}(\mathbf{B}\mathbf{y}) - \text{var}(\mathbf{b})$ este semi-pozitiv definită (într-adevăr matricea $\mathbf{C}\mathbf{C}'$ este simetrică iar termenii de pe diagonala principală sunt nenegativi). ■

Să notăm că σ^2 este dispersia teoretică a reziduurilor și în general nu este cunoscută. Termenul σ^2 se poate estima prin s^2 , dispersia empirică a ecarturilor, calculată după ajustare, deoarece:

Lema 4.1.3

$$s^2 = \frac{\|\mathbf{y} - \tilde{\mathbf{y}}\|^2}{n - p} = \frac{\|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2}{n - p}$$

este un estimator nedeplasat al lui σ^2 .

Demonstrație. Să considerăm triunghiul dreptunghic ale cărui vârfuri sunt extremitățile vectorilor $\mathbf{y}$, $\mathbf{Xb}$, și $\mathbf{X}\beta$ (fig. 4.1.1.). S-a notat cu $\mathbf{P}_X$ proiectorul pe V_X - subspațiul generat de variabilele exogene $x_1, \dots, x_p$, și cu $\mathbf{I} - \mathbf{P}_X$ proiectorul pe $V_X^\perp$. Deoarece $\mathbf{e} = \mathbf{y} - \mathbf{Xb}$ este perpendicular pe V_X se observă că

$$\mathbf{y} - \mathbf{Xb} = (\mathbf{I} - \mathbf{P}_X) \boldsymbol{\varepsilon}.$$

Așadar, $\boldsymbol{\varepsilon}$ se descompune în $\mathbf{Xb} - \mathbf{X}\beta$ în V_X și $\mathbf{y} - \mathbf{Xb}$ în $V_X^\perp$. Cu acestea, având în vedere că $\mathbf{I} - \mathbf{P}_X$, fiind proiector, este simetric:

$$(\mathbf{I} - \mathbf{P}_X)' = \mathbf{I} - \mathbf{P}_X$$

și idempotent:

$$\mathbf{I} - \mathbf{P}_X = (\mathbf{I} - \mathbf{P}_X)^2,$$

rezultă

$$\begin{aligned} \|\mathbf{y} - \mathbf{Xb}\|^2 &= \boldsymbol{\varepsilon}' (\mathbf{I} - \mathbf{P}_X)' (\mathbf{I} - \mathbf{P}_X) \boldsymbol{\varepsilon} = \\ &= \boldsymbol{\varepsilon}' (\mathbf{I} - \mathbf{P}_X) \boldsymbol{\varepsilon} = \\ &= \sum_{i,j} \alpha_{ij} \varepsilon_i \varepsilon_j, \end{aligned}$$

unde s-au notat cu α_{ij} componentele lui $\mathbf{I} - \mathbf{P}_X$.

Rezultă

$$\begin{aligned} M\left(\|\mathbf{y} - \mathbf{Xb}\|^2\right) &= \sum_{i,j} \alpha_{ij} M(\varepsilon_i \varepsilon_j) = \\ &= \sum_{i,j} \alpha_{ij} \sigma^2 \delta_{ij} = \\ &= \sigma^2 \sum_{i=1}^n \alpha_{ii} = \sigma^2 \text{tr}(\mathbf{I} - \mathbf{P}_X) \end{aligned}$$

unde δ_{ij} este simbolul lui Kroneker. Dar urma unui proiector este egală cu rangul său (deoarece valorile sale proprii sunt 0 sau 1) adică este egală cu dimensiunea spațiului de sosire care este aici $V_X^\perp$. Având în vedere că $\dim(V_X) = p$ rezultă $\dim(V_X^\perp) = n - p$, deci

$$M\left(\|\mathbf{y} - \mathbf{Xb}\|^2\right) = \sigma^2 (n - p).$$

■

Dacă notăm cu $\mathbf{V}$ matricea de covarianță empirică a variabilelor explicative presupuse centrate ($\mathbf{V} = \frac{1}{n} \mathbf{X}' \mathbf{X}$) se obține relația

$$\text{var}(\mathbf{b}) = \frac{\sigma^2}{n} \mathbf{V}^{-1}$$

Să remarcăm dualitatea care există între variabilele explicative și coeficienții acestor variabile în modelul de regresie liniară. Variabile explicative necorelate (matricea $\mathbf{V}$ diagonală) implică coeficienți de regresie necorelați.

Rezultatele precedente permit să imaginăm diferite teste statistice în ipoteze suficient de generale. Într-adevăr, dacă specificăm legea de repartiție a reziduurilor, atunci putem obține diferite teste clasice pe care le vom aminti în cele ce urmează fără demonstrație.

În continuare presupunem

$$\Omega : \varepsilon \sim N(\mathbf{0}_{n \times 1}, \sigma^2 \mathbf{I}_{n \times n}).$$

În acest caz, densitatea de probabilitate a vectorului aleator $\mathbf{y}$ este:

$$f(\mathbf{y}; \boldsymbol{\beta}, \sigma) = \frac{1}{(\sigma\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\sigma^2} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})' (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})\right)$$

deoarece $\mathbf{y}$ este un vector aleator normal n dimensional, de medie $\mathbf{X}\boldsymbol{\beta}$ și matrice de varianță-covarianță $\sigma^2 \mathbf{I}$.

Lema 4.1.4

Estimatorii de verosimilitate maximă ai lui $\boldsymbol{\beta}$ și σ^2 sunt

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \text{ și} \\ \hat{\sigma}^2 &= \frac{1}{n} \|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2 = \frac{1}{n} \|\mathbf{e}\|^2, \text{ care este deplasat.} \end{aligned}$$

Cum transformările liniare ale unui vector gaussian nu schimbă legea sa de repartiție, $\mathbf{b}$ este un vector normal p dimensional, de medie $\boldsymbol{\beta}$ și matrice de varianță-covarianță $\sigma^2 (\mathbf{X}'\mathbf{X})^{-1}$.

Tot din ipoteza Ω se mai poate deduce că²

$$\frac{\|\mathbf{e}\|^2}{\sigma^2} \sim \chi^2(n)$$

iar teorema lui Pitagora pentru triunghiul dreptunghic determinat de extremitățile vectorilor $\mathbf{y}$, $\mathbf{X}\mathbf{b}$, și $\mathbf{X}\boldsymbol{\beta}$ se transformă în teorema lui Cochran rezultând

$$\frac{\|\mathbf{X}\boldsymbol{\beta} - \mathbf{X}\mathbf{b}\|^2}{\sigma^2} \sim \chi^2(p) \text{ și } \frac{\|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2}{\sigma^2} \sim \chi^2(n-p).$$

Cele două variabile sunt independente, ca forme pătratice de rang p respectiv $n-p$ (rangul proiectoarelor) de n variabile normale centrat-reduce.

Pornind de la distribuția lui $\frac{\|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2}{\sigma^2}$ se pot construi intervale de încredere pentru σ .

²Fie $x_1, x_2, \dots, x_n$ variabile independente, distribuite după o lege normală standard. Atunci variabila obținută prin însumarea pătratelor lor, $\chi^2 = x_1^2 + x_2^2 + \dots + x_n^2$ urmează o distribuție chi-pătrat cu n grade de libertate notată $\chi^2(n)$.

Pentru a testa dacă o variabilă explicativă x_k are o influență reală asupra variabilei endogene y se consideră următoarea pereche de ipoteze:

$$H_0 : \beta_k = 0 \text{ cu alternativa } H_A : \beta_k \neq 0.$$

Statistica testului este

$$t_k = \frac{b_k}{s_k}$$

unde s_k este estimația abaterii standard a coeficientului b_k dată de formula $s_k = \sqrt{\frac{\|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2}{n-p} v_{kk}}$, cu v_{kk} al k -lea element de pe diagonala matricii $(\mathbf{X}'\mathbf{X})^{-1}$.

În ipoteza $\Omega \cap H_0$, statistica t_k este repartizată $t(n-p)$ (*Student* cu $n-p$ grade de libertate, deoarece modelul estimează p coeficienți). Fie

$$p_k = P(|t(n-p)| \geq t_k).$$

Dacă $p_k < 0,05$ se repinge ipoteza conform căreia variabila x_k nu are o influență reală asupra lui y cu un grad de încredere de 95%.

Testul de mai sus poate fi extins la o combinație liniară oarecare de coeficienți.

În cele de mai sus am văzut cum se poate testa succesiv nulitatea fiecărui coeficient. Totuși, răspunsurile la probleme de tipul " $\beta_1 = 0$ fără nicio presupunere asupra lui β_2 " apoi " $\beta_2 = 0$ fără nicio presupunere asupra lui β_1 " nu determină răspunsul la o problemă de tipul " $\beta_1 = 0$ și simultan $\beta_2 = 0$ " deoarece predictorii pot fi foarte corelați între ei. De aici reiese utilitatea testării nulității simultane a mai multor coeficienți de regresie.

Dacă presupunem, fără a pierde din generalitate, că primii q coeficienți de regresie sunt zero atunci perechea de ipoteze a testului compus este

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_q = 0 \text{ (și restul } p - q \text{ coeficienți sunt oarecare)}$$

cu alternativa

$$H_A : \text{cel puțin unul dintre primii } q \text{ coeficienți este nenul.}$$

Să notăm cu $\mathbf{X}_{H_0}$ ultimele $p - q$ coloane ale lui $\mathbf{X}$ și cu $\boldsymbol{\beta}_{H_0}$ ultimele $p - q$ componente ale lui $\boldsymbol{\beta}$. Modelul de regresie se scrie matriceal în cele două ipoteze astfel:

$$\begin{aligned} H_0 & : \mathbf{y}_0 = \mathbf{X}_{H_0}\boldsymbol{\beta}_{H_0} + \boldsymbol{\varepsilon}_0 \text{ (modelul redus),} \\ H_A & : \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \text{ (modelul complet).} \end{aligned}$$

Se consideră statistica

$$F = \frac{(\|\mathbf{y} - \tilde{\mathbf{y}}_0\|^2 - \|\mathbf{y} - \tilde{\mathbf{y}}\|^2) / q}{\|\mathbf{y} - \tilde{\mathbf{y}}\|^2 / (n - p)}$$

care în ipoteza $\Omega \cap H_0$ este repartizată Fisher cu q și $n - p$ grade de libertate³.

Se notează

$$S_0 = \|\mathbf{y} - \tilde{\mathbf{y}}_0\|^2 \text{ și } S_1 = \|\mathbf{y} - \tilde{\mathbf{y}}\|^2.$$

Dacă diferența între cele două cantități S_0 și S_1 este mare, deci F este mare, atunci efectul primelor q variabile este important și ipoteza nulă va fi respinsă; cele q variabile $x_1, \dots, x_q$ influențează simultan $\mathbf{y}$.

Să observăm că sunt necesare două estimări succesive pentru a calcula S_1 și S_0 .

Dacă dorim să testăm adecvarea modelului liniar la datele observate, atunci vom testa nulitatea coeficientului de determinare adică:

$$H_0 : R^2 = 0 \text{ (toți coeficienții de regresie liniari sunt zero)}$$

cu alternativa

$$H_A : R^2 \neq 0$$

Se consideră statistica

$$F_R = \frac{R^2/p}{(1 - R^2)/(n - p)}$$

care, în ipoteza $\Omega \cap H_0$, este repartizată Fisher cu p și $n - p$ grade de libertate. Ipoteza H_0 (a non-regresiei) corespunde și nulității coeficientului de corelație multiplă teoretic, $\mathcal{R}$, în cadrul regresiei între variabilele aleatoare. În ipoteza alternativă, $H_a : \mathcal{R}^2 \neq 0$, se poate arăta că R^2 este un estimator deplasat al lui $\mathcal{R}^2$, motiv pentru care unii autori folosesc în loc de R^2 o formă ajustată a acestuia, adică

$$\widehat{R}^2 = \frac{(n - 1)R^2 - p}{n - p}$$

care elimină deplasarea în $1/n$ dar poate conduce la valori negative a lui $\mathcal{R}^2$ când acesta este foarte mic.

Un calcul elementar arată că

$$\widehat{\sigma}^2 = \frac{n}{n - 1} (1 - \widehat{R}^2) s_y^2.$$

Dacă se dorește calcularea unui interval de încredere pentru o valoare y_0 prezisă de modelul de regresie liniară multiplă $(\mathbf{y}, \mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$, care corespunde unei observații suplimentare pentru care variabilele explicative iau valorile $x_{10}, x_{20}, \dots, x_{p0}$ atunci, considerând $\mathbf{x}'_0 = (1, x_{10}, x_{20}, \dots, x_{p0})$, $\tilde{\mathbf{y}}_0 = \mathbf{x}'_0 \mathbf{b}$ este o variabilă aleatoare normală de medie $\mathbf{x}'_0 \boldsymbol{\beta}$ și dispersie $\sigma^2 (\mathbf{x}'_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0)$.

³Fie variabilele aleatoare $X \sim \chi^2(\nu_1)$ și $Y \sim \chi^2(\nu_2)$. Atunci variabila aleatoare $F \sim \frac{\chi^2(\nu_1)}{\chi^2(\nu_2)}$ urmează o repartiție Fisher cu ν_1 și ν_2 grade de libertate.

În ipoteza Ω , statistica

$$\frac{\mathbf{y}_0 - \tilde{\mathbf{y}}_0}{\hat{\sigma} \sqrt{1 + \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0}}$$

este repartizată $t(n-p)$, ceea ce permite estimarea unui interval de încredere pentru “valoarea adevărată” y_0 cu un prag de semnificație dat.

4.1.4 Studiul reziduurilor și al observațiilor aberante

Studiul reziduurilor este important deoarece:

- poate evidenția posibilele observații aberante sau pe cele care joacă un rol important în determinarea funcției de regresie;
- adesea este singura modalitate de a verifica empiric ipotezele modelului (liniaritate, homoscedasticitate⁴ etc.). Dacă aceste ipoteze sunt corecte atunci graficul reziduurilor în funcție de variabilele explicative nu trebuie să prezinte nicio tendință.

Lema 4.1.5

$$\text{var}(\mathbf{e}) = \sigma^2 \left(\mathbf{I} - \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \right)$$

Demonstrație. Deoarece $\tilde{\mathbf{y}} \perp \mathbf{e}$ (din construcție) și

$$\mathbf{y} = (\mathbf{y} - \mathbf{X}\mathbf{b}) + \mathbf{X}\mathbf{b} = \mathbf{e} + \tilde{\mathbf{y}}$$

rezultă

$$\text{var}(\mathbf{y}) = \text{var}(\mathbf{e}) + \text{var}(\tilde{\mathbf{y}}).$$

Din ipoteza Ω rezultă

$$\sigma^2 \mathbf{I} = \text{var}(\mathbf{e}) + \sigma^2 \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'$$

deoarece, conform lemei 4.1.2

$$\text{var}(\tilde{\mathbf{y}}) = \text{var}(\mathbf{X}\mathbf{b}) = \mathbf{X} \text{var}(\mathbf{b}) \mathbf{X}' = \sigma^2 \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'.$$

Deci $\text{var}(\mathbf{e}) = \sigma^2 \left(\mathbf{I} - \mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \right)$ ■

Lema 4.1.5 arată că reziduurile sunt, în general, corelate.

Notând cu

$$h_i = \left[\mathbf{X} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' \right]_{ii}$$

obținem

$$V(e_i) = (1 - h_i) \sigma^2$$

⁴La date bivariate, variabila $\mathbf{y}$ prezintă *homoscedasticitate* dacă împrăștierea valorilor y nu depinde de $\mathbf{x}$. Grafic, secțiunile verticale în diagrama de împrăștiere prezintă distribuții similare ale norilor de puncte. Noțiunea contrară este cea de *heteroscedasticitate*.

cu $\frac{1}{n} \leq h_i \leq 1$ și $\sum_{i=1}^n h_i = p$ deoarece urma unui proiector este egală cu rangul său (valorile sale proprii fiind 0 sau 1) iar o estimatie a dispersiei reziduului este $s^2(1 - h_i)$.

Definiția 4.1.2 Se numește *reziduu studentizat* mărimea

$$\frac{e_i}{s\sqrt{1 - h_i}} = \frac{(y_i - \tilde{y}_i)}{s\sqrt{1 - h_i}}.$$

Când n este mare, reziduurile studentizate trebuie să rămână în intervalul $(-2, 2)$.

Un reziduu mare poate indica o valoare aberantă. Pe de altă parte, o valoare poate fi aberantă fără ca reziduuul său să fie important (fig. 4.1.2).




FIG. 4.1.2. VALOARE ABERANTĂ CU REZIDUU ≈ 0

Din acest motiv se recomandă studiul influenței fiecărei observații asupra rezultatului.

Să începem prin a studia *influența unei observații asupra propriei predicții*.

Definiția 4.1.3 Se numește *reziduu prognozat* ecartul $y_i - \tilde{y}_{(-i)}$ unde cu $\tilde{y}_{(-i)}$ s-a notat prognoza lui y_i dată de modelul liniar ajustat pe baza celor $n - 1$ observații obținute prin excluderea observației i .

Se poate arăta că reziduuul prognozat este $\frac{y_i - \tilde{y}_i}{1 - h_i}$ ([53]). Se recomandă deci prudență față de observațiile cu h_i mare.

Mărimea

$$Press = \sum_{i=1}^n \left(\frac{y_i - \tilde{y}_i}{1 - h_i} \right)^2$$

este o măsură a puterii predictive a modelului.

Interesantă pentru demersul nostru este și *influența unei observații asupra coeficienților regresiei*.

Definiția 4.1.4 Se numește *distanță Cook* mărimea:

$$D_i = \frac{(\mathbf{b} - \mathbf{b}_{(-i)})' (\mathbf{X}'\mathbf{X}) (\mathbf{b} - \mathbf{b}_{(-i)})}{p\tilde{s}^2} = \frac{\|\tilde{\mathbf{y}} - \tilde{\mathbf{y}}_{(-i)}\|}{p\tilde{s}^2}$$

(deoarece $\tilde{\mathbf{y}} = \mathbf{X}\mathbf{b}$ și $\tilde{\mathbf{y}}_{(-i)} = \mathbf{X}\mathbf{b}_{(-i)}$).

Distanța Cook măsoară ecartul dintre $\mathbf{b}$ și $\mathbf{b}_{(-i)}$ și o valoare supraunitară a sa reprezintă un indicator al unei influențe anormale a observației i asupra coeficienților de regresie.

4.1.5 Tehnici de stabilizare a coeficienților de regresie

Sursa principală de instabilitate în estimarea coeficientului β este redundanța predictorilor. Statistic, această situație se reflectă într-o corelație puternică între variabilele explicative.

Dacă predictorii sunt foarte corelați între ei $\mathbf{X}'\mathbf{X}$ este prost condiționată (adică valoarea determinantului este apropiată de 0) și inversa acestei matrici va avea coeficienți foarte mari. În această situație, având în vedere că $\mathbf{b} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$, coeficienții de regresie vor fi estimați imprecis și predicția $\tilde{\mathbf{y}}$ va fi obținută cu erori mari chiar dacă R^2 este aproape de 1.

Efectul coliniarității între predictorii se măsoară cu ajutorul:

- factorilor de inflație a dispersiei și al
- valorilor proprii ale matricii de corelație.

În cele ce urmează vom presupune că toate variabilele sunt centrat-reduce, ceea ce nu influențează R^2 , însă $\mathbf{X}'\mathbf{X}$ devine egal cu $n\mathbf{R}$, unde $\mathbf{R}$ este matricea de corelație a predictorilor. Astfel

$$\text{var}(\mathbf{b}) = \sigma^2 \frac{\mathbf{R}^{-1}}{n} \text{ și } \text{var}(b_i) = \frac{\sigma^2}{n} (\mathbf{R}^{-1})_{ii}.$$

Dacă cele p variabile explicative sunt ortogonale, regresia multiplă se reduce la p regresii simple: $\text{var}(b_i) = \frac{\sigma^2}{n}$.

Termenul $(\mathbf{R}^{-1})_{ii}$ se numește *factor de inflație a dispersiei* pentru că reprezintă un factor de multiplicitate a dispersiei ca urmare a redundanței (multicoliniarității) predictorilor. Media celor p factori de inflație este utilizată uneori ca indice global al multicoliniarității.

Să considerăm descompunerea $\mathbf{R} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}'$ unde $\mathbf{\Lambda}$ este matricea diagonală a valorilor proprii și $\mathbf{U}$ este matricea vectorilor proprii ai lui $\mathbf{R}$. În acest caz

$$\mathbf{R}^{-1} = \mathbf{U}\mathbf{\Lambda}^{-1}\mathbf{U}'$$

rezultând

$$\text{var}(b_i) = \frac{\sigma^2}{n} \sum_{j=1}^p \frac{(u_{ij})^2}{\lambda_j}.$$

$\text{var}(b_i)$ depinde de inversele valorilor proprii ale lui $\mathbf{R}$. Când predictorii sunt puternic corelați, ultimele valori proprii sunt aproape nule, de unde rezultă instabilitatea lui b_i .

Conform teoremei Gauss-Markov, metoda celor mai mici pătrate furnizează estimatorii de dispersie minimă ai lui β_i în clasa estimatorilor nedeplasați.

Cum pătratul erorii este egal cu dispersia plus pătratul deplasării, este posibil ca în anumite condiții să obținem estimări mai precise ale coeficienților cu o deplasare ușoară.

În cele ce urmează vom considera doar două tehnici de obținere de coeficienți stabili:

- Regresia pe componente principale;
- Regresia Ridge;

Metodele de selecție a variabilelor (subcapitolul 4.1.6) pot fi și ele considerate ca remedii posibile ale multicolarității.

Regresia pe componente principale revine la înlocuirea celor p variabile explicative cu cele p componente principale (demers posibil deoarece acestea generează același spațiu V_X) și efectuarea regresiei multiple pe acestea din urmă. Componentele principale fiind necorelate (lema 1.2.9), conform observației de mai sus regresia multiplă se reduce la p regresii simple iar

$$\tilde{\mathbf{y}} = \sum_{i=1}^p \alpha_i \mathbf{c}_i \text{ cu } \alpha_i = \frac{\text{cor}(\mathbf{y}, \mathbf{c}_i)}{\sqrt{\lambda_i}} s_{\mathbf{y}}$$

unde am notat cu $\mathbf{c}_i$ componentele principale. Este suficient să exprimăm $\mathbf{c}_i$ în funcție de variabilele inițiale pentru a obține o formulă de regresie liniară multiplă.

Când coliniaritatea predictorilor este exactă, atunci $\lambda_p = 0$ iar o soluție a ecuațiilor normale este $\tilde{\mathbf{y}} = \sum_{i=1}^{p-1} \alpha_i \mathbf{c}_i$.

Dacă se rețin doar q componente principale, eliminându-le pe cele de dispersie mică, atunci se obține o soluție aproximativă proiectând $\mathbf{y}$ pe un subspațiu al lui V_X .

Să observăm că acele componente principale care au o dispersie mare nu sunt întotdeauna cele mai explicative și că este mai util să le ordonăm în funcție de coeficienții lor de corelație cu $\mathbf{y}$.

Regresia Ridge consideră următorii estimatori pentru β

$$\mathbf{b}(k) = (\mathbf{X}'\mathbf{X} + k\mathbf{I})^{-1} \mathbf{X}'\mathbf{y}$$

unde k este o constantă pozitivă ce trebuie determinată. $\mathbf{b}(0)$ este estimatorul celor mai mici pătrate.

Se poate arăta [53] că există într-adevăr un k astfel încât

$$M(\|\mathbf{b}(k) - \mathbf{b}\|^2) \leq M(\|\mathbf{b} - \beta\|^2) = \frac{\sigma^2}{n} \sum_{i=1}^p \frac{1}{\lambda_i}$$

Valoarea optimală a lui k depinzând de β , necunoscut. În practică se variază k de la 0 la 1 pe datele centrat-reduce și se studiază variațiile lui $b_j(k)$ (graficul *Trace Ridge*).

4.1.6 Tehnici de selecție a variabilelor

Pentru a micșora numărul de predictori, a crește viteza de calcul și a obține formule stabile cu o putere predictivă bună, se „explică” $\mathbf{y}$ doar prin q predictori în loc de $p \gg q$.

Criteriile de căutare a celor q predictori depind de scopul regresiei: reconstituirea lui $\mathbf{y}$, prognoza de valori noi sau estimarea precisă a unui model.

Criteriul coeficientului de determinare R^2 , este bine adaptat primului obiectiv și este cel mai utilizat în programele de regresie pas cu pas. Așa cum menționam mai înainte, el variază monoton cu numărul variabilelor și deci nu poate fi folosit pentru a alege cardinalul mulțimii de predictori.

Dacă obiectivul este acela de a minimiza eroarea de prognoză, se recomandă folosirea lui s^2 sau a lui *Press* (mai greu de calculat). s^2 nu variază monoton cu numărul de variabile deoarece

$$s^2 = \frac{n}{n-p} (1 - R^2) s_y^2$$

În schimb s^2 variază monoton cu $\hat{R}^2$, coeficientul de determinare ajustat. Prin urmare, este mai interesant să considerăm $\hat{R}^2$ drept criteriu de alegere (*criteriul coeficientului de determinare ajustat*), deoarece astfel se pot compara formule de regresie cu număr diferit de variabile și se poate alege acea formulă care minimizează s^2 sau maximizează $\hat{R}^2$.

Implementarea unuia dintre criteriile de mai sus se poate face:

- printr-o căutare exhaustivă sau
- prin metode de căutare pas cu pas.

Căutarea exhaustivă este recomandată atunci când p nu este prea mare și este posibilă investigarea tuturor formulelor: sunt C_p^q formule de q variabile, deci în total $2^p - 1$ regresii.

Dacă q este fixat, va fi aleasă formula care maximizează pe R^2 iar dacă q nu este fixat, va fi aleasă formula care minimizează pe s^2 .

Metodele de căutare pas cu pas procedează prin eliminarea sau adăugarea succesivă de variabile.

- *Metoda descendentă* constă în eliminarea variabilei celei mai puțin semnificative dintre cele p variabile - în general aceea care diminuează cel mai puțin pe R^2 . Se recalculează coeficienții de regresie până la eliminarea a $p - 1$ variabile sau în funcție de un test statistic precizat.
- *Metoda ascendentă* procedează în sens invers: se pornește de la cea mai bună regresie într-o variabilă și se adaugă acea variabilă care maximizează pe R^2 .

- *Metoda stepwise* reprezintă o perfecționare a algoritmilor precedenți. La fiecare pas se efectuează, în plus, teste de semnificație de tip Student sau Fisher pentru a nu introduce o variabilă ne semnificativă și pentru a elimina eventual variabilele deja introduse care nu mai sunt atât de informative în noul context. Algoritmul se termină când nu mai poate fi adăugată sau scoasă vreo variabilă.

Aceste metode nu dau obligatoriu cea mai bună regresie în q variabile și nici același rezultat, dar sunt ușor de implementat. Ele exclud posibilitatea de a elimina o variabilă semnificativă. În acest context trebuie să atragem atenția asupra faptului că dacă se cunoaște că o variabilă trebuie să figureze într-un model, din considerente fizice de exemplu, aceasta nu trebuie eliminată doar pentru că un test statistic a declarat-o ne semnificativă.

4.1.7 Exemplu

Descrierea datelor

În urma unor măsurători ecografice realizate asupra a 414 nenăscuți s-au obținut valorile din tabelul A.7 (Anexă).

Variabilele din acest tabel reprezintă:

- predictorii
 - DBP = diametrul biparietal,
 - PC = perimetrul cefalic,
 - PA = perimetrul abdominal,
- variabila dependentă
 - GN = greutatea la naștere.

Ne propunem construirea unui model de regresie capabil să determine, pe baza datelor existente, greutatea la naștere pentru noi subiecți pentru care se cunosc valorile DBP, PC, PA. Altfel spus, utilizând valorile din tabelul A.7., trebuie găsiți coeficienții $\beta_0, \beta_1, \beta_2, \beta_3$ care permit predicția optimă a variabilei dependente $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3}$, unde y_i reprezintă greutatea la naștere a subiectului i și x_{i1}, x_{i2}, x_{i3} sunt valori ale predictorilor mai sus menționați pentru subiectul respectiv.

Efectuarea analizei și interpretarea rezultatelor

În programul STATISTICA, opțiunea pentru analiza de regresie este disponibilă în meniul *Statistics, Advanced Linear/Nonlinear Models, General Regression Models*. În fereastra activată (fig. 4.1.3) se optează pentru modelul regresiei multiple, având în vedere existența mai multor variabile predictor, și se apasă *OK*.