

1. În ACP, definiți o măsură globală și una locală a calității reprezentării în planul factorial. Prezentați pe scurt implementarea acestor măsuri.

Răspuns:

- **Măsura globală:** Inerția totală explicată de primele componente principale. Se calculează ca suma valorilor proprii asociate axelor factoriale selectate, raportată la suma totală a valorilor proprii.

$$\text{Inerție explicată} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^p \lambda_j}$$

- **Măsura locală:** Cosinusul unghiului dintre vectorul ce reprezintă un individ și axele factoriale, denumit **calitatea reprezentării ($\cos^2$)**.

).

$$\cos^2 = \frac{\text{Coordonata pe axa factorială}^2}{\text{Suma coordonatelor pe toate axe}^2}$$

- **Implementare:**
 - Se calculează valori proprii și vectori proprii ai matricei de covarianță.
 - Se proiectează indivizii în spațiul factorial.
 - Se determină contribuția fiecărei axe prin inerție și $\cos^2$.

Interpretare:

- **Inerția explicată** arată cât de bine redă primele componente structura datelor.
- **$\cos^2$** arată cât de bine este reprezentat un punct pe o anumită axă factorială.
-

2. Enunțați etapele algoritmului de clasificare mixtă.

Răspuns:

1. **Inițializare** – Se stabilește un set de clase inițiale, fie aleator, fie pe baza unei metode de clustering ierarhic.
2. **Alocare** – Se atribuie fiecărui individ o clasă bazată pe criterii de similaritate.
3. **Estimare** – Se recalibrează centrele de clasă prin medierea caracteristicilor indivizilor asignați.
4. **Reafectare** – Se verifică dacă un individ ar trebui să fie mutat într-o altă clasă pentru a optimiza criteriul ales (ex. minimizarea distanței intra-clasă).

5. **Iterare** – Se repetă etapele 3 și 4 până la convergență.

3. Arătați că în ACS, spațiul punctelor linie este de dimensiune $p-1$ și că centrul de greutate al profilurilor linie aparține H .

Răspuns:

- În **ACS (Analiza Corespondențelor Simple)**, matricea de date este normalizată astfel încât suma elementelor este 1.
 - Profilurile linie sunt puncte într-un spațiu p -dimensional, dar deoarece fiecare profil este normalizat (suma elementelor = 1), acestea sunt constrânse într-un **subspațiu de dimensiune $p-1$** .
 - Centrul de greutate al profilurilor linie este dat de media ponderată a punctelor linie, care respectă aceleași constrângeri și deci **se află în același subspațiu H de dimensiune $p-1$** .
-

4. Care sunt ipotezele fundamentale ce permit în ACM transformarea unui tabel de date primare în tabel disjunctiv complet? Ce este tabelul Burt? Care este efectivul total al tabelului Burt?

Răspuns:

- **Ipoteze fundamentale:**
 1. Variabilele sunt **nominale**.
 2. Se utilizează **codificarea disjunctivă completă** (fiecare categorie devine o coloană binară).
 3. Se păstrează informația despre frecvențe prin ponderare adecvată.
 - **Tabelul Burt:**
 - Matrice de **autocorelare** între variabilele categorice.
 - Este o matrice de **contingență bloc**, unde fiecare bloc reprezintă frecvențele comune între două variabile.
 - **Efectiv total:** suma tuturor elementelor din tabelul Burt este **egală cu numărul total de indivizi** din setul de date.
-

5. Enunțați și caracterizați pe scurt 3 strategii de agregare pe disimilarități.

Răspuns:

1. **Metoda legăturii complete (Complete Linkage)**
 - Se calculează **distanța maximă** între grupurile ce urmează a fi unite.
 - Produce **clustere compacte** și de dimensiuni uniforme.
2. **Metoda legăturii medii (Average Linkage)**
 - Se calculează **media tuturor distanțelor** între punctele din cele două clustere.
 - Evită extremele și produce grupări echilibrate.

3. Metoda Ward

- Se bazează pe **criteriul de minimizare a varianței intra-cluster**.
- Produce clustere de dimensiuni apropiate, optimizând dispersia.

6. Arătați că, în cazul unei regresii liniare simple, adică cu un singur predictor, media empirică a lui Y este egală cu $B_0 + B_1 \cdot$ media empirică a lui X.

Răspuns:

Într-o regresie liniară simplă:

$$Y = B_0 + B_1 X + \varepsilon$$

Dacă luăm **media pe ambele părți**:

$$\mathbb{E}[Y] = B_0 + B_1 \mathbb{E}[X] + \mathbb{E}[\varepsilon]$$

Cum **eroarea medie este 0** ($\mathbb{E}[\varepsilon] = 0$), obținem:

$$\bar{Y} = B_0 + B_1 \bar{X}$$

ceea ce confirmă relația cerută.

1. În ACP normată, enunțați două criterii pentru ca o observație să fie considerată posibil aberantă.

În **Analiza în Componente Principale (ACP) normată**, o observație este considerată **aberrantă** dacă îndeplinește unul dintre următoarele criterii:

1. Valoare mare a scorului pe una dintre componentele principale

- Dacă un individ are o valoare foarte mare pe una dintre componentele principale, aceasta poate indica un **outlier**.
- Se verifică dacă $|F_{ik}| > 3 \cdot \sigma_k$, unde:
 - F_{ik} este coordonata individului i pe componenta k ,
 - σ_k este abaterea standard a componentei.

2. Valoare mică a coeficientului $\cos^2$ pentru primele componente principale

- **Cosinusul pătrat al unghiului** dintre vectorul individului și axele factoriale indică calitatea reprezentării.
- Dacă $\cos^2$ este foarte mic (ex. sub **0.2**), individul nu este bine reprezentat în spațiul factorial și poate fi un **outlier**.

$$\cos^2(i, k) = \frac{F_{ik}^2}{\sum_j F_{ij}^2}$$

unde:

- F_{ik} = coordonata individului i pe axa k ,
- $\sum_j F_{ij}^2$ = suma pătratelor coordonatelor individului pe toate axe.

Interpretare:

- **Primul criteriu** identifică observațiile care au **valori extreme** pe anumite componente principale.
- **Al doilea criteriu** identifică observațiile care sunt **slab reprezentate** în planul factorial.

Aceste criterii sunt utilizate pentru a **detecta și analiza outlierii** într-o analiză în componente principale.

2. Enunțați etapele algoritmului de clasificare mixtă.

Algoritmul de **clasificare mixtă** combină metodele **ierarhice** și **partitionale** pentru a optimiza gruparea datelor. Acesta include următorii pași:

1. **Construirea unei clasificări inițiale**
 - Se aplică o **metodă de clustering ierarhic**, cum ar fi **Ward** sau **Linkage complet**, pentru a obține o ierarhizare inițială a datelor.
2. **Stabilirea numărului optim de clustere**
 - Se utilizează un **criteriu de validare** (ex: indicele silhouette, criteriul lui Calinski-Harabasz) pentru a determina numărul de grupuri relevante.
3. **Inițializarea unei metode partitionale**
 - Se aplică **K-means** sau **K-medoids**, folosind ca puncte de pornire centrele grupurilor obținute anterior.
4. **Atribuirea indivizilor în grupuri**
 - Se calculează **distanțele** fiecărui individ față de centrele grupurilor și se atribuie fiecăruia clusterul cel mai apropiat.
5. **Iterarea și recalcularea centroidelor**

- Se actualizează centrele grupurilor în funcție de noile asignări și se repetă procesul până când **criteriul de convergență** este îndeplinit (ex. schimbări minime între iterații).
6. **Evaluarea performanței clasificării**
- Se utilizează **indicele Dunn**, **indicele silhouette** sau **criteriul BIC** pentru a evalua calitatea clusteringului.

3. În ACS, ce relație există între proiecțiile punctelor-individ și proiecțiile punctelor-variabilă, pe aceeași axă?

În **Analiza Corespondențelor Simple (ACS)**, există o **relație directă** între coordonatele indivizilor și coordonatele variabilelor pe aceeași axă factorială. Aceasta se exprimă prin:

$$F_{ik} = \lambda_k G_{jk}$$

unde:

- F_{ik} este coordonata individului i pe axa k ,
- G_{jk} este coordonata variabilei j pe axa k ,
- λ_k este valoarea proprie corespunzătoare componentei k .

Această relație indică faptul că:

1. **Indivizii și variabilele sunt proiectați în același spațiu factorial.**
2. **Variabilele determină structura factorială, iar indivizii sunt poziționați în funcție de aceste variabile.**
3. **Corelația dintre un individ și o variabilă este dată de proiecția lor comună pe aceleași axe factoriale.**

4. Enunțați și caracterizați, pe scurt, trei strategii de agregare pe disimilarități.

Răspuns:

1. **Metoda "Single Linkage" (Lanțul minim)**
 - Se alege **cea mai mică distanță** dintre elementele celor două grupuri.
 - Poate genera **efectul de lanț** (clustere alungite și neuniforme).
2. **Metoda "Complete Linkage" (Lanțul maxim)**

- Se alege **cea mai mare distanță** dintre elementele grupurilor.
- Creează clustere **mai compacte**.

3. Metoda Ward

- Minimiza **varianța intra-cluster** la fiecare pas.
- Produce **clustere echilibrate ca dimensiune**.

5. Construiți matricea distanțelor euclidiene dintre indivizi pentru tabelul:

	V1	V2	V3
<i>Ind1</i>	0	0	0
<i>Ind2</i>	1	1	1
<i>Ind3</i>	1	1	0
<i>Ind4</i>	0	0	1

Răspuns:

Folosim distanța euclidiană:

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

Vom calcula matricea distanțelor euclidiene.

2. Se aplică formula distanței euclidiene între doi indivizi A și B :

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

3. Calculăm distanțele dintre fiecare pereche de indivizi:

- $d(Ind1, Ind2) =$
 $\sqrt{(0 - 1)^2 + (0 - 1)^2 + (0 - 1)^2} = \sqrt{3} = 1.732$
- $d(Ind1, Ind3) =$
 $\sqrt{(0 - 1)^2 + (0 - 1)^2 + (0 - 0)^2} = \sqrt{2} = 1.414$
- $d(Ind1, Ind4) =$
 $\sqrt{(0 - 0)^2 + (0 - 0)^2 + (0 - 1)^2} = \sqrt{1} = 1.000$
- $d(Ind2, Ind3) =$
 $\sqrt{(1 - 1)^2 + (1 - 1)^2 + (1 - 0)^2} = \sqrt{1} = 1.000$
- $d(Ind2, Ind4) =$
 $\sqrt{(1 - 0)^2 + (1 - 0)^2 + (1 - 1)^2} = \sqrt{2} = 1.414$
- $d(Ind3, Ind4) =$
 $\sqrt{(1 - 0)^2 + (1 - 0)^2 + (0 - 1)^2} = \sqrt{3} = 1.732$

4. Se construiește matricea distanțelor euclidiene:

$$\begin{bmatrix} 0.000 & 1.732 & 1.414 & 1.000 \\ 1.732 & 0.000 & 1.000 & 1.414 \\ 1.414 & 1.000 & 0.000 & 1.732 \\ 1.000 & 1.414 & 1.732 & 0.000 \end{bmatrix}$$

5b Care este pierderea de inerție ce se obține prin agregarea indivizilor 3 și 4?

Pierderea de inerție este definită ca diferența dintre **inerția înainte** și **inerția după agregare**. Formula generală este:

$$\Delta I = \frac{n_1 n_2}{n_1 + n_2} d^2(A, B)$$

unde:

- n_1, n_2 sunt numărul de observații din fiecare grup înainte de agregare.
- $d^2(A, B)$ este pătratul distanței dintre cele două grupuri înainte de agregare.

Vom calcula pierderea de inerție pentru indivizii 3 și 4.

Pierderea de inerție prin agregarea indivizilor 3 și 4 este **1.5**.

Formula folosită:

$$\Delta I = \frac{n_1 n_2}{n_1 + n_2} d^2(A, B)$$

unde $d(Ind3, Ind4) = 1.732$. Acest rezultat poate fi inclus direct

Pașii de rezolvare:

1. Formula pierderii de inerție:

$$\Delta I = \frac{n_1 n_2}{n_1 + n_2} d^2(A, B)$$

unde:

- $n_1 = n_2 = 1$ (fiecare individ are greutate 1),
- $d(Ind3, Ind4) = 1.732$.

2. Calculăm ΔI :

$$\Delta I = \frac{1 \cdot 1}{1 + 1} \cdot (1.732)^2$$

$$\Delta I = \frac{1}{2} \cdot 3$$

$$\Delta I = 1.5$$

2. În clasificarea ierarhică, prezentați pe scurt un algoritm de tăiere al arborelui de clasificare.

Răspuns:

Pentru a determina numărul optim de clustere într-un **dendrogramă**, se aplică un **algoritm de tăiere**:

1. **Construirea dendrogramului** – Se realizează clustering ierarhic utilizând o metodă de legătură (ex. Ward, Single, Complete Linkage).
2. **Definirea unui criteriu de tăiere**:

- **Tăiere la un nivel fix al distanței** – Se alege o valoare prag a distanței dintre clustere și se taie dendrograma la acel nivel.
 - **Elbow Method (metoda cotului)** – Se identifică punctul unde diferența dintre distanțele succesive devine nesemnificativă.
 - **Indicele silhouette** – Se calculează și se alege numărul de clustere cu valoarea maximă a acestui indice.
3. **Extracția grupelor** – Se obțin grupurile finale de indivizi.

3. În ACS, demonstrați că centrul de greutate al profilurilor-coloană este normalat și perpendicular pe spațiul punctelor-coloană din R^n

Răspuns:

- **Normare:** În ACS, fiecare profil-coloană este definit ca un vector normalizat astfel încât suma elementelor sale să fie 1. Se poate scrie:

$$G_c = \sum_i p_{ic} \cdot F_i$$

unde:

- p_{ic} este frecvența relativă a individului i pentru coloana c ,
- F_i este vectorul profilului linie.
- **Perpendicularitate:**
 - Spațiul punctelor-coloană este generat de profilurile-coloană.
 - În ACS, centrul de greutate al profilurilor-coloană este definit astfel încât să fie **ortogonal** pe subspațiul acestora.
 - Proprietatea ortogonalității derivă din metoda utilizată pentru diagonalizarea matricei de covarianță ponderată.

Astfel, centrul de greutate aparține subspațiului definit de variabile și este perpendicular pe direcțiile principale ale proiecției.

•

1. Verificăm că este normal:

- În ACS, suma ponderată a frecvențelor relative este **1**, deci centrul de greutate al profilurilor coloană este **normal**.

$$\sum_c G_c = 1$$

✓ Confirmat: Centrul de greutate al profilurilor coloană este normal.

2. Verificăm că este perpendicular pe spațiul punctelor-coloană:

- În ACS, coordonatele centrelor de greutate sunt definite astfel încât să fie **ortogonale pe direcțiile principale ale proiecției**.
- Rezultă că **centrul de greutate al profilurilor coloană este perpendicular pe direcțiile principale ale norului de puncte**.

✓ Confirmat: Centrul de greutate al profilurilor coloană este perpendicular pe spațiul punctelor-coloană.

4. Care sunt ipotezele fundamentale ce permit în ACM transformarea unui tabel de date primare în tabel disjunctiv complet? Ce este tabelul Burt? Care este efectivul total?

Răspuns:

- **Ipoteze fundamentale în ACM:**
 1. **Variabilele trebuie să fie nominale** (categorice).
 2. **Se folosește codificarea disjunctivă completă** – fiecare categorie devine o coloană binară.
 3. **Inerția trebuie să fie distribuită proporțional** între variabile și indivizi.
- **Tabelul Burt:**
 - Este o **matrice de contingență bloc**, unde fiecare bloc conține **frecvențele comune** ale categoriilor.
 - Se obține prin multiplicarea matricei disjunctive complete cu transpusa sa.

$$B = ZZ^T$$

unde Z este matricea disjunctivă.

- **Efectiv total al tabelului Burt:**
 - **Suma tuturor elementelor** tabelului Burt este egală cu **numărul total de indivizi** din setul de date.
-

5. Care sunt inconvenientele metodei Forgy?

Răspuns:

Metoda **Forgy** este o tehnică de inițializare pentru algoritmul K-means, în care centrele de cluster sunt selectate **aleatori** din setul de date.

Principalele inconveniente:

1. **Sensibilitate la punctele inițiale**
 - Dacă punctele inițiale sunt alese prost, algoritmul poate ajunge la un minim local slab.
2. **Instabilitate între execuții**
 - Deoarece alegerea inițială este aleatorie, algoritmul poate returna soluții diferite pentru aceleași date.
3. **Clusterizarea inefficientă pentru seturi de date cu zgomot**
 - Punctele de date zgomotoase pot influența negativ stabilitatea clusteringului.

1. În ACP, distanța punctelor unui tabel centrat-redus - formulă

În **Analiza în Componente Principale (ACP)**, datele sunt standardizate pentru a avea media 0 și deviația standard 1.

Distanța dintre două puncte X_i și X_j într-un tabel centrat-redus este dată de **distanța Euclidiană** calculată pe variabilele standardizate:

$$d(X_i, X_j) = \sqrt{\sum_{k=1}^p (Z_{ik} - Z_{jk})^2}$$

unde:

- Z_{ik} este valoarea standardizată a individului i pe variabila k ,
- p este numărul de variabile.

Această distanță reflectă similaritatea dintre indivizi în **spațiul original al variabilelor standardizate**.

2. În ACS, distanța dintre punctele unui tabel centrat-redus - formulă

În **Analiza Corespondențelor Simple (ACS)**, distanța dintre două puncte-individ este definită folosind **distanța Khi-pătrat ponderată**

$$d^2(X_i, X_j) = \sum_{k=1}^p \frac{(f_{ik} - f_{jk})^2}{p_k}$$

unde:

- f_{ik} este frecvența relativă a individului i pe variabila k ,
- p_k este suma totală a frecvențelor pe variabila k .

Această distanță este utilizată deoarece ACS analizează **date categorice** și nu continue, ceea ce necesită o măsură de disimilaritate adaptată.

3. Inconvenientele metodei Forgy

Metoda Forgy este o tehnică utilizată pentru inițializarea algoritmului **K-means**, în care centrele de clustere sunt selectate **aleatoriu** din setul de date.

Principalele dezavantaje:

1. **Sensibilitate la punctele inițiale**

- Alegerea aleatorie poate conduce la soluții suboptimale, deoarece K-means converge spre un **minim local**.
- 2. **Rezultate instabile între execuții**
 - Deoarece inițializarea este diferită la fiecare rulare, pot apărea **variații** semnificative în clasificarea finală.
- 3. **Clusterizare slabă în prezența zgomotului**
 - Punctele zgomotoase sau outlierii pot influența inițializarea și, implicit, rezultatul final.
- 4. **Necesitatea mai multor rulări pentru stabilitate**
 - Pentru a obține o soluție robustă, trebuie **rulat de mai multe ori**, alegând soluția cu cel mai mic criteriu de eroare.

O alternativă mai bună la Forgy este **K-means++**, care inițializează centrele de clustere mai inteligent.

4. Demonstrați că indicele Jaccard este o disimilaritate

Indicele **Jaccard** este utilizat pentru a măsura similaritatea dintre **două seturi**, dar poate fi folosit și ca o **măsură de disimilaritate**.

Definiția coeficientului Jaccard

Dacă avem două seturi AA și BB, coeficientul de similaritate Jaccard este definit ca:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

unde:

- $|A \cap B|$ este numărul de elemente comune,
- $|A \cup B|$ este numărul total de elemente distincte în cele două seturi.

Măsura de disimilaritate Jaccard

Pentru a obține o **măsură de disimilaritate**, se definește complementul coeficientului de similaritate:

$$D_J(A, B) = 1 - J(A, B)$$

Această măsură respectă **proprietățile unei disimilarități**:

1. **Non-negativitate:** $0 \leq D_J(A, B) \leq 1$.
2. **Identitate:** $D_J(A, A) = 0$.
3. **Simetrie:** $D_J(A, B) = D_J(B, A)$.
4. **Inegalitatea triunghiului** (pentru anumite cazuri):
 - Deși indicele Jaccard nu este o **distanță metrică**, pentru aplicații în clustering, este utilizat ca o **măsură validă de disimilaritate**.

Astfel, **Jaccard este o disimilaritate**, deoarece indică **cât de diferite sunt două seturi**, iar valoarea sa crește pe măsură ce seturile devin mai distincte.



10. Formula distanței în ACS (Analiza Corespondențelor Simple)

În **ACS**, distanța dintre două puncte-individ este calculată folosind **distanța Khi-pătrat ponderată**, definită astfel:

$$d^2(X_i, X_j) = \sum_{k=1}^p \frac{(f_{ik} - f_{jk})^2}{p_k}$$

unde:

- f_{ik} este frecvența relativă a individului i pentru variabila k ,
- f_{jk} este frecvența relativă a individului j pentru variabila k ,
- p_k este suma totală a frecvențelor pentru variabila k .

Această formulă este utilizată pentru că **datele în ACS sunt categorice**, iar distanța trebuie să țină cont de frecvențele ponderate ale fiecărei categorii.

12. În clasificare ierarhică prezentați pe scurt un algoritm empiric de tăiere a arborelui de clasificare.

În **clasificarea ierarhică**, tăierea arborelui (dendrograma) este procesul de determinare a numărului optim de clustere. Un algoritm empiric pentru această tăiere include următorii pași:

Pașii algoritmului:

1. **Construirea dendrogramului**
 - Se aplică un algoritm de clasificare ierarhică (ex: **Single Linkage, Complete Linkage, Ward**).
 - Se construiește **matricea distanțelor** dintre indivizi.
2. **Definirea unui criteriu de tăiere**

Se alege unul dintre următoarele criterii:

 - **Distanța prag**: Se taie arborele la un nivel al distanței dintre clustere unde creșterea distanței este bruscă.
 - **Metoda „Elbow” (cotului)**: Se identifică punctul unde **diferența dintre distanțele succesive devine ne semnificativă**.
 - **Indicele silhouete**: Se calculează coeficientul silhouete pentru diferite numere de clustere și se alege numărul care maximizează acest coeficient.
3. **Tăierea efectivă a arborelui**
 - Se analizează dendrograma și se trasează o linie orizontală la nivelul ales (pe baza criteriului selectat).
 - Se identifică numărul de clustere formate de această tăiere.
4. **Atribuirea finală a indivizilor în clustere**
 - Se etichetează fiecare grup de indivizi ca făcând parte dintr-un anumit cluster.

14. Enunțați și caracterizați, pe scurt, 3 strategii de agregare pe disimilitati

În clasificarea ierarhică, agregarea indivizilor în grupuri se face pe baza **matricei de disimilaritate**. Cele mai utilizate metode de agregare sunt:

1. Metoda legăturii complete (Complete Linkage)

- **Definiție**: Se calculează **distanța maximă** dintre indivizii celor două grupuri ce urmează să fie unite.

- **Formula:**

$$d(A, B) = \max\{d(x, y) \mid x \in A, y \in B\}$$

unde A și B sunt grupurile analizate.

- **Caracteristici:**

- Produce **clustere compacte**, în care toate elementele sunt apropiate.
- Evită formarea de **clustere alungite**.
- Poate supraestima distanțele dintre grupuri.

,

2. Metoda legăturii simple (Single Linkage)

- **Definiție:** Se calculează **cea mai mică distanță** dintre indivizii celor două grupuri ce urmează să fie unite.

- **Formula:**

$$d(A, B) = \min\{d(x, y) \mid x \in A, y \in B\}$$

- **Caracteristici:**

- Formează **lanțuri de elemente apropiate** (efect de „chaining”).
- Este sensibilă la **outlieri**, care pot crea clustere neuniforme.
- Potrivită pentru identificarea grupărilor extinse, dar poate crea clustere dispersate.

•

3. Metoda Ward (criteriul minimizării varianței intra-cluster)

- **Definiție:** Se minimizează **creșterea varianței intra-cluster** la fiecare etapă de agregare.

- Formula pentru pierderea de inerție la agregare:

$$\Delta I = \frac{n_1 n_2}{n_1 + n_2} d^2(A, B)$$

unde:

- n_1, n_2 sunt dimensiunile clusterelor,
- $d(A, B)$ este distanța dintre centrele clusterelor.
- **Caracteristici:**
 - Produce **cluster echilibrate** și bine separate.
 - Evită formarea lanțurilor de cluster.
 - Este metoda preferată pentru **stabilitatea clusteringului**.

17. Care sunt ipotezele fundamentale ce permit în ACM transformarea unui tabel de date primare în tabel disjunctiv complet. Ce este tabelul BURT? Care este efectivul total

Ipotezele fundamentale pentru transformarea unui tabel de date primare în tabel disjunctiv complet în ACM (Analiza Corespondențelor Multiple)

În **Analiza Corespondențelor Multiple (ACM)**, un tabel de date primare este transformat într-un **tabel disjunctiv complet (TDC)** pentru a permite aplicarea tehnicilor de analiză factorială. Această transformare se bazează pe următoarele **ipoteze fundamentale**:

1. **Variabilele trebuie să fie categorice (nominale sau ordinale)**
 - ACM nu se aplică direct pe variabile numerice continue, ci doar pe variabile discrete.
2. **Codificarea disjunctivă completă**
 - Fiecare **categorie** a unei variabile devine o coloană separată în tabel.
 - Pentru fiecare individ, doar o **singură valoare per variabilă este 1**, restul sunt 0.
3. **Inerția trebuie să fie distribuită proporțional între variabile și indivizi**
 - Inerția totală este definită astfel încât să fie comparabilă între variabile cu număr diferit de categorii.

Ce este tabelul BURT?

Tabelul Burt este o **matrice de contingență bloc** utilizată în ACM, care conține frecvențele comune ale categoriilor variabilelor. Se obține prin:

$$B = ZZ^T$$

unde:

- Z este **matricea disjunctivă completă** (TDC),
- Z^T este transpusa sa.

Structura tabelului Burt

Dacă avem trei variabile categorice (V_1, V_2, V_3), tabelul Burt are forma:

$$\begin{bmatrix} V_1 & V_1 \cap V_2 & V_1 \cap V_3 \\ V_2 \cap V_1 & V_2 & V_2 \cap V_3 \\ V_3 \cap V_1 & V_3 \cap V_2 & V_3 \end{bmatrix}$$

unde fiecare bloc $V_i \cap V_j$ reprezintă frecvențele comune între categoriile variabilelor respective.

Care este efectivul total al tabelului Burt?

- **Efectivul total** al tabelului Burt este **suma tuturor elementelor** din tabel.
- Acesta este **egal cu numărul total de indivizi** înmulțit cu **numărul de variabile** analizate.

Dacă N este numărul total de indivizi și avem p variabile, atunci:

$$\text{Efectiv total} = N \cdot p$$

18. La 12 persoane li s-a cerut să asocieze culorilor albastru, roșu și verde un singur adjectiv, calm sau viu. S-a obținut următorul tabel: Calculați centrul de greutate al profilelor linie și verificați că vectorul este normat și ortogonal pe profilele linie centrate.

1. Definirea tabelului de frecvențe

În enunț, avem un **tabel de contingență** cu răspunsurile a **12 persoane** care au asociat culorilor **Albastru (A), Roșu (R) și Verde (V)** un singur adjectiv: **Calm** sau **Viu**.

	A	R	V	Total linie
Calm	2	3	1	6
Viu	2	2	2	6

Total general: 12

2. Calculul profilurilor linie

Profilele linie sunt obținute prin împărțirea fiecărui element la **totalul liniei**, pentru a obține **frecvențele relative**.

$$\text{Profil liniar} = \frac{\text{Valoare în celulă}}{\text{Total linie}}$$

Aplicăm formula:

	A	R	V
Calm	$\frac{2}{6} = 0.333$	$\frac{3}{6} = 0.500$	$\frac{1}{6} = 0.167$
Viu	$\frac{2}{6} = 0.333$	$\frac{2}{6} = 0.333$	$\frac{2}{6} = 0.333$

3. Calculul centrului de greutate al profilurilor linie

Centrul de greutate se obține prin **media ponderată** a frecvențelor relative pentru fiecare variabilă.

$$G = \frac{1}{2} \sum_{i=1}^2 p_i$$

Aplicăm formula pentru fiecare coloană:

$$G_A = \frac{0.333 + 0.333}{2} = 0.333$$

$$G_R = \frac{0.500 + 0.333}{2} = 0.417$$

$$G_V = \frac{0.167 + 0.333}{2} = 0.250$$

Rezultatul:

	A	R	V
Centru greutate	0.333	0.417	0.250

4. Calculul profilurilor linie centrate

Profilele linie centrate se obțin prin **scăderea centrului de greutate** din fiecare valoare a profilurilor linie:

$$\text{Profil Linie Centrat} = \text{Profil Linie} - \text{Centru Greutate}$$

Aplicăm formula:

	A	R	V
Calm	$0.333 - 0.333 = 0.000$	$0.500 - 0.417 = 0.083$	$0.167 - 0.250 = -0.083$
Viu	$0.333 - 0.333 = 0.000$	$0.333 - 0.417 = -0.083$	$0.333 - 0.250 = 0.083$

5. Verificarea normării centrului de greutate

Un centru de greutate este normat dacă suma elementelor sale este egală cu 1.

$$G_A + G_R + G_V = 0.333 + 0.417 + 0.250 = 1.0$$

Rezultatul: Centrul de greutate este normat .

6. Verificarea ortogonalității profilurilor linie centrate față de centrul de greutate

Două vectori sunt **ortogonali** dacă **produsul lor scalar este 0**.

Produsul scalar al profilurilor linie centrate cu centrul de greutate:

$$(0.000 \times 0.333) + (0.083 \times 0.417) + (-0.083 \times 0.250) = 0$$

$$(0.000 \times 0.333) + (-0.083 \times 0.417) + (0.083 \times 0.250) = 0$$

Rezultatul: Profilurile linie centrate sunt ortogonale față de centrul de greutate .



$$\sum_k ((\text{Profil Linie Centrat}_1)_k \cdot G_k + (\text{Profil Linie Centrat}_2)_k \cdot G_k)$$

Demonstrați că indicele Jacard este o disimilaritate

1. Definiția disimilarității

O funcție $d(x, y)$ este o **măsură de disimilaritate** dacă îndeplinește următoarele **proprietăți**:

1. Non-negativitate:

$$d(x, y) \geq 0, \quad \forall x, y$$

2. Identitate (auto-similaritate):

$$d(x, x) = 0, \quad \forall x$$

3. Simetrie:

$$d(x, y) = d(y, x), \quad \forall x, y$$

4. Inegalitatea triunghiului (opțional pentru o disimilaritate, obligatoriu pentru o metrică):

$$d(x, z) \leq d(x, y) + d(y, z), \quad \forall x, y, z$$

2. Formula Indicele Facard

Indicele **Facard** este definit astfel:

$$d_F(A, B) = 1 - \frac{|A \cap B|}{\max(|A|, |B|)}$$

unde:

- $|A|$ și $|B|$ sunt dimensiunile celor două mulțimi,
- $|A \cap B|$ este numărul de elemente comune.

e jacard nu Facard

3. Verificarea proprietăților unei disimilarități

✓ (i) Non-negativitate

- Deoarece $|A \cap B| \leq \max(|A|, |B|)$, rezultă că:

$$\frac{|A \cap B|}{\max(|A|, |B|)} \leq 1$$

ceea ce implică:

$$1 - \frac{|A \cap B|}{\max(|A|, |B|)} \geq 0$$

Deci $d_F(A, B) \geq 0$, ceea ce confirmă proprietatea.

✓ (ii) Identitatea

- Dacă $A = B$, atunci $|A \cap B| = |A| = |B|$, deci:

$$d_F(A, B) = 1 - \frac{|A|}{\max(|A|, |A|)} = 1 - 1 = 0$$

Deci $d_F(A, A) = 0$, ceea ce confirmă proprietatea.

✓ (iii) Simetria

- Deoarece **numărul de elemente comune** este simetric:

$$|A \cap B| = |B \cap A|$$

și $\max(|A|, |B|)$ este independent de ordinea lui A și B ,
rezultă că:

$$d_F(A, B) = d_F(B, A)$$

Deci indicele este **simetric**.

✓ (iv) Inegalitatea triunghiului (aproximativ verificată)

- Pentru orice trei mulțimi A, B, C , avem:

$$d_F(A, C) \leq d_F(A, B) + d_F(B, C)$$

Această proprietate **nu este întotdeauna strict respectată**, dar
indicele **poate fi folosit ca disimilaritate** deoarece respectă
celelalte proprietăți necesare.

1. Enunțați principiul echivalenței distribuționale pentru coloane la agregarea liniilor unui tabel de contingență. Demonstrați că distanța Hellinger verifică acest principiu.

În analiza datelor categorice, **principiul echivalenței distribuționale** afirmă că **distanța dintre două linii ale unui tabel de contingență trebuie să fie invariantă la agregarea liniilor care au aceleași distribuții relative pe coloane.**

Definiție formală:

Dacă două rânduri dintr-un tabel de contingență au **aceeași distribuție relativă pe coloane**, atunci distanța dintre ele și orice alt rând trebuie să rămână **neschimbată** după agregare.

Aceasta asigură că **gruparea indivizilor cu distribuții similare** nu afectează rezultatul analizei factoriale sau clusteringului.

Distanța Hellinger între două distribuții de probabilitate $X = (x_1, x_2, \dots, x_n)$ și $Y = (y_1, y_2, \dots, y_n)$ este definită ca:

$$d_H^2(X, Y) = \sum_{i=1}^n (\sqrt{x_i} - \sqrt{y_i})^2$$

unde:

- $x_i = \frac{n_i}{N}$ și $y_i = \frac{m_i}{M}$ sunt frecvențele relative ale liniilor X și Y ,
- n_i și m_i sunt numărul de apariții pentru categoria i ,
- N și M sunt sumele totale ale rândurilor respective.

Verificarea principiului echivalenței distribuționale

Conform **principiului echivalenței distribuționale**, dacă două rânduri dintr-un tabel de contingență au **aceeași distribuție relativă pe coloane**, atunci distanța dintre ele și orice alt rând trebuie să rămână **neschimbată** după agregare.

1. Considerăm două rânduri X și Y proporționale

Dacă X și Y sunt proporționale, atunci există un scalar $\alpha > 0$ astfel încât:

$$y_i = \alpha x_i, \quad \forall i$$

Luând rădăcina pătrată:

$$\sqrt{y_i} = \sqrt{\alpha} \cdot \sqrt{x_i}$$

Aplicând formula distanței Hellinger:

$$d_H^2(X, Y) = \sum_{i=1}^n (\sqrt{x_i} - \sqrt{\alpha} \cdot \sqrt{x_i})^2$$

Factorizăm $\sqrt{x_i}$:

$$d_H^2(X, Y) = \sum_{i=1}^n x_i (1 - \sqrt{\alpha})^2$$

Dacă agregăm mai multe astfel de rânduri, proporționalitatea se păstrează, iar distanța Hellinger rămâne constantă.

Distanța Hellinger **verifică principiul echivalenței distribuționale**, deoarece este **invariantă** la agregarea liniilor care au aceeași distribuție relativă.

Ce legătură există în ACM între centrele de greutate ale modalităților și centrul de greutate al norului global? Justificați răspunsul!

În Analiza Corespondențelor Multiple (ACM), centrul de greutate al norului global este media ponderată a centrelor de greutate ale modalităților, ponderate prin frecvențele acestora.

Matematic, această relație se exprimă prin formula:

$$G = \sum_j f_j G_{M_j}$$

unde:

- G este centrul de greutate al norului global,
- G_{M_j} sunt centrele de greutate ale modalităților,
- f_j sunt frecvențele relative ale modalităților.

Justificare:

- Centrele de greutate ale modalităților sunt plasate **simetric** față de centrul norului global.
- Distanțele dintre modalități și centrul global reflectă structura variabilelor.
- Această relație asigură **corectitudinea reprezentării** în spațiul factorial ACM.

Care sunt inconvenientele metodei Forgý

Inconvenientele metodei Forgý

Metoda **Forgý** este o tehnică de inițializare utilizată în algoritmul **K-means**, în care centrele de clustere sunt selectate **aleatoriu** din setul de date.

Principalele dezavantaje:

1. **Sensibilitate la inițializare**
 - Alegerea aleatorie a centroidelor poate duce la **soluții suboptimale**, deoarece K-means poate converge către **minime locale**.
2. **Rezultate instabile între execuții**
 - Deoarece inițializarea este aleatorie, algoritmul poate furniza **clasificări diferite** la fiecare rulare.
3. **Clusterizare slabă în prezența outlierilor**
 - Punctele anormale pot influența negativ inițializarea, ducând la **cluster dezechilibrate**.
4. **Necesitatea mai multor rulări pentru stabilitate**
 - Pentru a obține o soluție robustă, metoda trebuie **rulată de mai multe ori**, alegând configurația cu **cea mai mică variație intra-cluster**.

13. Ce distanță se utilizează în ACP centrat redus în spațiul indivizilor, dar în ACS? Scrieți formulele lor!

Distanța utilizată în ACP centrat-reduc (spațiul indivizilor)

În **ACP centrat-reduc**, datele sunt standardizate astfel încât fiecare variabilă să aibă **media 0 și deviația standard 1**.

Distanța utilizată între doi indivizi AA și BB este **distanța Euclidiană** calculată pe variabilele standardizate:

$$d(A, B) = \sqrt{\sum_{k=1}^p (Z_{Ak} - Z_{Bk})^2}$$

unde:

- Z_{Ak} și Z_{Bk} sunt valorile **standardizate** ale indivizilor A și B pentru variabila k ,
- p este numărul total de variabile.

Distanța utilizată în ACS (spațiul indivizilor)

În **ACS**, datele sunt de tip **categoric** și sunt exprimate sub formă de **frecvențe relative**. Distanța utilizată este **distanța Khi-pătrat ponderată**, definită astfel:

$$d^2(A, B) = \sum_{k=1}^p \frac{(f_{Ak} - f_{Bk})^2}{p_k}$$

unde:

- f_{Ak} și f_{Bk} sunt **frecvențele relative** ale indivizilor A și B pentru variabila k ,
- p_k este frecvența totală a variabilei k .

4 În clasificarea neierarhică enunțați criteriul de optim local folosit pentru obținerea unor clase cât mai omogene.

În clasificarea neierarhică, cel mai utilizat **criteriu de optimizare** pentru obținerea unor **clustere omogene** este **minimizarea varianței intra-cluster**.

Criteriul Ward (criteriul minimizării varianței intra-cluster)

$$J = \sum_{k=1}^K \sum_{i \in C_k} ||x_i - \mu_k||^2$$

unde:

- K este numărul total de clustere,
- C_k reprezintă clusterul k ,
- x_i este un individ din clusterul C_k ,
- μ_k este centrul clusterului C_k .

Interpretare:

- Se minimizează **dispersia intra-cluster**, obținând **clustere cât mai omogene**.
- Evită formarea de clustere dezechilibrate și îmbunătățește coerența grupării.

✓ Criteriul Ward este cel mai utilizat pentru obținerea unor clase cât mai omogene.

Răspuns: Criteriul de optim local în clasificarea neierarhică

În clasificarea neierarhică, criteriul de **optim local** folosit pentru obținerea unor clase cât mai omogene este **minimizarea varianței intra-cluster**.

Formula criteriului de optim local (K-means)

$$J = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

unde:

- K este numărul de clustere,
- C_k este clusterul k ,
- x_i este un individ din clusterul C_k ,
- μ_k este centrul clusterului C_k .

Explicație:

- Se minimizează distanța  ratică dintre indivizi și centrul clusterului lor

Explicație:

- Se minimizează distanța pătratică dintre indivizi și centrul clusterului lor.
- Algoritmul poate rămâne blocat într-un **optim local**, depinzând de punctele inițiale alese.
- O soluție pentru evitarea unui optim local este **K-means++**, care optimizează inițializarea clusterelor.